Revoluce v Tvorbě Hmoty – Průlomové Aplikace a Budoucnost AI v Materiálovém Inženýrství

Spojení umělé inteligence (AI) a materiálového inženýrství není pouhým akademickým cvičením; je to katalyzátor bezprecedentní vědecké revoluce, která od základu mění způsob, jakým objevujeme, navrhujeme a vytváříme hmotu. Nacházíme se na prahu nové éry, kde zdlouhavé a nákladné procesy založené na intuici a metodě pokus-omyl ustupují datově řízeným strategiím, které slibují řádové zrychlení inovací. Tento report provede čtenáře od fundamentální změny vědeckého paradigmatu, přes konkrétní, dechberoucí úspěchy, kde AI již dnes přepisuje pravidla hry, až po vizi budoucnosti. V této budoucnosti autonomní laboratoře a inteligentní systémy navrhují materiály na míru pro řešení největších globálních výzev – od čisté energie po pokročilou medicínu. Pro studenty technických oborů to představuje jedinečnou příležitost. Ti, kteří se chopí těchto nových nástrojů, se nestanou pouhými pozorovateli, ale aktivními architekty materiálové budoucnosti, schopnými tvořit řešení, která byla ještě včera doménou science fiction.

Část 1: Nové paradigma – Proč je AI v materiálových vědách nevyhnutelné?

Od Alchymie k Algoritmům: Omezení Tradičního Objevování Materiálů

Tradiční model objevování a vývoje nových materiálů byl po staletí procesem, který se více podobal umění než exaktní vědě. Byl pomalý, nesmírně nákladný a vysoce neefektivní.[1] Vědci se spoléhali na kombinaci hlubokých teoretických znalostí, chemické intuice a především na zdlouhavou metodu "pokus-omyl".[3] Tento přístup, kdy se syntetizují a následně testují stovky či tisíce kandidátních sloučenin, vede k tomu, že průměrná doba od prvotního objevu materiálu v laboratoři po jeho komerční nasazení trvá 10 až 20 let.[5]

Tato časová prodleva má drtivé ekonomické důsledky. V mnoha případech, kdy se nový, revoluční materiál konečně dostane na trh, se jeho původní patentová ochrana chýlí ke konci. Tím se ztrácí klíčová konkurenční výhoda a snižuje se návratnost obrovských investic do výzkumu a vývoje.[1] Tento model je nejen ekonomicky neudržitelný, ale především je příliš pomalý na to, aby dokázal efektivně reagovat na naléhavé globální výzvy, jako je potřeba

dekarbonizace energetiky, vývoj udržitelných technologií nebo rychlý pokrok v medicíně.[4] Hledat nový materiál tradiční metodou je jako snažit se najít jednu konkrétní knihu v obrovské knihovně bez jakéhokoli katalogu – vědec musí náhodně otevírat svazky jeden po druhém a doufat v náhodný objev.

Čtvrté Paradigma Vědy: Zrození Materiálové Informatiky

Vědecký pokrok lze historicky rozdělit do čtyř klíčových fází neboli paradigmat. První, **empirické paradigma**, bylo založeno na pozorování a experimentu. Druhé, **teoretické paradigma**, přineslo modely a rovnice, které dokázaly popsat pozorované jevy. Třetí, **výpočetní paradigma**, využilo sílu počítačů k simulaci komplexních systémů. Dnes vstupujeme do **čtvrtého paradigmatu – datově řízené vědy**.[2] Toto paradigma je založeno na myšlence, že z obrovských datových souborů, které jsou příliš velké a složité pro tradiční lidské uvažování, lze pomocí pokročilých algoritmů systematicky extrahovat nové znalosti a objevy.[1]

Aplikací tohoto čtvrtého paradigmatu na materiálové vědy vznikla zcela nová, interdisciplinární disciplína: **materiálová informatika**.[7] Nejde jen o inkrementální zlepšení stávajících metod; je to fundamentální změna v samotném přístupu k výzkumu.[9] Materiálová informatika opouští tradiční "dopředný" návrh, kde se nejdříve syntetizuje materiál a až poté se testují jeho vlastnosti. Místo toho zavádí koncept

"inverzního návrhu" (inverse design).[8] Tento revoluční přístup obrací celý proces: vědec nejprve definuje požadované vlastnosti (např. "hledám lehký, průhledný a vodivý materiál pro solární panely") a AI následně prohledává obrovský chemický prostor nebo dokonce generuje zcela nové struktury, aby našla "recept" na materiál, který tyto vlastnosti splňuje. Tento posun od deskriptivní otázky "Jaké vlastnosti má materiál X?" k preskriptivní otázce "Který materiál bude mít vlastnosti Y?" transformuje materiálového vědce z objevitele na designéra a architekta hmoty.

Metrika	Tradiční Paradigma (Před-AI)	Materiálová Informatika (AI-Driven)
Doba uvedení na trh	10-20 let [5]	Potenciálně 1-2 roky [11]
Metodologie	Intuice, Pokus-Omyl [3]	Datově řízená predikce, Inverzní návrh [8]
Rozsah	Inkrementální vylepšení, omezený průzkum	Rychlé prohledávání obrovských návrhových

		prostorů [3]
Klíčová otázka	"Jaké jsou vlastnosti tohoto materiálu?"	"Který materiál má vlastnosti, které potřebuji?"
Náklady	Vysoké (rozsáhlé experimentování) [1]	Významně snížené (virtuální screening) [9]

Část 2: Současné průlomy – Kde AI již dnes mění pravidla hry

Umělá inteligence není jen teoretickým příslibem; již dnes přináší konkrétní, přelomové výsledky v laboratořích po celém světě. Následující případové studie ilustrují, jak různé přístupy AI řeší reálné problémy a posouvají hranice možného. Tyto úspěchy ukazují synergii mezi různými technikami AI: od prediktivních modelů, které optimalizují známé třídy materiálů, přes základní modely, které umožňují široké prohledávání, až po generativní modely, které jsou schopny skutečné invence.

Případová studie 1: Kování nekovatelného – AI navrhuje superslitiny

- **Problém:** Slitiny s vysokou entropií (High-Entropy Alloys, HEAs), které se skládají z pěti či více prvků ve zhruba stejných poměrech, vykazují výjimečné mechanické vlastnosti, jako je extrémní pevnost a odolnost vůči vysokým teplotám. Jejich komplexní složení však vytváří astronomicky velký kombinační prostor. Prozkoumat tento prostor tradičními experimentálními metodami by bylo časově i finančně nemožné.[13] Cílem bylo najít nové slitiny s optimálními vlastnostmi pro letecký a energetický průmysl a zároveň dramaticky snížit počet nákladných experimentů.[14]
- **Řešení pomocí AI:** Vědci nasadili prediktivní modely strojového učení, jako jsou Random Forest a hluboké neuronové sítě (Deep Neural Networks), trénované na existujících datech z experimentů a počítačových simulací.[13] Tyto modely se naučily rozpoznávat složité, nelineární vztahy mezi chemickým složením slitiny, její mikrostrukturou a výslednými mechanickými vlastnostmi. Klíčovou roli sehrál koncept **aktivního učení** (Active Learning), kde AI po každém experimentu sama navrhne, která další slitina by měla být syntetizována a otestována, aby získala co nejvíce nových informací a co nejrychleji zpřesnila svůj vnitřní model.[13]
- **Výsledek:** Tento přístup vedl k úspěšnému vývoji nových titanových slitin s vynikající rovnováhou mezi pevností v tahu (kolem 1200 MPa) a tažností (kolem 12 %).[14] Prediktivní modely dosáhly mimořádné přesnosti; například u slitin na bázi γ-TiAl dosáhl model pro

predikci pevnosti v tahu koeficientu determinace (R^2) vyššího než 0.93 a pro predikci tažnosti dokonce 0.99.[14] Vznikají také pokročilé, fyzikálně-informované AI systémy, které integrují schopnosti velkých jazykových modelů s atomistickými simulacemi pro plně autonomní návrh slitin s požadovanými vlastnostmi.[15]

- **Dopad:** AI dramaticky zrychluje a zlevňuje proces návrhu slitin pro nejnáročnější aplikace. Umožňuje navrhovat materiály s vlastnostmi "na zakázku", což otevírá dveře k lehčím a úspornějším letadlům, efektivnějším elektrárnám a odolnějším konstrukcím v extrémních podmínkách.

Případová studie 2: Energie pro budoucnost – Zrychlený objev elektrolytů pro baterie nové generace

- **Problém:** Objev nových, vysoce výkonných a bezpečných elektrolytů je největší překážkou na cestě k bateriím nové generace, které jsou nezbytné pro masivní rozšíření elektromobility a efektivní ukládání energie z obnovitelných zdrojů. Ideální elektrolyt musí splňovat několik protichůdných požadavků současně: vysokou iontovou vodivost, chemickou stabilitu a vysokou účinnost.[16] Teoretický počet molekul, které by mohly sloužit jako elektrolyty, je odhadován na 10^{60} – číslo tak obrovské, že je naprosto mimo dosah jakýchkoli tradičních experimentálních metod.[16]
- **Řešení pomocí AI:** Tým vědců z University of Michigan ve spolupráci s Argonne National Laboratory využil sílu superpočítačů Polaris a Aurora k trénování specializovaných **základních modelů** (Foundation Models) na obrovských datasetech miliard známých molekulárních struktur.[18] Tyto modely si nevyvinuly jen schopnost predikovat jednu vlastnost, ale naučily se "univerzálnímu porozumění molekulárnímu vesmíru", což jim umožňuje s vysokou přesností predikovat celou škálu klíčových vlastností, jako je vodivost, bod tání, hořlavost a stabilita.[18] Jiný přístup, zvolený vědci z University of Chicago, spočíval ve využití AI k automatické analýze dat z 250 vědeckých článků publikovaných za posledních 50 let. Z těchto dat AI vytvořila tzv. "eScore", které hodnotí a řadí molekuly podle jejich vhodnosti pro použití v bateriích.[16]
- **Výsledek:** Trénovaný základní model nejenže sjednotil schopnosti dříve vyvinutých modelů pro jednotlivé vlastnosti, ale ve své prediktivní síle je i překonal.[18] Přístup založený na "eScore" úspěšně identifikoval molekulu s výkonem srovnatelným s nejlepšími komerčně dostupnými elektrolyty, což potvrdilo platnost celého datově řízeného přístupu.[17] V jiné studii AI-asistované modelování pomohlo vědcům pochopit, proč vysoká koncentrace soli v zink-iontových bateriích stabilizuje vodu v elektrolytu a zásadně zlepšuje výkon a bezpečnost baterie.[19]
- **Dopad:** AI zde funguje jako neuvěřitelně efektivní "filtr", který z téměř nekonečného chemického prostoru vybírá jen hrstku nejslibnějších kandidátů pro drahé a časově náročné laboratorní testování.[16] Tento přístup zásadně mění paradigma výzkumu v oblasti

ukládání energie a přibližuje nás k bezpečnějším, levnějším a výkonnějším bateriím, které jsou klíčem k udržitelné budoucnosti.[20]

Případová studie 3: Nové nástroje alchymisty – Generativní AI pro návrh nových katalyzátorů

- **Problém:** Katalyzátory jsou základním kamenem moderního chemického průmyslu; odhaduje se, že se podílejí na více než 90 % všech výrobních procesů. Jejich tradiční objevování však stále spoléhá na zdlouhavou metodu pokus-omyl.[21] Cílem je přejít k skutečnému inverznímu návrhu: definovat požadovanou chemickou reakci a nechat AI navrhnout zcela novou, optimální strukturu katalyzátoru.
- **Řešení pomocí AI:** Místo prediktivních modelů, které "jen" předpovídají vlastnosti existujících struktur, zde nastupují **generativní modely**. Technologie jako variační autoenkodéry (VAEs), generativní adversariální sítě (GANs) a v poslední době především transformery a difuzní modely se učí základním pravidlům, která řídí stabilitu a funkci molekul a krystalů. Na základě těchto naučených pravidel pak dokáží "vymýšlet" nebo "generovat" zcela nové, dosud neviděné struktury, které s vysokou pravděpodobností budou mít požadované katalytické vlastnosti.[10] Příkladem je model **CatGPT**, který byl specificky trénován, aby na základě požadavku generoval nejen strukturu, ale i kompletní, proveditelný a v praxi použitelný postup syntézy daného katalyzátoru.[21]
- **Výsledek:** V jedné průlomové studii dokázal model založený na VAE vygenerovat tisíce kandidátů na nové katalyzátory, z nichž 84 % bylo chemicky validních a unikátních. Následná analýza identifikovala 557 vysoce slibných kandidátů založených na levné a hojně dostupné mědi, která by mohla nahradit extrémně drahé a vzácné kovy jako platina a palladium.[23] Model CatGPT zase dokázal na základě jednoduchého dotazu navrhnout kompletní a detailní proces přípravy katalyzátoru pro oxidační kopulaci metanu (OCM), což je klíčová reakce pro přeměnu zemního plynu na cennější chemikálie.[21]
- **Dopad:** Generativní AI umožňuje skutečný *de novo* design materiálů. Počítač již není jen nástrojem pro analýzu, ale stává se kreativním partnerem, který dokáže extrapolovat za hranice existujících lidských znalostí a navrhovat struktury, které by člověk sám nevymyslel.[22] To otevírá dveře k objevování vysoce účinných a udržitelných katalyzátorů pro zelenou chemii, výrobu vodíku z vody, přeměnu CO2 na paliva a další klíčové technologie pro budoucnost planety.

Část 3: Budoucí hranice – Kam směřuje potenciál AI v materiálovém inženýrství?

Současné úspěchy jsou jen ochutnávkou toho, co nás čeká. Výzkum se ubírá směrem k ještě hlubší integraci umělé inteligence, robotiky a fyzikálních principů. Cílem není jen zrychlit jednotlivé kroky výzkumu, ale vytvořit plně autonomní ekosystémy pro objevování materiálů, které budou fungovat s minimálním lidským zásahem a s rychlostí, která je dnes nepředstavitelná.

Autonomní Vědec: Laboratoře s Vlastním Řízením ("Self-Driving Labs")

- **Koncept:** Představte si plně automatizovanou robotickou platformu, která pracuje 24 hodin denně, 7 dní v týdnu. Tato platforma, označovaná jako "Self-Driving Lab" (SDL), integruje AI a robotiku do jediné **uzavřené smyčky** (closed-loop).[25] Cyklus začíná tím, že AI na základě všech dosavadních dat vygeneruje hypotézu a navrhne optimální experiment. Robotické rameno poté tento experiment provede – smíchá chemikálie, zahřeje vzorek, provede měření. Výsledky jsou v reálném čase analyzovány a data jsou okamžitě poslána zpět do AI, která na jejich základě aktualizuje svůj model a plánuje další, ještě informovanější krok.[6]
- **Potenciál zrychlení:** Cílem těchto systémů je zkrátit dobu objevu a optimalizace nového materiálu z typických 10 let na pouhý 1 rok – tedy desetinásobně.[11] Díky schopnosti provádět stovky experimentů denně a učit se z každé iterace mohou tyto laboratoře prozkoumat obrovské prostory materiálových parametrů s bezprecedentní rychlostí a efektivitou.[6]
- **Klíčový průlom – Dynamické experimenty:** Nedávný vývoj tzv. "dynamických průtokových experimentů" představuje další řádové zrychlení. Místo tradičního přístupu, kdy se čeká na dokončení reakce a až poté se měří výsledek, nový systém monitoruje chemický proces v reálném čase a sbírá data každou půl sekundu. AI tak nezískává jen jeden konečný "snímek" výsledku, ale celý "film" o průběhu reakce.[27] Tento nesmírně bohatý datový proud umožňuje AI činit chytřejší a rychlejší rozhodnutí. Výsledkem je systém, který sbírá data nejméně 10x rychleji a dokáže identifikovat optimální materiál již po prvním cyklu učení.[27] Tato technologie neznamená jen zrychlení, ale také udržitelnější výzkum s menší spotřebou chemikálií a menším množstvím odpadu.

Vložení Fyziky do AI: Síla Fyzikálně Informovaných Neuronových Sítí (PINNs)

- **Problém "malých dat":** V mnoha oblastech materiálového výzkumu jsou experimentální data vzácná, drahá na pořízení, neúplná nebo zašuměná. Tento tzv. **"small data" problém** je velkou překážkou pro standardní modely strojového učení, které pro spolehlivé fungování vyžadují obrovské množství příkladů.[8]
- **Řešení pomocí PINNs:** Fyzikálně informované neuronové sítě (Physics-Informed Neural Networks, PINNs) jsou speciálním typem AI, která má do své učící se struktury přímo "zabudované" základní fyzikální zákony, obvykle ve formě parciálních diferenciálních rovnic.[29] Během trénování se síť snaží nejen co nejlépe popsat dostupná data (jako standardní AI), ale zároveň je nucena dodržovat tyto fyzikální principy – například zákony zachování energie a hybnosti, rovnice vedení tepla nebo difúze.[29]
- **Analogie:** Představte si studenta, který se učí řešit fyzikální úlohy. Student používající standardní AI vidí jen zadání a správný výsledek a snaží se najít vzorec, který je spojuje. Student používající PINNs vidí totéž, ale navíc musí u každého kroku svého výpočtu dokázat, že je v souladu s Newtonovými zákony. Tento druhý student bude schopen řešit nové, neznámé úlohy mnohem spolehlivěji, i když viděl méně tréninkových příkladů.
- **Dopad:** PINNs dokáží vytvářet vysoce přesné a robustní modely i s velmi malým množstvím experimentálních dat. Fyzikální zákony fungují jako silná "regularizace", která vede model ke správnému, fyzikálně smysluplnému řešení a zabraňuje mu "vymýšlet si" v oblastech, kde chybí data.[29] To je zásadní pro praktické nasazení AI v reálných experimentálních vědách.

Odemknutí Století Znalostí: Těžba Dat z Vědecké Literatury (NLP)

- **Problém "temných dat" ("Dark Data"):** Obrovské množství kolektivních lidských znalostí o materiálech je "uzamčeno" v nestrukturovaném formátu. Jsou to data obsažená v textu, tabulkách a obrázcích milionů vědeckých článků, patentů a technických zpráv.[33] Tato "temná data" jsou pro počítače v podstatě nečitelná a jejich potenciál zůstává nevyužit.[33]
- **Řešení pomocí NLP:** Modely pro zpracování přirozeného jazyka (Natural Language Processing, NLP), zejména moderní velké jazykové modely (LLMs), mají schopnost automaticky "číst" a sémanticky "rozumět" těmto dokumentům.[36] Dokáží identifikovat a extrahovat klíčové informace, jako jsou názvy materiálů, jejich vlastnosti, naměřené hodnoty nebo parametry syntézy, a převádět je do strukturovaných, strojově čitelných databází.[38]
- **Příklad:** Projekt ChatExtract demonstroval, že pomocí promyšleně navržených dotazů (prompt engineering) lze s využitím LLM extrahovat data o objemovém modulu pružnosti z plných textů vědeckých článků s přesností přes 90 % a s 96% úplností (recall).[40]
- **Dopad:** NLP transformuje celou vědeckou literaturu na jeden masivní, propojený a prohledávatelný tréninkový dataset. To umožní odhalit skryté souvislosti, trendy a

korelace, které jsou rozptýleny napříč desetiletími výzkumu v tisících různých publikací a které žádný lidský vědec nemůže sám nikdy objevit.

Holistický Pohled: Vzestup Multimodálních Modelů

- **Koncept:** Budoucnost AI v materiálových vědách nespočívá v modelech, které se specializují na jediný typ dat, ale v **multimodálních modelech**, které dokáží současně zpracovávat a integrovat informace z různých zdrojů a formátů (modalit).[41]
- **Příklad:** Představte si AI, která analyzuje vědecký článek o nové slitině. Tento model by současně: 1) četl a chápal text popisující experiment (NLP), 2) interpretoval data z grafu závislosti napětí na deformaci (počítačové vidění), 3) analyzoval snímek mikrostruktury z elektronového mikroskopu (analýza obrazu) a 4) rozuměl chemickému vzorci a krystalové struktuře (strukturální data).[43]
- **Dopad:** Spojením těchto různých datových proudů dosáhnou multimodální modely, jako je experimentální MatterChat, mnohem hlubšího, kontextuálnějšího a komplexnějšího "pochopení" materiálu.[44] To povede k výrazně přesnějším predikcím a schopnosti řešit složité vědecké problémy, které vyžadují syntézu informací z různých zdrojů.[28] Tyto systémy nebudou jen asistenty, ale skutečnými partnery ve vědeckém bádání. Tento holistický přístup odráží i změnu role samotného vědce – ten se stává spíše stratégem a kreativním ředitelem, který definuje cíle a interpretuje objevy svého týmu autonomních AI a robotických agentů.

Závěrečné shrnutí: Architekti Zítřka

Spojení materiálového inženýrství a umělé inteligence není pouhou evolucí, ale skutečnou revolucí. Jak jsme viděli, nejde o akademické cvičení s teoretickými přísliby, ale o soubor mocných nástrojů, které již dnes přinášejí hmatatelné výsledky a jsou klíčem k řešení největších světových výzev. Ať už jde o čistou energii, kde AI urychluje vývoj bezpečnějších a výkonnějších baterií a účinnějších katalyzátorů pro zelenou chemii, udržitelnou výrobu, která těží z nových, na míru navržených slitin, nebo medicínské technologie vyžadující pokročilé biokompatibilní materiály – ve všech těchto oblastech se AI stává nepostradatelným akcelerátorem pokroku.[4]

Pro současnou generaci studentů technických a přírodovědných oborů to znamená jedinečnou příležitost. Éra objevování materiálů metodou pokus-omyl, která definovala celé 20. století, definitivně končí. Budoucnost patří těm, kteří se naučí nejen rozumět fyzice a chemii hmoty, ale kteří dokáží také ovládat data, trénovat prediktivní a generativní modely a řídit autonomní experimentální systémy.

Dovednosti na pomezí materiálové vědy, datové vědy a umělé inteligence jsou vstupenkou do

předních linií vědeckého výzkumu a průmyslových inovací. Studenti, kteří si tyto kompetence osvojí, se nestanou jen inženýry. Stanou se architekty materiálové budoucnosti, kteří nebudou hmotu jen pasivně zkoumat, ale budou ji aktivně navrhovat a tvořit pro potřeby 21. století a daleko za ním. Budou to právě oni, kdo položí materiálové základy pro svět, který bude čistší, zdravější a technologicky vyspělejší.

Citovaná díla

1. FIG. 1. Materials discovery schematic. In the traditional approach, new... - ResearchGate, použito září 15, 2025, https://www.researchgate.net/figure/Materials-discovery-schematic-In-the-traditional-approach-new-materials-are-discovered_fig1_334457428
2. Data-Driven Materials Science: Status, Challenges, and Perspectives - PMC, použito září 15, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC6839624/
3. Material Informatics: Unlocking The Power Of Data In Materials Science - 20/15 Visioneers, použito září 15, 2025, https://www.20visioneers15.com/post/material-informatics
4. AI can transform innovation in materials design – here's how | World Economic Forum, použito září 15, 2025, https://www.weforum.org/stories/2025/06/ai-materials-innovation-discovery-to-design/
5. Artificial Intelligence-Powered Materials Science - PMC, použito září 15, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC11803041/
6. Scaling Materials Discovery with Self-Driving Labs | IFP - Institute for Progress, použito září 15, 2025, https://ifp.org/scaling-materials-discovery-with-self-driving-labs/
7. The four paradigms of science: empirical, theoretical, computational, and data-driven., použito září 15, 2025, https://www.researchgate.net/figure/The-four-paradigms-of-science-empirical-theoretical-computational-and-data-driven_fig1_301480892
8. Smart Materials, Smarter R&D: Materials Informatics in 2025 | IDTechEx Research Article, použito září 15, 2025, https://www.idtechex.com/en/research-article/smart-materials-smarter-r-d-materials-informatics-in-2025/33248
9. How Materials Informatics Platforms are Revolutionizing Materials Development and Optimization, použito září 15, 2025, https://www.materials.zone/blog/how-materials-informatics-platforms-are-revolutionizing-materials-development-and-optimization
10. Artificial Intelligence and Generative Models for Materials Discovery -- A Review - arXiv, použito září 15, 2025, https://arxiv.org/abs/2508.03278
11. AI for Discovery and Self-Driving Labs - The Matter Lab - University of Toronto, použito září 15, 2025, https://www.matter.toronto.edu/basic-content-page/ai-for-discovery-and-self-dr

iving-labs
12. Editorial: Machine Learning in Materials Science | Journal of Chemical Information and Modeling - ACS Publications, použito září 15, 2025, https://pubs.acs.org/doi/10.1021/acs.jcim.4c00727
13. AI Design for High Entropy Alloys: Progress, Challenges and Future ..., použito září 15, 2025, https://www.mdpi.com/2075-4701/15/9/1012
14. Full article: Alloys innovation through machine learning: a statistical literature review, použito září 15, 2025, https://www.tandfonline.com/doi/full/10.1080/27660400.2024.2326305
15. Automating alloy design and discovery with physics-aware multimodal multiagent AI - PNAS, použito září 15, 2025, https://www.pnas.org/doi/10.1073/pnas.2414074122
16. Researchers Develop AI Framework for Optimizing Battery Electrolytes - AZoM, použito září 15, 2025, https://www.azom.com/news.aspx?newsID=64530
17. A Big Data approach for battery electrolytes | Pritzker School of Molecular Engineering, použito září 15, 2025, https://pme.uchicago.edu/news/big-data-approach-battery-electrolytes
18. Building AI foundation models to accelerate the discovery of new ..., použito září 15, 2025, https://www.anl.gov/article/building-ai-foundation-models-to-accelerate-the-discovery-of-new-battery-materials
19. Scientists Use AI and X-ray Vision to Gain Insight into Battery Electrolyte | BNL Newsroom, použito září 15, 2025, https://www.bnl.gov/newsroom/news.php?a=122451
20. Stanford University Highlights New A.I.-Discovered Battery Electrolyte - Aionics, Inc., použito září 15, 2025, https://aionics.io/stanford-university-highlights-new-a-i-discovered-battery-electrolyte/
21. Catal-GPT: AI-driven directed efficient design framework for catalysts ..., použito září 15, 2025, https://academic.oup.com/nsr/advance-article/doi/10.1093/nsr/nwaf299/8212829
22. Heterogeneous catalyst design by generative models - OAE Publishing Inc., použito září 15, 2025, https://www.oaepublish.com/articles/jmi.2025.38
23. Designing catalysts with deep generative models and computational data. A case study for Suzuki cross coupling reactions - PMC, použito září 15, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC10259369/
24. Generative Pretrained Transformer for Heterogeneous Catalysts - PubMed, použito září 15, 2025, https://pubmed.ncbi.nlm.nih.gov/39576215/
25. Autonomous 'self-driving' laboratories: a review of technology and policy implications | Royal Society Open Science - Journals, použito září 15, 2025, https://royalsocietypublishing.org/doi/10.1098/rsos.250646
26. Self-Driving Laboratories for Chemistry and Materials Science - ChemRxiv, použito září 15, 2025, https://chemrxiv.org/engage/api-gateway/chemrxiv/assets/orp/resource/item/66708e2e5101a2ffa8cbd354/original/self-driving-laboratories-for-chemistry-and-mat

erials-science.pdf
27. Researchers Hit 'Fast Forward' on Materials Discovery with Self ..., použito září 15, 2025, https://news.ncsu.edu/2025/07/fast-forward-for-self-driving-labs/
28. Scientific AI in Materials Science: a Path to a Sustainable and Scalable Paradigm - PMC, použito září 15, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC7919383/
29. What Are Physics-Informed Neural Networks (PINNs)? - MATLAB ..., použito září 15, 2025, https://www.mathworks.com/discovery/physics-informed-neural-networks.html
30. Physics-informed neural networks - Wikipedia, použito září 15, 2025, https://en.wikipedia.org/wiki/Physics-informed_neural_networks
31. Physics-Informed Neural Networks in Polymers: A Review - MDPI, použito září 15, 2025, https://www.mdpi.com/2073-4360/17/8/1108
32. From PINNs to PIKANs: Recent Advances in Physics-Informed Machine Learning - arXiv, použito září 15, 2025, https://arxiv.org/html/2410.13228v1
33. Dark Data: Recovering the Lost Opportunities - DZone, použito září 15, 2025, https://dzone.com/articles/dark-data-recovering-lost-opportunities
34. Biomedical Informatics & Data Science - Yale School of Medicine, použito září 15, 2025, https://medicine.yale.edu/biomedical-informatics-data-science/news/newsletter/newsletter-issue/biomedical-informatics-and-data-science-10-04-2023/
35. Design of a Decision Making Model for Integrating Dark Data from Hybrid Sectors, použito září 15, 2025, https://thegrenze.com/pages/servej.php?fn=92.pdf&name=Design%20of%20a%20Decision%20Making%20Model%20for%20IntegratingDark%20Data%20from%20Hybrid%20Sectors&id=1097&association=GRENZE&journal=GIJET&year=2022&volume=8&issue=1
36. nlp for Knowledge Discovery and Information Extraction from Energetics Corpora - arXiv, použito září 15, 2025, https://arxiv.org/pdf/2402.06964
37. Natural Language Processing Techniques for Advancing Materials Discovery: A Short Review - ResearchGate, použito září 15, 2025, https://www.researchgate.net/publication/371361841_Natural_Language_Processing_Techniques_for_Advancing_Materials_Discovery_A_Short_Review
38. Extracting accurate materials data from research papers with conversational language models and prompt engineering - PMC, použito září 15, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC10882009/
39. Full article: Automatic extraction of materials and properties from superconductors scientific literature - Taylor & Francis Online, použito září 15, 2025, https://www.tandfonline.com/doi/full/10.1080/27660400.2022.2153633
40. Flexible, model-agnostic method for materials data extraction from text using general purpose language models - Digital Discovery (RSC Publishing) DOI:10.1039/D4DD00016A, použito září 15, 2025, https://pubs.rsc.org/en/content/articlehtml/2024/dd/d4dd00016a
41. MM4Mat - Google Sites, použito září 15, 2025, https://sites.google.com/view/mm4mat
42. What is Multimodal AI? | IBM, použito září 15, 2025,

https://www.ibm.com/think/topics/multimodal-ai
43. AI Models in Materials Science: Where They Succeed and Where They Fall Short, použito září 15, 2025, https://completeaitraining.com/news/ai-models-in-materials-science-where-they-succeed-and-where/
44. arxiv.org, použito září 15, 2025, https://arxiv.org/abs/2502.13107