AI v materiálovém inženýrství: Přednáška 2 – Od materiálu k datům

Kapitola 1: Úvod a rekapitulace

Vítejte zpět v kurzu "AI v materiálovém inženýrství". V minulé, úvodní přednášce jsme se nechali inspirovat dechberoucími možnostmi, které umělá inteligence přináší do našeho oboru. Viděli jsme, jak dokáže procházet astronomickým kombinačním prostorem a objevovat nové superslitiny s vysokou entropií (HEAs) – úkol, který by byl pro tradiční experimentální přístup naprosto nemyslitelný.[1] Dotkli jsme se konceptu autonomních laboratoří, kde AI nejen analyzuje data, ale aktivně a inteligentně řídí další experiment, čímž dramaticky zrychluje cyklus objevování.[4]

To vše vyvolává jednu zásadní, praktickou otázku, která je jádrem dnešní přednášky. Jak ale algoritmus, který je ve své podstatě jen souborem matematických operací, "porozumí", co je to ocel, keramika nebo polymer? Jak převedeme fyzikální realitu, se vší její komplexností – od atomárního uspořádání přes krystalovou strukturu až po mikrostrukturu – do jazyka, kterému stroje rozumí, tedy do jazyka čísel?

Dnes si postavíme most mezi materiálovým světem a světem umělé inteligence. Projdeme si celý proces krok za krokem, abychom demystifikovali, jak se z reálného materiálu stane vstup pro algoritmus. Struktura dnešní přednášky je následující:

1. Nejprve se podíváme na **zdroje dat** – kde se bere palivo pro naše AI modely. Zjistíme, odkud pochází informace, které AI využívá.
2. Poté se ponoříme do nejdůležitějšího konceptu dneška: **featurizace**, neboli "překladu" materiálů do číselných vektorů. Toto je klíčový krok, který umožňuje strojům "vidět" materiály.
3. Následně si představíme základní **paradigmata učení**. Zjistíme, jaké typy problémů s těmito daty můžeme řešit a jaké otázky můžeme AI pokládat.
4. Řekneme si, jak se vypořádat s častým problémem reálného výzkumu – **nedostatkem dat**. Představíme si chytré strategie, jak pracovat efektivně i s omezenými zdroji.
5. Nakonec vše shrneme a připravíme se na příští lekci, kde tyto připravené data konečně použijeme k trénování prvních prediktivních modelů.

Cílem dnešní přednášky je, abyste na jejím konci dokonale chápali, jak se z fyzického materiálu stane strukturovaný, numerický vstup pro strojové učení. Tento fundamentální princip je naprosto nezbytný pro pochopení všeho, co bude následovat.

Kapitola 2: Palivo pro AI – Zdroje materiálových dat

Každý model strojového učení, bez ohledu na jeho složitost, je jen tak dobrý, jak dobrá jsou data, na kterých byl natrénován. Data jsou základním palivem, které pohání motor umělé inteligence. V materiálových vědách máme to štěstí, že existuje bohatý a rozmanitý ekosystém zdrojů dat, z nichž každý má své silné a slabé stránky. Pojďme se podívat na ty nejdůležitější.

2.1 Veřejné databáze: Digitální knihovny materiálů

Představte si obrovské, digitálně dostupné encyklopedie, které neobsahují text a obrázky, ale strukturované informace o vlastnostech milionů materiálů. To jsou veřejné materiálové databáze, které se staly páteří moderní materiálové informatiky.

- **Materials Project (MP):** Jedná se o jeden z nejvýznamnějších a nejrozsáhlejších zdrojů v našem oboru.[5] Materials Project je otevřená databáze, která obsahuje především výpočetně získané vlastnosti pro více než 130 000 anorganických sloučenin a přes půl milionu molekul.[6] Data jsou generována pomocí vysokokapacitních výpočtů založených na Teorii funkcionálu hustoty (DFT), které běží na superpočítačích.[5] Pro každý materiál zde naleznete klíčové vlastnosti, jako je entalpie vzniku, krystalová struktura, zakázaný pás (band gap), elastické tenzory a mnoho dalších.[5] Zásadní je, že databáze je volně přístupná a nabízí výkonné API (Application Programming Interface), které umožňuje programově stahovat data a provádět sofistikované analýzy, například pomocí Python knihovny MPRester.[6]

- **Open Quantum Materials Database (OQMD):** Další klíčová databáze, která se zaměřuje na termodynamické vlastnosti materiálů vypočtené pomocí DFT.[9] OQMD obsahuje data pro více než 1,3 milionu struktur a je zvláště cenná pro predikci termodynamické stability.[11] Umožňuje vědcům rychle ověřit, zda je hypotetická sloučenina pravděpodobně syntetizovatelná, a to na základě její formační energie ve srovnání s ostatními známými fázemi v daném chemickém systému.

- **Citrine Informatics (Citrine):** Zatímco MP a OQMD jsou primárně akademické projekty, Citrine představuje komerční platformu, která ukazuje průmyslovou hodnotu kurátorovaných dat.[12] Citrine nabízí AI platformu pro vývoj materiálů a chemikálií, která nejen agreguje veřejná data, ale především umožňuje firmám strukturovat a využívat jejich vlastní, často chaotická interní data – od tabulek v Excelu přes laboratorní deníky až po staré reporty.[13]

2.2 Výpočetní simulace: Virtuální laboratoře

Veřejné databáze jsou z velké části naplněny daty z výpočetních simulací. Tyto simulace fungují jako "virtuální laboratoře", kde můžeme generovat data na vyžádání, zejména pro materiály nebo podmínky, které jsou experimentálně obtížně dosažitelné nebo příliš drahé.

- **Teorie funkcionálu hustoty (Density Functional Theory, DFT):** DFT je kvantově-mechanická metoda, která umožňuje vypočítat elektronovou strukturu a z ní odvozené vlastnosti materiálů z prvních principů (*ab initio*), tedy bez potřeby jakýchkoli experimentálních vstupů.[15] Je to nesmírně silný nástroj, protože nám dovoluje predikovat vlastnosti, jako jsou zakázané pásy nebo formační energie, pro zcela nové, hypotetické materiály, které ještě nikdy nebyly syntetizovány.[17] Tímto způsobem můžeme virtuálně "prosíťovat" tisíce kandidátních materiálů a vybrat jen ty nejslibnější pro reálnou experimentální syntézu, což dramaticky šetří čas a zdroje.[17]

- **Metoda konečných prvků (Finite Element Method, FEM):** Zatímco DFT operuje na atomární úrovni, FEM je výpočetní technika pro řešení parciálních diferenciálních rovnic na komplexních geometriích a je ideální pro simulace na úrovni kontinua.[19] V materiálových vědách se FEM používá k predikci makroskopického mechanického chování, jako jsou napětí, deformace, únava materiálu nebo šíření trhlin v součástkách.[21] FEM tak tvoří most mezi fundamentálními vlastnostmi materiálu (získanými např. z DFT) a jeho reálným inženýrským výkonem.

2.3 Vysokokapacitní experimenty (HTE): Automatizované skutečné laboratoře

Vysokokapacitní experimentování (High-Throughput Experimentation, HTE) je fyzickým protějškem vysokokapacitních výpočtů. Cílem je akcelerovat *reálné* experimenty pomocí automatizace, miniaturizace a paralelizace.[23] Místo tradičního přístupu "jeden experiment za druhým" umožňuje HTE provádět stovky či tisíce experimentů současně.[23] Typickým příkladem je příprava tenkovrstvých knihoven, kde se na jediném substrátu vytvoří stovky oblastí s mírně odlišným chemickým složením, které jsou následně automaticky charakterizovány. HTE tak v krátkém čase generuje velké, strukturované a vysoce kvalitní experimentální datasety, které jsou neocenitelné pro trénování modelů strojového učení na datech z reálného světa a pro validaci výpočetních predikcí.[26]

2.4 Vědecká literatura: Těžba "temných dat" pomocí NLP

Jak jsme zmínili v minulé přednášce, obrovské množství znalostí je uzamčeno v nestrukturované podobě v desítkách let vědeckých článků, patentů a technických zpráv – to

jsou tzv. "temná data".[28] Zpracování přirozeného jazyka (Natural Language Processing, NLP), zejména moderní velké jazykové modely (LLMs), nám dávají nástroje, jak tato data "vytěžit".[29] Specializované modely, trénované na vědeckých textech, dokáží "číst" a porozumět článkům a automaticky z nich extrahovat strukturované informace.[28] Mohou například identifikovat syntézní postupy ("materiál X byl žíhán při teplotě 800 °C po dobu 2 hodin"), extrahovat naměřené hodnoty vlastností a nalézt vztahy mezi nimi. Tímto způsobem se daří přeměnit desítky let starou literaturu na strojově čitelnou a prohledávatelnou databázi, která doplňuje mezery v našich znalostech.

Tyto čtyři zdroje dat netvoří oddělené ostrovy, ale hluboce propojený ekosystém. Každá složka kompenzuje slabiny ostatních. DFT simulace jsou relativně levné a mohou generovat obrovské množství dat pro hypotetické materiály, čímž plní velké databáze jako Materials Project. Tato data jsou však pro ideální krystaly při teplotě 0 K a mohou obsahovat systematické chyby. Experimentální data, ať už z HTE nebo tradičních laboratoří, představují "skutečnou pravdu", ale jsou drahá a je jich málo. Moderní přístup v materiálové informatice nespočívá ve výběru jednoho zdroje, ale v jejich inteligentní kombinaci. Využíváme levná a hojná výpočetní data k prozkoumání obrovských prostorů a k vytvoření obecných modelů. Tyto modely pak "ukotvíme" v realitě pomocí malého množství přesných experimentálních dat, z nichž některá jsou nově generována (HTE) a jiná získána z minulosti (NLP). Tento multi-fidelitní přístup, kombinující data různé kvality a ceny, je klíčem k praktickému úspěchu.

Kapitola 3: Klíčový krok – Featurizace a deskriptory

Nyní, když víme, odkud brát data, stojíme před nejdůležitějším krokem celého procesu. Tento krok je absolutním jádrem dnešní přednášky a klíčem k pochopení, jak AI v našem oboru funguje.

3.1 Jádro problému: Překlad z jazyka chemie do jazyka matematiky

Musíme si jednoznačně uvědomit, že model strojového učení, ať už je to neuronová síť nebo rozhodovací strom, nerozumí konceptu "nerezová ocel" ani chemickému vzorci "FeCrNi". Rozumí pouze a výhradně vektorům čísel. Algoritmus nevidí periodickou tabulku ani krystalovou mřížku. Vidí pouze matici čísel. Celý proces aplikace AI na materiály tedy stojí a padá s naší schopností přeložit komplexní fyzikální a chemickou realitu materiálu do tohoto numerického jazyka.

Tento "překlad" definujeme pomocí dvou klíčových pojmů:

- **Featurizace (Featurization):** Je to *proces* převodu reprezentace materiálu (např. jeho chemického vzorce, souboru s krystalovou strukturou) na numerický vektor pevné délky.

Je to samotný akt překladu.[14]

- **Deskriptory/Příznaky (Descriptors/Features):** Jsou to *výsledky* featurizace. Jsou to jednotlivé číselné hodnoty uvnitř vektoru, které kvantifikují specifické aspekty materiálu. Dobrá sada deskriptorů tvoří pro každý materiál jedinečný "digitální otisk prstu".[31]

Volba správných deskriptorů není jen technický úkol; je to primární mechanismus, kterým materiálový vědec vkládá své expertní znalosti a fyzikální intuici do modelu. Algoritmus je sám o sobě "naivní" vůči fyzice. Vidí jen korelace v číslech. Teprve výběrem deskriptorů mu říkáme, kterých fyzikálních charakteristik si má všímat. Pokud chceme predikovat tvrdost oceli, víme, že závisí na mikrostruktuře. Proto zvolíme deskriptory odvozené z SEM snímků, a tím model explicitně instruujeme: "Odpověď na problém leží v těchto charakteristikách, zaměř se na ně." Úspěšný model tedy nejen potvrzuje kvalitu algoritmu, ale i správnost naší původní fyzikální hypotézy zakódované ve výběru deskriptorů.

3.2 Typy deskriptorů s konkrétními příklady

Deskriptory můžeme rozdělit do několika kategorií podle toho, z jaké úrovně popisu materiálu vycházejí.

Kompoziční deskriptory

Tyto deskriptory jsou odvozeny *pouze* z chemického vzorce materiálu (např. Fe_2O_3). Jsou nejjednodušší na výpočet, ale zároveň nesou nejméně informací.

- **Příklady:**
  - **Jednoduché zlomky:** Vektor reprezentující atomární procento každého prvku. Pro Fe_2O_3 by to byl vektor s hodnotami pro Fe (40%) a O (60%).
  - **Stechiometrické atributy:** Počet prvků ve sloučenině, poměry mezi prvky atd..[32]
  - **Vážené průměry vlastností prvků:** Vypočítáme průměrnou atomovou hmotnost, průměrnou elektronegativitu, průměrný počet valenčních elektronů atd., kde je každý prvek vážen svým atomárním zlomkem ve sloučenině.[33]

- **Omezení:** Hlavní slabinou kompozičních deskriptorů je, že zcela ignorují prostorové uspořádání atomů. Nedokáží tedy rozlišit mezi polymorfy – materiály se stejným chemickým složením, ale odlišnou krystalovou strukturou a dramaticky odlišnými vlastnostmi, jako jsou například diamant a grafit (oba jsou čistý uhlík, C).[34]

Strukturální deskriptory

Tyto deskriptory jsou odvozeny z trojrozměrného uspořádání atomů, typicky ze souboru ve formátu CIF (Crystallographic Information File), který je standardním výstupem například z

rentgenové difrakce.

- **Příklady:**
  - **Informace o mřížce:** Mřížkové parametry (a,b,c,α,β,γ), objem základní buňky.[11]
  - **Informace o symetrii:** Číslo prostorové grupy, krystalová soustava.
  - **Hustota a uspořádání:** Hustota materiálu, koeficient zaplnění prostoru (packing fraction).
  - **Deskriptory lokálního prostředí:** Radiální distribuční funkce (RDF), která popisuje pravděpodobnost nalezení atomu v určité vzdálenosti od jiného, referenčního atomu. Pokročilejší a velmi silnou metodou je SOAP (Smooth Overlap of Atomic Positions), která poskytuje detailní "otisk" lokálního chemického prostředí kolem každého atomu.[35]

- **Výhoda:** Protože kódují geometrii krystalové struktury, dokáží bez problému rozlišit mezi polymorfy.

Mikrostrukturální deskriptory

Tyto deskriptory jdou o úroveň výše a jsou odvozeny z obrazových dat, nejčastěji ze snímků ze skenovacího (SEM) nebo transmisního (TEM) elektronového mikroskopu. Kvantifikují charakteristiky materiálu na škále větší než je jednotlivá krystalová buňka, což je často klíčové pro mechanické a jiné makroskopické vlastnosti.

- **Příklady:**
  - **Vlastnosti zrn:** Průměrná velikost zrna, distribuce velikostí zrn, hustota hranic zrn.[36]
  - **Vlastnosti fází:** Objemový podíl jednotlivých fází (např. podíl feritu a perlitu v oceli), jejich tvar a distribuce.[37]
  - **Vlastnosti defektů:** Porozita, hustota dislokací, hustota a orientace trhlin. Tyto charakteristiky se extrahují z obrazů pomocí pokročilých technik počítačového vidění a analýzy obrazu.[38]

Následující tabulka shrnuje tyto koncepty.

Typ deskriptoru	Zdrojová informace	Příklad deskriptoru	Příklad otázky, na kterou odpovídá
Kompoziční	Chemický vzorec (Fe_2O_3)	Průměrná elektronegativita	"Jaká je celková 'touha' tohoto materiálu přitahovat elektrony, bez ohledu na

			strukturu?"
Strukturální	Krystalová struktura (CIF soubor)	Mřížkový parametr 'a'	"Jak 'roztažená' je základní buňka krystalu v jednom směru?"
Strukturální	Krystalová struktura (CIF soubor)	Radiální distribuční funkce g(r)	"Jaká je pravděpodobnost nalezení sousedního atomu v určité vzdálenosti od referenčního atomu?"
Mikrostrukturální	SEM snímek	Průměrná velikost zrna	"Z jak velkých krystalických domén se v průměru skládá tento polykrystalický materiál?"

3.3 Nástroje v Pythonu: Ekosystém materiálové informatiky

Tento komplexní proces featurizace se naštěstí nedělá od nuly. V programovacím jazyce Python, který je de facto standardem pro datovou vědu, existuje silný ekosystém open-source knihoven navržených speciálně pro materiálovou informatiku.

- **Pymatgen (Python Materials Genomics):** Toto je základní knihovna pro *reprezentaci* materiálů jako Python objektů.[8] Dokáže načítat a zapisovat desítky různých formátů souborů (CIF, VASP vstupy atd.) a vytvářet z nich bohaté objekty Structure nebo Molecule, které obsahují veškeré informace o atomech, jejich pozicích a mřížce.[40] Pymatgen je tak silný, že je motorem, který pohání celou databázi Materials Project.[8]

- **Matminer (Materials Data Mining):** Toto je knihovna pro samotnou *featurizaci*.[41] Vezme objekty vytvořené Pymatgenem jako vstup a nabízí obrovskou sbírku předpřipravených funkcí pro výpočet stovek různých deskriptorů (kompozičních, strukturálních atd.).

Výsledky pak elegantně uspořádá do tabulkové datové struktury.[42]

Tyto specializované knihovny zapadají do širšího ekosystému nástrojů pro datovou vědu:

- **NumPy:** Poskytuje základní datovou strukturu pro numerická pole a matice.
- **Pandas:** Výstupem z Matmineru je typicky DataFrame z knihovny Pandas – standardní nástroj pro práci s tabulkovými daty v Pythonu. Je to v podstatě inteligentní tabulka, kde řádky odpovídají jednotlivým materiálům a sloupce jejich deskriptorům (a cílové vlastnosti).
- **Scikit-learn:** Je to hlavní knihovna pro klasické algoritmy strojového učení v Pythonu. Jako vstup bere právě DataFrame z Pandas a umožňuje na něm trénovat prediktivní modely.

Představte si celý proces jako výrobní linku: Soubor s krystalovou strukturou (CIF) → Pymatgen ho načte a vytvoří digitální objekt → Matminer tento objekt vezme a vypočítá z něj 100 různých deskriptorů → Pandas je uspořádá do přehledné tabulky → Scikit-learn tuto tabulku použije k natrénování prediktivního modelu.

Kapitola 4: Paradigmata učení – Jaký typ problému řešíme?

Nyní, když máme data ve správném formátu – tedy jako tabulku, kde řádky jsou materiály a sloupce jsou jejich deskriptory – musíme se rozhodnout, jaký typ otázky chceme umělé inteligenci položit. V závislosti na otázce a povaze našich dat použijeme jiný "způsob učení" neboli paradigma. Tyto paradigmata jsou přímými výpočetními analogy základních módů vědeckého bádání: predikce, explorace a optimalizace.

4.1 Učení s učitelem (Supervised Learning)

- **Analogie:** "Učení se s klíčem ke správným odpovědím."

- **Mechanismus:** V tomto paradigmatu máme k dispozici vstupní data **X** (matici deskriptorů pro naše materiály) a k nim odpovídající, známé výstupní hodnoty **y** (cílovou vlastnost, kterou chceme predikovat). Cílem algoritmu je naučit se mapovací funkci f takovou, že y=f(X). Algoritmus se učí na příkladech, kde zná správnou odpověď, a snaží se zobecnit tento vztah i na nové, dosud neviděné příklady.

- **Příklad z materiálových věd:** Máme databázi 1000 ocelí. Pro každou ocel známe její chemické složení a parametry tepelného zpracování (to jsou naše vstupní data **X**, převedená na deskriptory) a také její experimentálně změřenou mez pevnosti (to je naše cílová hodnota **y**). Úkolem je natrénovat model, který se naučí vztah mezi nimi a dokáže

pro novou, neviděnou ocel predikovat její mez pevnosti jen na základě jejího složení a zpracování.[43] Toto je zdaleka nejběžnější paradigma pro predikci vlastností materiálů.

4.2 Učení bez učitele (Unsupervised Learning)

- **Analogie:** "Třídění neznámých kartiček na hromádky podle podobnosti."
- **Mechanismus:** Zde máme k dispozici pouze vstupní data **X** (deskriptory), ale neznáme žádné správné odpovědi **y**. Cílem není predikovat konkrétní hodnotu, ale najít skryté vzory, struktury nebo shluky (klastry) v samotných datech.[45] Algoritmus se snaží data uspořádat na základě jejich vnitřní podobnosti.
- **Příklad z materiálových věd:** Máme obrovskou databázi z Materials Project s deskriptory pro 100 000 materiálů, ale nevíme, jak je smysluplně roztřídit. Algoritmus pro shlukování (clustering) může v tomto vícerozměrném "prostoru materiálů" najít přirozené skupiny.[47] Možná objeví, že materiály se shlukují do skupin, které odpovídají známým krystalovým strukturám (např. perovskity, wurtzity), nebo možná najde úplně novou, dosud nepopsanou "rodinu" materiálů se zajímavými společnými vlastnostmi, což může vést k novým vědeckým hypotézám.[48] Je to mocný nástroj pro objevování a exploraci dat.

4.3 Posilované učení (Reinforcement Learning)

- **Analogie:** "Učení metodou pokus-omyl s odměnami a tresty, jako při učení psa novým povelům."
- **Mechanismus:** Toto paradigma se liší od předchozích dvou. Nejde o učení ze statického datasetu, ale o učení se optimální strategii prostřednictvím interakce s prostředím. "Agent" provádí "akce" v "prostředí", což mění "stav" prostředí, a za to dostává "odměnu" nebo "trest". Cílem agenta je naučit se takovou sekvenci akcí (politiku), která maximalizuje celkovou kumulativní odměnu.[49]
- **Příklad z materiálových věd:** Posilované učení se méně používá pro přímou predikci vlastností, ale je nesmírně silné pro optimalizaci procesů. Představte si AI, která řídí syntézu tenké vrstvy v CVD reaktoru.[50] "Stav" je aktuální teplota, tlak a koncentrace plynů. "Akce" jsou například "zvýšit teplotu o 5 °C" nebo "přidat prekurzor". "Odměna" je vysoká, pokud výsledný materiál má vysokou krystalinitu a málo defektů, a "trest" (negativní odměna), pokud je amorfní. Postupným zkoušením tisíců virtuálních (nebo reálných, v autonomní laboratoři) syntéz se agent naučí optimální časový profil všech parametrů pro syntézu dokonalého materiálu, což může být strategie, na kterou by člověk nikdy nepřišel.[51]

Kapitola 5: Realita malých dat a chytré strategie

Zatímco databáze jako Materials Project obsahují statisíce datových bodů, realita každodenního výzkumu je často odlišná. V typickém R&D projektu nebo během doktorského studia je generování i několika desítek vysoce kvalitních experimentálních datových bodů časově i finančně náročné. Co dělat, když potřebujeme predikovat vlastnost, kterou nelze spolehlivě spočítat, a každý experiment trvá týden a stojí tisíce korun? Naštěstí existují chytré strategie, jak se s tímto problémem "malých dat" vypořádat. Tyto strategie se dělí do dvou hlavních filozofií: efektivnější získávání nových dat a lepší využití již existujících, byť ne zcela ideálních dat.

5.1 Aktivní učení (Active Learning): AI jako chytrý experimentátor

Aktivní učení je ztělesněním první filozofie: maximalizace informační hodnoty každého nového experimentu. Místo náhodného prohledávání prostoru nebo spoléhání se na intuici necháme model, aby sám aktivně řídil experimentální kampaň.

- **Přímé navázání na HEAs:** Vraťme se k našemu příkladu s vysokou entropií slitin z první přednášky. Prohledat celý kombinační prostor je nemožné. Aktivní učení nabízí elegantní řešení.[3]

- **Uzavřená smyčka (Closed Loop):** Proces funguje v iterativní smyčce, která dramaticky snižuje počet potřebných experimentů [1]:
  1. **Start s málem:** Natrénujeme počáteční model na několika málo dostupných datech (např. 10-20 slitinách). Tento model bude samozřejmě velmi nepřesný.
  2. **Inteligentní dotaz:** Model analyzuje své vlastní predikce a nejistoty. Sám si položí otázku: "Který další experiment mi přinese nejvíce nových informací a nejrychleji mě posune k cíli (např. k nalezení slitiny s maximální tvrdostí)?" Algoritmus vybere bod v neprozkoumaném prostoru, kde je jeho nejistota největší, nebo kde očekává největší zlepšení vlastnosti.
  3. **Cílený experiment:** Laboratoř provede pouze tento jeden, nejinformativnější experiment, který model navrhl.
  4. **Rozšíření a opakování:** Nově získaný datový bod se přidá do trénovací sady, model se přetrénuje a celý cyklus se opakuje. S každým krokem se model zpřesňuje a jeho další návrhy jsou stále chytřejší a cílenější.[4]

Tento přístup přeměňuje AI z pasivního analyzátoru dat na aktivního partnera ve výzkumném procesu, který inteligentně naviguje experimentátora skrze obrovský designový prostor.

5.2 Další strategie: Učení se z příbuzných úloh

Druhá filozofie se zaměřuje na opětovné využití znalostí. Pokud nemáme dostatek dat pro náš specifický problém, můžeme využít znalosti získané z řešení jiného, ale příbuzného problému, pro který máme dat mnohem více.

- **Transferové učení (Transfer Learning):**
  - **Koncept:** Představte si to jako "dát modelu náskok".[55] Místo toho, aby se model učil vše od nuly na našem malém datasetu, vezmeme model, který už byl předtrénován na obrovském množství dat z příbuzné úlohy (tzv. *zdrojová úloha*), a pouze ho "doladíme" na naší specifické *cílové úloze*.[57]
  - **Příklad Sim2Real (Simulation-to-Real):** Toto je klíčová aplikace v materiálových vědách.[58]
    1. **Zdrojová úloha:** Natrénujeme velkou neuronovou síť na predikci zakázaného pásu s použitím 100 000 výpočetních DFT dat z Materials Project. Během tohoto tréninku se model naučí obecné, fundamentální vztahy mezi krystalovou strukturou a elektronickými vlastnostmi – v podstatě se naučí kus fyziky pevných látek.
    2. **Cílová úloha:** Chceme predikovat experimentálně změřený zakázaný pás pro novou třídu materiálů, pro kterou máme jen 20 reálných měření.
    3. **Přenos znalostí:** Vezmeme předtrénovaný model, "zmrazíme" váhy v jeho prvních vrstvách (které se naučily obecnou fyziku) a přetrénujeme pouze poslední, specializované vrstvy na našich 20 experimentálních bodech. Model se tak nemusí učit základy od nuly a dosáhne mnohem vyšší přesnosti, než kdyby se trénoval jen na malém datasetu. Efektivně tak využíváme levná výpočetní data k vybudování základu, který pak kalibrujeme pomocí drahých experimentálních dat.[60]
- **Adaptace domény (Domain Adaptation):** Krátce zmíníme, že existuje i příbuzná technika zvaná adaptace domény, která se používá v situacích, kdy se sice řeší stejná úloha (např. predikce téže vlastnosti), ale distribuce dat (deskriptorů) mezi zdrojovým a cílovým datasetem se liší (např. výpočetní vs. experimentální data).[61] Těmto pokročilejším technikám se budeme věnovat v pozdějších přednáškách.

Nejvýkonnější strategie často kombinují oba přístupy. Mohou začít s modelem založeným na transferovém učení, který poskytne silnou výchozí pozici, a následně použít aktivní učení k efektivnímu sběru nových experimentálních dat pro jeho další zpřesnění. Tato dualita – opětovné využití starých znalostí a inteligentní získávání nových – je nejefektivnějším řešením problému malých dat v materiálových vědách.

Kapitola 6: Závěr

Dnes jsme společně urazili klíčovou cestu od abstraktního konceptu materiálu k jeho konkrétní, strojově čitelné reprezentaci. Postavili jsme most, po kterém budeme v následujících týdnech přecházet.

Shrnutí klíčových poznatků

Pojďme si zrekapitulovat to nejdůležitější. Viděli jsme, že cesta od reálného materiálu k predikci pomocí AI má dva naprosto zásadní, nepřeskočitelné kroky.

Prvním je získání kvalitních dat. Zjistili jsme, že existuje bohatý ekosystém zdrojů, které se vzájemně doplňují: obrovské veřejné databáze plněné daty z výpočetních simulací, automatizované vysokokapacitní experimenty generující reálná data a nástroje NLP, které těží znalosti ze starší vědecké literatury.

Druhým, a pro dnešek nejdůležitějším, je chytrá **featurizace**. Je to proces, kterým materiálu přiřadíme jeho jedinečný digitální otisk prstu – vektor deskriptorů. Naučili jsme se rozlišovat mezi kompozičními, strukturálními a mikrostrukturálními deskriptory a pochopili jsme, že volba těch správných je aktem, kterým do modelu vkládáme naši expertní doménovou znalost. Bez dobrých deskriptorů, které v sobě nesou relevantní fyzikální a chemickou informaci, nemůže žádný AI model fungovat.

Citovaná díla

1. Machine learning-enabled high-entropy alloy discovery, použito září 21, 2025, https://realworldml.github.io/files/cr/paper43.pdf
2. Machine Learning Advances in High-Entropy Alloys: A Mini-Review - MDPI, použito září 21, 2025, https://www.mdpi.com/1099-4300/26/12/1119
3. Machine learning–enabled high-entropy alloy discovery - TU Delft Research Portal, použito září 21, 2025, https://research.tudelft.nl/files/134177341/science.abo4940.pdf
4. Accelerated High-Entropy Alloys Discovery for Electrocatalysis via Robotic-Aided Active Learning - Ju Li Group, použito září 21, 2025, http://li.mit.edu/S/ZhichuRen/Upload/37_accelerated_high_entropy_alloy.pdf
5. Materials Project - Wikipedia, použito září 21, 2025, https://en.wikipedia.org/wiki/Materials_Project
6. Materials Project, použito září 21, 2025, https://next-gen.materialsproject.org/
7. Materials Project - GitHub, použito září 21, 2025, https://github.com/materialsproject
8. Open Source Software - Materials Project, použito září 21, 2025,

https://next-gen.materialsproject.org/about/open-source-software
9. (PDF) The Open Quantum Materials Database (OQMD): Assessing the accuracy of DFT formation energies - ResearchGate, použito září 21, 2025, https://www.researchgate.net/publication/286490327_The_Open_Quantum_Materials_Database_OQMD_Assessing_the_accuracy_of_DFT_formation_energies
10. The Open Quantum Materials Database (OQMD): Assessing the accuracy of DFT formation energies - Northwestern Scholars, použito září 21, 2025, https://www.scholars.northwestern.edu/en/publications/the-open-quantum-materials-database-oqmd-assessing-the-accuracy-o-2
11. The Open Quantum Materials Database (OQMD): OPTIMADE ..., použito září 21, 2025, https://www.optimade.org/providers-dashboard/providers/oqmd.html
12. Company - Citrine Informatics, použito září 21, 2025, https://citrine.io/company/
13. Citrine Platform Overview: The AI Platform for Materials & Chemicals, použito září 21, 2025, https://citrine.io/platform/
14. Citrine DataManager, použito září 21, 2025, https://citrine.io/platform/citrine-datamanager/
15. Density functional theory across chemistry, physics and biology - PMC - PubMed Central, použito září 21, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC3928866/
16. Density functional theory - Wikipedia, použito září 21, 2025, https://en.wikipedia.org/wiki/Density_functional_theory
17. What is Density Functional Theory and How Does It Work? | Synopsys, použito září 21, 2025, https://www.synopsys.com/glossary/what-is-density-functional-theory.html
18. Basics of the density functional theory - AIMS Press, použito září 21, 2025, https://www.aimspress.com/article/doi/10.3934/matersci.2017.6.1372
19. What is Finite Element Analysis (FEA)? | Ansys, použito září 21, 2025, https://www.ansys.com/simulation-topics/what-is-finite-element-analysis
20. Finite element method - Wikipedia, použito září 21, 2025, https://en.wikipedia.org/wiki/Finite_element_method
21. How FEA is Revolutionizing Material Science - Decos HealthTech, použito září 21, 2025, https://healthtech.decos.com/en/resources/blog/how-fea-revolutionizing-material-science
22. EN175: Mechanics of Solids - Intro to FEA, použito září 21, 2025, https://www.brown.edu/Departments/Engineering/Courses/En1750/Notes/FEA_Intro/FEA_Intro.htm
23. Practical High-Throughput Experimentation for Chemists - PMC, použito září 21, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC5467193/
24. High Throughput Research Accelerating Materials Discovery Design Development and Deployment | National Academies, použito září 21, 2025, https://www.nationalacademies.org/event/11-09-2020/high-throughput-research-accelerating-materials-discovery-design-development-and-deployment
25. Practical High-Throughput Experimentation for Chemists - PMC, použito září 21, 2025, https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5467193/
26. High-Throughput Experimentation in Materials Science: A Review - YouTube,

použito září 21, 2025, https://www.youtube.com/watch?v=ue1oLnQvK7I
27. Early Years of High-Throughput Experimentation and Combinatorial Approaches in Catalysis and Materials Science - ACS Publications, použito září 21, 2025, https://pubs.acs.org/doi/10.1021/acscombsci.8b00189
28. MatSci-NLP: Evaluating Scientific Language ... - ACL Anthology, použito září 21, 2025, https://aclanthology.org/2023.acl-long.201.pdf
29. Revolutionizing Materials Science with NLP: Introducing MatSci-NLP and HoneyBee | Mila, použito září 21, 2025, https://mila.quebec/en/article/revolutionizing-materials-science-with-nlp-introducing-matsci-nlp-and-honeybee
30. Full article: Mining experimental data from materials science literature with large language models: an evaluation study - Taylor & Francis Online, použito září 21, 2025, https://www.tandfonline.com/doi/full/10.1080/27660400.2024.2356506
31. A Survey of Quantitative Descriptions of Molecular Structure - PMC, použito září 21, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC3809149/
32. COMPOSITIONAL AND ELEMENTAL DESCRIPTORS FOR PEROVSKITE MATERIALS - OpenReview, použito září 21, 2025, https://openreview.net/pdf/a17f3142dac918aa5cd0538821df2d265c4b24d7.pdf
33. Machine learning descriptors in materials chemistry: prediction and experimental validation synthesis of novel intermetallic UCd - ChemRxiv, použito září 21, 2025, https://chemrxiv.org/engage/api-gateway/chemrxiv/assets/orp/resource/item/63b23bbd16e9a864303c5bf0/original/machine-learning-descriptors-in-materials-chemistry-prediction-and-experimental-validation-synthesis-of-novel-intermetallic-u-cd3.pdf
34. Compositional Representation of Polymorphic Crystalline Materials - arXiv, použito září 21, 2025, https://arxiv.org/html/2312.13289v2
35. Representing crystal structures: descriptors - ai4materials's documentation!, použito září 21, 2025, https://ai4materials.readthedocs.io/en/latest/ai4materials.descriptors.html
36. Microstructure - CES Information Guide - Materials Science Engineering, použito září 21, 2025, https://depts.washington.edu/matseed/ces_guide/microstructure.htm
37. The correlation between statistical descriptors of heterogeneous materials - Swansea University, použito září 21, 2025, https://engweb.swan.ac.uk/~cfli/papers_pdf_files/2021_CMAME_The_correlation_between_statistical_descriptors_of_heterogeneous_materials.pdf
38. Project - Microstructure representation learning - cucis - Northwestern University, použito září 21, 2025, http://cucis.ece.northwestern.edu/projects/MURI/workrep.html
39. Correlation Analysis of Statistical Microstructure Descriptors with Micromechanical Responses of Particulate Composite Materials, použito září 21, 2025, http://www.i-asem.org/publication_conf/asem17/4.MM/T5H.4.MM2272_4389F1.pdf
40. pymatgen: Home, použito září 21, 2025, https://pymatgen.org/

41. matminer (Materials Data Mining) — matminer 0.1.0 documentation, použito září 21, 2025, https://matminer.readthedocs.io/
42. matminer (Materials Data Mining) — matminer 0.9.3 documentation, použito září 21, 2025, https://hackingmaterials.lbl.gov/matminer/
43. The Role of Machine Learning in the Understanding and Design of Materials - PMC, použito září 21, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC7716341/
44. A Strategic Approach to Machine Learning for Material Science: How to Tackle Real-World Challenges and Avoid Pitfalls - ACS Publications, použito září 21, 2025, https://pubs.acs.org/doi/10.1021/acs.chemmater.2c01333
45. Unsupervised learning - Wikipedia, použito září 21, 2025, https://en.wikipedia.org/wiki/Unsupervised_learning
46. Introduction to Unsupervised Learning: Types, Applications and Differences from Supervised Learning | DataCamp, použito září 21, 2025, https://www.datacamp.com/blog/introduction-to-unsupervised-learning
47. Unsupervised Learning - Accelerate Science Core AI Concepts, použito září 21, 2025, https://docs.science.ai.cam.ac.uk/ai-core-concepts/unsupervised-learning/
48. Unsupervised Machine Learning: Examples and Use Cases - AltexSoft, použito září 21, 2025, https://www.altexsoft.com/blog/unsupervised-machine-learning/
49. 9 Real-Life Reinforcement Learning Examples and Use Cases, použito září 21, 2025, https://onlinedegrees.scu.edu/media/blog/9-examples-of-reinforcement-learning
50. Quantum Material Synthesis by Reinforcement Learning, použito září 21, 2025, https://ml4physicalsciences.github.io/2020/files/NeurIPS_ML4PS_2020_123.pdf
51. (PDF) Materials discovery through reinforcement learning: a comprehensive review, použito září 21, 2025, https://www.researchgate.net/publication/392578066_Materials_discovery_through_reinforcement_learning_a_comprehensive_review
52. Materials discovery with extreme properties via reinforcement learning-guided combinatorial chemistry - Chemical Science (RSC Publishing), použito září 21, 2025, https://pubs.rsc.org/en/content/articlelanding/2024/sc/d3sc05281h
53. Machine learning-enabled high-entropy alloy discovery - TU Delft Repository, použito září 21, 2025, https://repository.tudelft.nl/record/uuid:8576ecef-2e12-44c4-93d2-2819cd82d188
54. Benchmarking active learning strategies for materials optimization and discovery - Oxford Academic, použito září 21, 2025, https://academic.oup.com/ooms/article/2/1/itac006/6637521
55. What is transfer learning? - IBM, použito září 21, 2025, https://www.ibm.com/think/topics/transfer-learning
56. What is Transfer Learning in AI? An Introductory Guide with Examples - DataCamp, použito září 21, 2025, https://www.datacamp.com/blog/what-is-transfer-learning-in-ai-an-introductory-guide
57. Transfer learning - Wikipedia, použito září 21, 2025, https://en.wikipedia.org/wiki/Transfer_learning
58. arxiv.org, použito září 21, 2025,

https://arxiv.org/html/2504.02848v1#:~:text=Simulation%2Dto%2DReal%20(Sim2Real)%20transfer%20learning%2C%20the,the%20scarcity%20of%20experimental%20data.
59. Transfer learning from first-principles calculations to experiments with chemistry-informed domain transformation - arXiv, použito září 21, 2025, https://arxiv.org/html/2504.02848v1
60. DS06.09.05: Transfer Learning in Machine Learning for Materials Science: Enhancing Predictions and Discovery, použito září 21, 2025, https://mrs.digitellinc.com/p/s/ds060905-transfer-learning-in-machine-learning-for-materials-science-enhancing-predictions-and-discovery-41661
61. Domain Adaptation Principal Component Analysis: Base Linear Method for Learning with Out-of-Distribution Data - MDPI, použito září 21, 2025, https://www.mdpi.com/1099-4300/25/1/33