Základní modely pro predikci a exploraci dat

Kapitola 1: Úvod a most z minulé lekce

Vítejte zpět, kolegyně a kolegové. V minulé přednášce jsme společně sestavili kompletní a profesionální pracovní postup pro trénink a validaci prediktivního modelu. Nyní máte v rukou mocný nástroj: víte, jak vzít připravená data, zapouzdřit celý proces do scikit-learn Pipeline, natrénovat jednoduchý lineární model a, což je nejdůležitější, robustně ověřit jeho výkon pomocí křížové validace. Rozumíte metrikám jako je střední absolutní chyba (MAE) a koeficient determinace (R^2), takže dokážete kvantifikovat úspěšnost modelu a říci například: "Náš model dokáže předpovědět mez pevnosti nové slitiny s průměrnou chybou 15 MPa."[1]

Tím jsme vyřešili jeden konkrétní, ale velmi důležitý typ úlohy. To nás ale přivádí ke dvěma zásadním otázkám, které odhalují limity našeho současného arzenálu a které budou motivací pro celou dnešní přednášku.

Zaprvé, co když naším cílem není předpovědět spojitou hodnotu, jako je pevnost v tahu, ale zařadit materiál do jedné z několika kategorií? Například, bude tato nová sloučenina feromagnetická: ano/ne? Vytvoří tato slitina po ochlazení fázi α, nebo fázi β? Naše lineární regrese, která je navržena k prokládání přímky daty, nám na tyto otázky odpovědět neumí.

Zadruhé, co když je náš úkol ještě fundamentálnější? Co když máme obrovskou databázi 100 000 materiálů z Materials Project a ani nevíme, co přesně hledáme? Chceme v těchto datech pouze najít skryté vzory, "rodiny" podobných materiálů, které by mohly vést k nové vědecké hypotéze.[1] V tomto případě nemáme žádnou cílovou vlastnost, kterou bychom chtěli predikovat. Chceme se jen "podívat" do dat a nechat je, aby nám sama řekla, co je v nich zajímavé.

Tato přednáška vás vybaví pomyslným "švýcarským nožem" základních modelů strojového učení, které vám umožní řešit právě tyto nové typy úloh. Naše agenda je následující:

1. **Učení s učitelem:** Rozšíříme náš repertoár o modely pro **klasifikaci**, které dokáží předpovídat kategorické vlastnosti.
2. **Měření úspěchu klasifikace:** Představíme si nové metriky, které jsou pro klasifikační úlohy nezbytné.
3. **Učení bez učitele:** Vstoupíme do světa **explorace dat**, kde budeme hledat skryté struktury a vzory bez jakékoli cílové vlastnosti.
4. **Pravděpodobnostní modely:** Podíváme se na modely, které nám kromě predikce poskytnou i klíčovou informaci pro každého vědce – odhad nejistoty.

Přechod od minulé přednášky k této představuje zásadní posun ve způsobu, jakým používáme AI ve vědeckém procesu. Zatímco učení s učitelem, které jsme doposud probírali, je především o *odpovídání na známé otázky* ("Jaká bude pevnost?"), učení bez učitele je o *objevování nových otázek* ("Jaké zajímavé rodiny materiálů existují, které bychom měli studovat?"). Dnes se naučíte obojí.

Kapitola 2: Učení s učitelem – Predikce vlastností

V této kapitole se zaměříme na klasifikační úlohy, kde je naším cílem předpovědět diskrétní kategorii. Představíme si několik modelů, z nichž každý přistupuje k problému z jiné "filozofické" perspektivy.

Logistická regrese: Od přímky k pravděpodobnosti

Logistická regrese je přirozeným sourozencem lineární regrese, kterou již znáte.[1] Vnitřně funguje velmi podobně: vypočítá vážený součet vstupních deskriptorů, stejně jako lineární regrese.[2] Klíčový rozdíl spočívá v posledním kroku. Zatímco lineární regrese tento výsledek (který může být jakékoli číslo od -∞ do +∞) použije jako finální predikci, logistická regrese jej "protáhne" speciální nelineární funkcí zvanou **sigmoidní (nebo logistická) funkce**.[2]

Tato funkce má charakteristický tvar písmene "S" a její genialita spočívá v tom, že jakékoli vstupní číslo "zmáčkne" do rozsahu mezi 0 a 1.[2] Výstupem modelu tedy není přímo kategorie, ale **pravděpodobnost**, že daný vzorek patří do pozitivní třídy (obvykle označené jako "1").[3] Místo predikce "pevnost je 1250 MPa", model říká "pravděpodobnost, že tento materiál je feromagnetický, je 88 %". Pro finální rozhodnutí pak stačí nastavit práh (typicky 0.5) – pokud je pravděpodobnost vyšší, klasifikujeme jako "ano", jinak jako "ne".

Logistická regrese tedy staví most mezi lineárními modely a pravděpodobnostním světem, což z ní činí základní, ale velmi silný nástroj pro binární klasifikační úlohy, jako je predikce, zda bude materiál polovodič (1) nebo kov (0).[4]

Modely založené na vzdálenosti: Geometrický pohled na data

Další rodina modelů se na problém dívá čistě geometricky. Představte si, že každý materiál je bodem ve vícerozměrném prostoru, kde osy jsou jednotlivé deskriptory, které jsme vytvořili ve druhé přednášce.[1] Tyto modely se rozhodují na základě polohy a vzdálenosti mezi těmito body.

Metoda nejbližšího souseda (k-NN)

Princip k-NN je možná nejintuitivnější ze všech algoritmů strojového učení. Řídí se jednoduchým pravidlem: "ukaž mi své sousedy a já ti řeknu, kdo jsi".[5] Když chceme klasifikovat nový, neznámý materiál, algoritmus jednoduše najde *k* nejbližších bodů (sousedů) v trénovacích datech a provede "hlasování". Nový materiál je zařazen do třídy, která má mezi jeho *k* sousedy většinu.[6]

Klíčovým a jediným hyperparametrem je zde volba **k**:

- **Malé *k*** (např.): Model je velmi flexibilní a citlivý na lokální strukturu dat. To ho ale činí náchylným k šumu a outlierům. Představte si, že se rozhodujete jen na základě jednoho, možná trochu excentrického, souseda. Model má vysokou varianci a tendenci k přeučení.[5]
- **Velké *k***: Model je robustnější vůči šumu, protože rozhodnutí je průměrem z mnoha sousedů. Příliš velké *k* ale může způsobit, že model bude ignorovat lokální, jemnější vzory v datech a stane se příliš zjednodušujícím. Představte si, že pro lokální problém pořádáte celoměstské referendum. Model má vysoký bias a tendenci k podučení.[5]

Volba *k* je tedy klasickou ukázkou kompromisu mezi biasem a variancí, což je koncept, se kterým jste se implicitně setkali v minulé lekci, když jsme mluvili o směrodatné odchylce výkonu při křížové validaci.[1] Optimální *k* se typicky hledá pomocí GridSearchCV. Skvělým příkladem z materiálových věd je klasifikace prvků na kovy a nekovy na základě jejich periodických vlastností (atomový poloměr, elektronegativita atd.) použitých jako deskriptory.[6]

Support Vector Machines (SVM)

SVM přistupuje ke klasifikaci s cílem maximální robustnosti. Představte si, že máte data dvou tříd, například stabilní a nestabilní sloučeniny. SVM se nesnaží najít jen jakoukoli hranici, která je oddělí, ale hledá tu nejlepší možnou hranici – takovou, která má od nejbližších bodů obou tříd co největší odstup. Intuitivně se snaží najít "nejširší možnou ulici" (tzv. maximální margin) mezi dvěma "městy" datových bodů.[8] Body, které leží na krajnici této ulice, se nazývají **podpůrné vektory (support vectors)**, protože právě ony "podpírají" a definují polohu hranice.

Co když ale data nejsou oddělitelná přímkou (v 2D) nebo nadrovinou (ve více dimenzích)? Zde přichází na řadu geniální myšlenka zvaná **trik s jádrem (kernel trick)**. Intuitivně si to představte tak, že vezmeme naše data, která na plochém listu papíru nejdou oddělit rovnou čarou, a tento list "prohneme" do třetí dimenze. V tomto novém, vyšším prostoru už můžeme najít rovnou plochu, která data čistě oddělí.[8] Matematicky to SVM dělá, aniž by muselo explicitně počítat souřadnice v tomto novém prostoru, což je výpočetně velmi efektivní. Díky tomu si SVM skvěle poradí i se složitými, nelineárními vztahy, které jsou běžné například v polymerní vědě při predikci mechanických vlastností.[8]

Rozhodovací stromy: Lidsky čitelná pravidla

Posledním modelem v této kapitole je rozhodovací strom, který je ze všech modelů nejpodobnější lidskému rozhodování. Funguje jako série jednoduchých otázek typu "pokud-pak" (if-then), které postupně dělí data na stále menší a homogennější skupiny.[12]

Představte si, že chceme klasifikovat slitiny na "křehké" a "houževnaté". Strom by se mohl naučit následující pravidla:

1. Je průměrný počet valenčních elektronů > 5?
    - **Ano:** Je teplota tání < 1200 K?
        - **Ano:** Klasifikuj jako "Křehký".
        - **Ne:** Klasifikuj jako "Houževnatý".
    - **Ne:** Je rozdíl v elektronegativitě prvků > 1.0?
        - **Ano:** Klasifikuj jako "Křehký".
        - **Ne:** Klasifikuj jako "Houževnatý".

Hlavní výhodou rozhodovacích stromů je jejich **vysoká interpretovatelnost**. Celý model lze vizualizovat jako vývojový diagram, kterému rozumí i laik.[12] To z nich činí vynikající nástroj nejen pro predikci, ale i pro objevování znalostí a generování vědeckých hypotéz – pohled na strukturu stromu nám může odhalit, které deskriptory jsou pro daný problém nejdůležitější.[15]

Jejich největší síla je ale zároveň jejich největší slabinou. Díky své flexibilitě dokáží data rozdělit až na úroveň jednotlivých vzorků, což znamená, že jsou extrémně **náchylné k přeučení**. Jednoduchý strom se snadno naučí nazpaměť šum a specifika trénovacích dat, místo aby se naučil obecný princip.[12] Tuto slabinu si zapamatujte, protože se k ní vrátíme na konci přednášky a stane se odrazovým můstkem pro příští lekci.

Kapitola 3: Jak měřit a porovnat modely pro klasifikaci?

V minulé lekci jsme pro hodnocení regrese používali metriky jako MAE a R^2. Tyto metriky měří "vzdálenost" mezi predikovanou a skutečnou hodnotou. U klasifikace, kde je výstupem kategorie (např. "fáze α" nebo "fáze β"), však koncept "vzdálenosti" ztrácí smysl. Musíme proto zavést zcela novou sadu metrik.

Matice záměn (Confusion Matrix): Základní kámen pravdy

Všechny klíčové metriky pro klasifikaci jsou odvozeny z jednoduché, ale nesmírně informativní tabulky zvané **matice záměn**. Ta nám neříká jen *kolikrát* se model spletl, ale především *jakým způsobem* se spletl.[17] Pro binární klasifikaci (např. "supravodivý" vs. "nesupravodivý") má matice 4 kvadranty:

- **True Positive (TP):** Skutečnost: supravodivý. Predikce: supravodivý. (Správně nalezený "poklad")
- **True Negative (TN):** Skutečnost: nesupravodivý. Predikce: nesupravodivý. (Správně ignorovaný "balast")
- **False Positive (FP) / Chyba I. druhu:** Skutečnost: nesupravodivý. Predikce: supravodivý. (Falešný poplach)
- **False Negative (FN) / Chyba II. druhu:** Skutečnost: supravodivý. Predikce: nesupravodivý. (Promarněná příležitost)

Metriky: Více než jen celková přesnost

Z těchto čtyř hodnot můžeme odvodit několik metrik, z nichž každá nám vypráví jiný příběh o výkonu modelu.

Accuracy (Celková přesnost)

Toto je nejjednodušší metrika: . Udává, jaké procento všech predikcí bylo správných. Ačkoli se zdá intuitivní, u nevyvážených datasetů je **extrémně zavádějící**. Představte si, že hledáme nový, vysoce výkonný materiál, který je v přírodě velmi vzácný. V naší databázi máme 999 běžných materiálů a pouze 1 tento vzácný, "pozitivní" případ. Model, který se naučí vždy predikovat "běžný materiál", bude mít accuracy 99.9%, ale je pro náš cíl – objevování – naprosto k ničemu, protože ten jediný důležitý materiál nikdy nenajde.[11]

Precision, Recall a F1-Score

Pro reálné vědecké problémy, které jsou často nevyvážené, potřebujeme chytřejší metriky.

- **Precision (Přesnost):** Definuje se jako poměr správně pozitivně klasifikovaných případů (True Positives) ke všem případům, které byly klasifikovány jako pozitivní (součet True Positives a False Positives). Odpovídá na otázku: **"Ze všech materiálů, které model označil za pozitivní (např. 'vysoce výkonné'), kolik jich skutečně bylo pozitivních?"**.[21] Vysoká precision je klíčová, když je cena za falešný poplach (FP) vysoká. Například ve farmaceutickém průmyslu, kde syntéza a testování jedné navržené molekuly

stojí miliony. Chceme si být co nejjistější, že kandidáti, které model navrhne, jsou skutečně slibní.

- **Recall (Senzitivita nebo Pokrytí):** Definuje se jako poměr správně pozitivně klasifikovaných případů (True Positives) ke všem skutečně pozitivním případům (součet True Positives a False Negatives). Odpovídá na otázku: **"Ze všech skutečně pozitivních materiálů v datasetu, kolik jich model dokázal najít?"**.[21] Vysoký recall je klíčový, když je cena za promeškání (FN) vysoká. Například v akademickém výzkumu, kde je cílem objevit nový, průlomový materiál. Raději prozkoumáme pár "slepých uliček" (nižší precision), než abychom přehlédli objev století.
- **F1-Score:** Definuje se jako harmonický průměr precision a recall: . Poskytuje jediný, vyvážený ukazatel výkonu, který je užitečný, když nám záleží na obou typech chyb.[21]

Volba mezi optimalizací pro precision nebo recall tedy není čistě statistické rozhodnutí. Je to strategické rozhodnutí, které odráží ekonomické a vědecké priority daného výzkumného projektu. Neexistuje jedna "nejlepší" metrika; existuje pouze ta nejvhodnější pro váš konkrétní cíl.

Kapitola 4: Učení bez učitele – Objevování skrytých struktur v datech

Nyní provedeme zásadní myšlenkový obrat. Až dosud jsme se pohybovali v rámci učení s učitelem, kde jsme vždy měli k dispozici matici deskriptorů a k ní odpovídající cílovou vlastnost (sloupec). Nyní tento sloupec "zahodíme". Naším úkolem už není predikovat známou vlastnost, ale prozkoumat samotnou matici a zjistit, zda v ní neexistují nějaké skryté, vnitřní struktury nebo vzory.[1] Vstupujeme do světa explorativní analýzy dat.

Shlukování (Clustering): Hledání "rodin" materiálů

Cílem shlukování je automaticky rozdělit naše data do skupin (shluků, klastrů) tak, aby si materiály uvnitř jednoho shluku byly co nejpodobnější a materiály z různých shluků co nejodlišnější.

K-means

K-means je jedním z nejstarších a nejpopulárnějších shlukovacích algoritmů. Jeho princip je elegantně jednoduchý [22]:

1. **Zvol *k*:** Na začátku musíme algoritmu říci, kolik shluků chceme najít.
2. **Inicializuj těžiště:** Algoritmus náhodně umístí *k* bodů do našeho datového prostoru.

Těmto bodům říkáme **těžiště (centroids)**.

3. **Přiřaď a přepočti:** Proces probíhá ve dvou iterativních krocích:
   - **Přiřazovací krok:** Každý datový bod (materiál) je přiřazen k nejbližšímu těžišti.
   - **Přepočítávací krok:** Poloha každého těžiště je aktualizována – přesune se do středu (průměru) všech bodů, které mu byly přiřazeny.
4. **Opakuj:** Kroky 3a a 3b se opakují, dokud se pozice těžišť nepřestanou měnit.

K-means je skvělý pro rychlé nalezení přirozených, sférických shluků v datech. V materiálových vědách se může použít například k automatické identifikaci fází ve slitinách. Představte si, že provedete stovky nanoindentačních měření na vzorku dvoufázové oceli. Každé měření vám dá dvojici hodnot (tvrdost, modul pružnosti). K-means dokáže v tomto 2D prostoru automaticky najít dva shluky, které s vysokou pravděpodobností odpovídají měřením v měkčí feritické fázi a tvrdší martenzitické fázi, a to bez jakéhokoli předchozího značkování.[24]

DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) nabízí robustnější a flexibilnější přístup ke shlukování. Na rozdíl od K-means se nesnaží najít těžiště, ale definuje shluky jako **hustě osídlené oblasti v datovém prostoru**.[25] Intuitivně si ho představte jako algoritmus, který hledá "kontinenty" datových bodů, které jsou od sebe odděleny "oceány" prázdného prostoru.

Jeho hlavní výhody jsou:

- **Není třeba specifikovat počet shluků:** DBSCAN je najde sám na základě hustoty dat.
- **Dokáže najít libovolně tvarované shluky:** Není omezen na sférické tvary jako K-means.
- **Automatická detekce outlierů:** Toto je jeho klíčová vlastnost pro vědecké objevování. Jakýkoli bod, který neleží v žádné dostatečně husté oblasti, je automaticky označen jako **šum (noise)** nebo **outlier**.[26]

V materiálových vědách jsou právě tyto "anomálie" často těmi nejzajímavějšími datovými body. Mohou představovat nečekanou fázi, materiál s extrémními vlastnostmi nebo vadu ve výrobě. DBSCAN se tak skvěle hodí například pro detekci defektů na polovodičových waferech, kde shluky vadných čipů tvoří husté oblasti (indikující systematický problém), zatímco izolované vady jsou označeny jako šum.[27]

Nelineární redukce dimenze pro vizualizaci

V třetí přednášce jsme si představili PCA jako nástroj pro redukci dimenze.[1] PCA je lineární metoda, která se snaží zachovat co nejvíce globální variance v datech. Pro účely vizualizace a

objevování shluků však často existují ještě mocnější, nelineární techniky.

t-SNE a UMAP

t-SNE (t-distributed Stochastic Neighbor Embedding) a UMAP (Uniform Manifold Approximation and Projection) jsou pokročilé algoritmy navržené speciálně pro vizualizaci vysokodimenzionálních dat ve 2D nebo 3D. Jejich cílem není zachovat globální strukturu jako u PCA, ale především zachovat **lokální sousedské vztahy**.[29]

Intuitivně si představte, že se snažíte na plochou mapu světa překreslit povrch globusu. t-SNE a UMAP se snaží zajistit, aby města, která jsou si na globusu blízko, byla blízko i na výsledné 2D mapě, i za cenu zkreslení vzdáleností mezi kontinenty. Výsledkem je "mapa materiálů", kde se materiály s podobnými deskriptory přirozeně shlukují a tvoří vizuálně zřetelné "ostrovy" nebo "kontinenty".[31]

UMAP je modernější a v mnoha ohledech vylepšenou verzí t-SNE. Je výrazně rychlejší a často lépe zachovává i část globální struktury dat.[29] Tyto vizualizace jsou neocenitelným nástrojem pro generování hypotéz – pokud na UMAP mapě vidíme dosud nepopsaný shluk materiálů, může to být signál k zahájení nového výzkumného směru. Je však třeba mít na paměti, že velikost shluků, jejich vzájemná vzdálenost a osy na výsledném grafu nemají přímý fyzikální význam a slouží primárně k explorativní analýze.[29]

Kapitola 5: Pravděpodobnostní pohled a odhad nejistoty

Pro vědce je jakákoli predikce bez udání její spolehlivosti neúplná. Nestačí nám bodový odhad, že "pevnost bude 1500 MPa". Potřebujeme vědět, jak moc si je model touto predikcí jistý – je to "1500 ± 10 MPa" nebo "1500 ± 300 MPa"? Tento odhad nejistoty je klíčový pro rozhodování, zda se vyplatí daný materiál syntetizovat.

Gaussovské procesy

Gaussovské procesy (GP) jsou flexibilní regresní metoda, která tento problém elegantně řeší. Na rozdíl od lineární regrese, která se snaží daty proložit jednu "nejlepší" funkci (přímku), si GP představuje, že data mohla být vygenerována nekonečným množstvím různých funkcí. GP modeluje **distribuci přes všechny tyto možné funkce**.[33]

Když pak chceme predikci pro nový bod, GP nám nevrátí jedno číslo, ale celou Gaussovu

distribuci možných hodnot. Z této distribuce získáme dvě klíčové informace [35]:

1. **Střední hodnotu (Mean):** Nejpravděpodobnější hodnota predikce (náš bodový odhad).
2. **Rozptyl (Variance):** Míra naší **nejistoty** ohledně této predikce.

Charakteristickou vlastností GP je, že v oblastech, kde máme hodně trénovacích dat, je rozptyl (nejistota) velmi malý. Naopak v oblastech daleko od známých dat, kde model "neví", co se děje, je rozptyl přirozeně velký.

Propojení s Aktivním učením

A právě tato schopnost kvantifikovat nejistotu dělá z Gaussovských procesů ideální motor pro **Aktivní učení** – koncept, který jsme si letmo představili v úvodních přednáškách.[1] Aktivní učení přeměňuje model z pasivního prediktoru na aktivního partnera ve výzkumu, který nám pomáhá chytře navrhovat další experimenty.[37]

Proces funguje v uzavřené smyčce (closed-loop):

1. Natrénujeme GP na několika málo počátečních experimentálních bodech.
2. Model proskenuje obrovský prostor kandidátních materiálů a pro každý z nich predikuje nejen cílovou vlastnost, ale i svou nejistotu.
3. **Akviziční funkce** – mozek aktivního učení – vybere další experiment na základě nějaké strategie. Nejjednodušší strategií je tzv. **uncertainty sampling**: vyber ten materiál, u kterého je si model **nejméně jistý** (má největší predikovanou varianci).[38]
4. V laboratoři provedeme pouze tento jeden, nejinformativnější experiment.
5. Výsledek přidáme do trénovací sady, přetrénujeme GP (který nyní bude v okolí nového bodu mnohem jistější) a celý cyklus opakujeme.

Tento přístup dramaticky zrychluje objevování nových materiálů, protože se vyhýbáme zbytečným experimentům v oblastech, které už dobře známe, a cíleně se zaměřujeme na ty části materiálového prostoru, které slibují největší zisk informací.[40]

Kapitola 6: Závěr a výhled na příští týden

Dnes jsme udělali obrovský krok vpřed. Rozšířili jsme náš arzenál nástrojů daleko za hranice jednoduché lineární regrese. Nyní máte k dispozici základní sadu modelů pro řešení tří klíčových typů úloh v materiálové informatice:

- **Regrese:** Predikce spojitých vlastností (z minulé lekce).
- **Klasifikace:** Předpovídání kategorických vlastností, jako je typ fáze nebo magnetické chování.
- **Shlukování:** Explorace dat a objevování nových "rodin" materiálů bez jakéhokoli

předchozího zadání.

Navíc jsme se dotkli tématu pravděpodobnostních modelů, jako jsou Gaussovské procesy, které nám dávají nejen predikci, ale i klíčový odhad její spolehlivosti. Viděli jsme, jak tato schopnost přímo pohání inteligentní strategie pro návrh experimentů, jako je aktivní učení.

Při naší cestě jsme si všimli, že některé modely, jako jsou rozhodovací stromy, jsou úžasně interpretovatelné – můžeme se podívat dovnitř a pochopit, proč dělají svá rozhodnutí. Jiné, složitější modely, se kterými se setkáme, se často chovají jako "černé skříňky". Je důležité vědět, že existuje celá, rychle se rozvíjející oblast zvaná **vysvětlitelná AI (XAI)**, která vyvíjí techniky (jako SHAP nebo LIME), jež nám umožňují nahlédnout i do těchto složitých modelů a budovat důvěru v jejich predikce.[41]

A tím se dostáváme k navnadění na příští týden. Ukázali jsme si, že jednotlivé rozhodovací stromy jsou sice skvěle interpretovatelné, ale náchylné k přeučení. Co kdybychom ale mohli vzít stovky takových "slabých", nestabilních stromů a donutit je spolupracovat? Příště si ukážeme, jak "moudrost davu" může přeměnit jednoduché modely na jedny z nejvýkonnějších a nejrobustnějších prediktorů v klasickém strojovém učení. Podíváme se na sílu **ansámblových metod: Random Forest a Gradient Boosting**.

Citovaná díla

1. 1. přednáška - AI revoluce v materiálovém inženýrství.pdf
2. What Is Logistic Regression? | IBM, použito října 11, 2025, https://www.ibm.com/think/topics/logistic-regression
3. Logistic regression - Wikipedia, použito října 11, 2025, https://en.wikipedia.org/wiki/Logistic_regression
4. Logistic Regression — Technique for Classification problems | by Kaleemullah Younas, použito října 11, 2025, https://medium.com/@kaleemullahyounas123/logistic-regression-technique-for-classification-problems-639000510fe5
5. What is the k-nearest neighbors algorithm? | IBM, použito října 11, 2025, https://www.ibm.com/think/topics/knn
6. The use of the k nearest neighbor method to classify the representative elements - Elsevier, použito října 11, 2025, https://www.elsevier.es/es-revista-educacion-quimica-78-articulo-the-use-k-nearest-neighbor-S0187893X15000312
7. Mastering K-Nearest Neighbors (KNN): A Comprehensive Guide with Detailed Code | by Ebad Sayed | Medium, použito října 11, 2025, https://medium.com/@sayedebad.777/mastering-k-nearest-neighbors-knn-aa4b2ffca68b
8. Support Vector Machines in Polymer Science: A Review - PMC, použito října 11, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC11859395/
9. Artificial Intelligence in Predicting Mechanical Properties of Composite Materials - MDPI, použito října 11, 2025, https://www.mdpi.com/2504-477X/7/9/364

10. Prediction of Material Mechanical Properties with Support Vector Machine - ResearchGate, použito října 11, 2025, https://www.researchgate.net/publication/220728419_Prediction_of_Material_Mechanical_Properties_with_Support_Vector_Machine
11. Confusion matrix - Wikipedia, použito října 11, 2025, https://en.wikipedia.org/wiki/Confusion_matrix
12. What is a Decision Tree? | IBM, použito října 11, 2025, https://www.ibm.com/think/topics/decision-trees
13. Decision tree learning - Wikipedia, použito října 11, 2025, https://en.wikipedia.org/wiki/Decision_tree_learning
14. Confusion - Edge.org, použito října 11, 2025, https://www.edge.org/response-detail/27209
15. (PDF) Experiences Using Decision Trees for Knowledge Discovery - ResearchGate, použito října 11, 2025, https://www.researchgate.net/publication/312348610_Experiences_Using_Decision_Trees_for_Knowledge_Discovery
16. Predicting materials properties and behavior using classification and regression trees, použito října 11, 2025, https://www.researchgate.net/publication/248471409_Predicting_materials_properties_and_behavior_using_classification_and_regression_trees
17. Confusion Matrix: How To Use It & Interpret Results [Examples], použito října 11, 2025, https://www.v7labs.com/blog/confusion-matrix-guide
18. What is A Confusion Matrix in Machine Learning? The Model Evaluation Tool Explained, použito října 11, 2025, https://www.datacamp.com/tutorial/what-is-a-confusion-matrix-in-machine-learning
19. Everything You Need to Know When Assessing Confusion Matrices Skills - Alooba, použito října 11, 2025, https://www.alooba.com/skills/concepts/data-science-6/confusion-matrices/
20. Class-imbalanced datasets | Machine Learning - Google for Developers, použito října 11, 2025, https://developers.google.com/machine-learning/crash-course/overfitting/imbalanced-datasets
21. How to Calculate Precision, Recall, and F-Measure for Imbalanced ..., použito října 11, 2025, https://machinelearningmastery.com/precision-recall-and-f-measure-for-imbalanced-classification/
22. What is k-means clustering? | IBM, použito října 11, 2025, https://www.ibm.com/think/topics/k-means-clustering
23. k-means clustering - Wikipedia, použito října 11, 2025, https://en.wikipedia.org/wiki/K-means_clustering
24. "Challenges in the phase identification of steels using unsupervised ..., použito října 11, 2025, https://dc.engconfintl.org/nanomechtest_viii/82/
25. DBSCAN for Anomaly Detection - Kaggle, použito října 11, 2025, https://www.kaggle.com/code/luckypen/dbscan-for-anomaly-detection

26. DBSCAN for Anomaly detection - Medium, použito října 11, 2025, https://medium.com/@injure21/dbscan-for-anomaly-detection-994266b4d782
27. A Novel DBSCAN-based Defect Pattern Detection and Classification ..., použito října 11, 2025, https://www.researchgate.net/publication/333094399_A_Novel_DBSCAN-based_Defect_Pattern_Detection_and_Classification_Framework_for_Wafer_Bin_Map
28. Result form 3D clustering using DBSCAN: a defects detected in the... - ResearchGate, použito října 11, 2025, https://www.researchgate.net/figure/Result-form-3D-clustering-using-DBSCAN-a-defects-detected-in-the-complete-scan-volume-b_fig15_376785895
29. Understanding UMAP, použito října 11, 2025, https://pair-code.github.io/understanding-umap/
30. t-SNE and UMAP | Data Visualization Class Notes - Fiveable, použito října 11, 2025, https://fiveable.me/data-visualization/unit-5/t-sne-umap/study-guide/3klWziQkl2OAjhax
31. Understanding How Dimension Reduction Tools Work: An Empirical Approach to Deciphering t-SNE, UMAP, TriMap, and PaCMAP for Data Visualization, použito října 11, 2025, https://jmlr.org/papers/v22/20-1061.html
32. T-sne and umap projections in Python - Plotly, použito října 11, 2025, https://plotly.com/python/t-sne-and-umap-projections/
33. A tutorial on Gaussian process regression with a focus on ... - bioRxiv, použito října 11, 2025, https://www.biorxiv.org/content/10.1101/095190v2.full-text
34. Tutorial: Gaussian process models for machine learning, použito října 11, 2025, https://mlg.eng.cam.ac.uk/zoubin/tut06/snelson-gp.pdf
35. Gaussian Process Regression Models - MATLAB & Simulink, použito října 11, 2025, https://www.mathworks.com/help/stats/gaussian-process-regression-models.html
36. Gaussian Processes regression: basic introductory example - Scikit-learn, použito října 11, 2025, https://scikit-learn.org/stable/auto_examples/gaussian_process/plot_gpr_noisy_targets.html
37. Progress on Active Learning Assisted Materials Discovery - SciOpen, použito října 11, 2025, https://www.sciopen.com/article/10.14062/j.issn.0454-5648.20220924
38. Benchmarking Active Learning Strategies for Materials Optimization and Discovery - arXiv, použito října 11, 2025, https://arxiv.org/pdf/2204.05838
39. (PDF) Active Learning for Discovering Complex Phase Diagrams with Gaussian Processes, použito října 11, 2025, https://www.researchgate.net/publication/383951063_Active_Learning_for_Discovering_Complex_Phase_Diagrams_with_Gaussian_Processes
40. On-the-fly closed-loop materials discovery via Bayesian active learning - PMC, použito října 11, 2025, https://pmc.ncbi.nlm.nih.gov/articles/PMC7686338/
41. Review on Explainable AI by using LIME and SHAP Models for Healthcare Domain, použito října 11, 2025, https://www.researchgate.net/publication/375849554_Review_on_Explainable_AI_by_using_LIME_and_SHAP_Models_for_Healthcare_Domain

42. Explainable AI (XAI) with SHAP and LIME | by Declan Daniel Joyce | Medium, použito října 11, 2025, https://medium.com/@declan.daniel.joyce/explainable-ai-xai-with-shap-and-lime-07e14242affd
43. Commentary on explainable artificial intelligence methods: SHAP and LIME - ResearchGate, použito října 11, 2025, https://www.researchgate.net/publication/370495149_Commentary_on_explainable_artificial_intelligence_methods_SHAP_and_LIME