Přednáška 6: Síla kolektivu – Ansámblové metody a jak nahlédnout do černé skříňky

Kapitola 1: Úvod – Od nestabilního experta k moudrosti davu

1.1 Most z minulé lekce: Problém přeučení

Vítejte zpět v kurzu "AI v materiálovém inženýrství". V minulé přednášce jsme se seznámili s rozhodovacími stromy, modely, které jsou díky své struktuře (podobné vývojovému diagramu) úžasně interpretovatelné. Viděli jsme, jak dokáží extrahovat jednoduchá pravidla typu "pokud-pak" a odhalit, které deskriptory jsou pro daný problém klíčové. Tato transparentnost je ve vědě nesmírně cenná.
Narazili jsme však na zásadní, téměř fatální slabinu. Jejich největší síla – flexibilita – je zároveň jejich největší Achillovou patou. Jednotlivý rozhodovací strom je extrémně náchylný k přeučení (overfitting). Díky své schopnosti dělit data až na úroveň jednotlivých vzorků má tendenci se dokonale "naučit nazpaměť" nejen skutečný, zobecnitelný fyzikální vztah mezi deskriptory a vlastností (signál), ale i všechny náhodné šumy, odchylky měření a specifika konkrétních vzorků v trénovacích datech. Výsledkem je model, který exceluje na datech, která už viděl, ale naprosto selhává při predikci na nových, dosud neviděných materiálech. Tento problém vysoké variance je zásadní překážkou pro jejich praktické využití v seriózním výzkumu a stává se odrazovým můstkem pro celou dnešní přednášku.

1.2 Princip "Moudrosti davu" (Wisdom of the Crowd)

Jak tedy využít sílu rozhodovacích stromů a zároveň potlačit jejich tendenci k přeučení? Odpověď leží v jednom z nejstarších a nejintuitivnějších principů kolektivní inteligence: v moudrosti davu. Tato myšlenka, že kolektivní úsudek diverzifikované a nezávislé skupiny je často přesnější než úsudek kteréhokoli jednotlivého experta, je základním kamenem takzvaných ansámblových metod.
Klasickým příkladem je pozorování Francise Galtona z roku 1906. Na dobytčím trhu požádal dav zhruba 800 lidí, aby odhadli váhu poraženého býka. Ačkoliv jednotlivé odhady byly velmi rozptýlené a často zcela mylné, medián (a průměr) všech odhadů se od skutečné váhy lišil o méně než 1 %. Dav jako celek byl chytřejší než téměř každý jeho jednotlivec.
Tuto analogii můžeme přímo přenést do světa strojového učení. Představme si každý jednotlivý, přeučený rozhodovací strom jako jednoho člověka v davu. Sám o sobě je nespolehlivý, jeho "odhad" je zatížen vysokou variancí. Ale pokud vytvoříme mnoho takových stromů, z nichž

každý se učí na mírně odlišné verzi dat, budou dělat různé chyby. Tyto chyby, pokud jsou dostatečně náhodné a nekorelované, mají tendenci se při agregaci vzájemně vyrušit. Ve strojovém učení tento princip formalizujeme tak, že kombinujeme predikce z mnoha "slabých žáků" (weak learners) – modelů, které jsou jen o málo lepší než náhodné hádání – abychom vytvořili jednoho "silného žáka" (strong learner) s výrazně lepším, robustnějším a stabilnějším výkonem.
Tento přístup není jen statistickým trikem. Je to přímá algoritmická implementace procesu, jakým dochází ke vědeckému konsenzu. Vědecký pokrok není založen na neomylném názoru jediného génia, ale na postupném budování konsenzu z mnoha nezávislých experimentů a studií. Každá jednotlivá studie má své chyby, šum a omezení – má vysokou varianci. Teprve agregací výsledků z mnoha studií, například v meta-analýzách, docházíme k robustnímu a spolehlivému závěru, protože se náhodné chyby jednotlivých studií vzájemně vyruší. Ansámblové metody tedy napodobují samotný proces budování vědecké důvěry, což je hlubší důvod, proč jsou tak úspěšné – jsou v souladu se základním principem, jak docházíme k poznání.

Kapitola 2: Demokratický přístup – Bagging a Náhodné lesy (Random Forest)

První rodina ansámblových metod, kterou si představíme, je založena na myšlence "demokracie" – necháme hlasovat mnoho nezávislých modelů a finální rozhodnutí bude výsledkem tohoto hlasování. Klíčovou technikou je zde Bagging.

2.1 Bootstrap Aggregating (Bagging): Snížení variance pomocí hlasování

Název Bagging je zkratkou pro **Bootstrap Aggregating** a popisuje přesně dvoustupňový proces, který tato metoda používá.

1. **Bootstrapping:** Prvním krokem je vytvoření diverzity mezi našimi modely. Z původní trénovací sady, která obsahuje *N* materiálů, vytvoříme mnoho (například 100) nových trénovacích sad. Každá z těchto nových sad má také velikost *N*, ale je vytvořena náhodným výběrem z původní sady **s vracením**. To znamená, že při každém výběru jednoho materiálu do nové sady je tento materiál "vrácen zpět" do osudí a může být vybrán znovu. Důsledkem je, že některé materiály se v dané bootstrap sadě objeví vícekrát, zatímco jiné se v ní neobjeví vůbec. Statisticky platí, že každá taková bootstrap sada obsahuje v průměru zhruba 63.2 % unikátních vzorků z původní sady. Tímto procesem získáme mnoho mírně odlišných pohledů na naše data.

2. **Agregace:** Na každé z těchto nově vytvořených bootstrap sad natrénujeme zcela nezávislý model (typicky rozhodovací strom), a to paralelně. Když pak chceme predikovat vlastnost nového, neviděného materiálu, necháme všechny tyto modely "hlasovat". Finální predikce je získána agregací jejich individuálních predikcí:
    - Pro **regresní úlohy** (predikce spojité hodnoty, např. mez pevnosti) je finální

predikcí **průměr** všech individuálních predikcí.
    - Pro **klasifikační úlohy** (predikce kategorie, např. "stabilní" vs. "nestabilní") je finální predikcí **většinový hlas** (třída, kterou predikovalo nejvíce stromů).

Hlavním cílem a výsledkem Baggingu je dramatické **snížení variance**. Jednotlivé stromy, natrénované na různých podmnožinách dat, budou mít mírně odlišné struktury a budou dělat různé chyby. Průměrováním nebo hlasováním se tyto chyby mají tendenci vzájemně vyrušit. To vede k hladší a stabilnější rozhodovací hranici a výrazně snižuje riziko přeučení, které trápilo jednotlivé stromy.

2.2 Náhodný les (Random Forest): Dvojitá náhodnost pro robustnost

Náhodný les (Random Forest) je specifickou a velmi populární implementací Baggingu, která přidává ještě jednu další vrstvu náhodnosti, aby byla výsledná "moudrost davu" ještě efektivnější.
Zatímco Bagging vytváří různorodé stromy tím, že jim ukazuje různé vzorky dat (různé řádky), Random Forest jde o krok dál. Při konstrukci každého stromu, na každém jednotlivém uzlu, kde se strom rozhoduje, podle kterého příznaku data rozdělit, nebere v úvahu všechny dostupné příznaky (všechny sloupce). Místo toho si pro každé dělení vybere pouze **náhodnou podmnožinu příznaků**. Tomuto postupu se říká "feature randomness" nebo "random subspace method".
Důsledek této druhé vrstvy náhodnosti je zásadní. Představme si, že v našich datech máme jeden velmi silný prediktivní příznak – například průměrnou elektronegativitu, která silně koreluje s cílovou vlastností. V klasickém Baggingu by tento silný příznak byl pravděpodobně vybrán pro první dělení ve většině stromů. To by vedlo k tomu, že všechny stromy v ansámblu by si byly navzájem velmi podobné (vysoce korelované) a jejich chyby by se nevyrušily tak efektivně.
Random Forest tomuto scénáři brání. Tím, že na každém uzlu nabídne stromu jen omezený, náhodný výběr příznaků, nutí ho, aby prozkoumal i méně zjevné, ale stále relevantní vztahy v datech. Některé stromy budou muset použít jiné příznaky, protože ten dominantní zrovna nebyl v náhodném výběru k dispozici. Tím se jednotlivé stromy stávají více různorodými a méně korelovanými, což vede k ještě efektivnějšímu snížení variance při finální agregaci.

2.3 Příklad z materiálových věd: Predikce vlastností

Random Forest je jedním z nejpopulárnějších a nejspolehlivějších algoritmů v materiálové informatice, zejména pro úlohy s tabulkovými daty. Jeho robustnost a schopnost modelovat složité, nelineární vztahy ho činí ideálním nástrojem pro širokou škálu problémů. Příkladem může být predikce Curieovy teploty magnetických materiálů, kde se model učí vztah mezi chemickým složením (deskriptory odvozené ze vzorce) a kritickou teplotou pro magnetický přechod. Další aplikací je predikce klíčových mechanických vlastností, jako je teplota skelného přechodu (T_g) u epoxidových polymerů, na základě jejich složení a parametrů síťování.
Popularita Random Forest v našem oboru pramení z jeho schopnosti efektivně pracovat s typickými materiálovými datasety: často vysokodimenzionálními (stovky různých deskriptorů) a zároveň relativně malými co do počtu vzorků. Je také poměrně snadné ho nastavit, protože jeho

výkon je méně citlivý na přesné hodnoty hyperparametrů ve srovnání s jinými pokročilými metodami.

Reálná materiálová data, zejména ta experimentální, jsou navíc často "špinavá" – neúplná, zašuměná a obsahující mnoho vzájemně korelovaných deskriptorů. Například různé deskriptory odvozené od atomových poloměrů nebo elektronegativity budou přirozeně silně korelovat. Zatímco jednodušší modely, jako je lineární regrese, mohou trpět problémy s multikolinearitou, Random Forest je vůči těmto nedokonalostem přirozeně odolný. Bootstrapping zajišťuje, že každý strom vidí mírně odlišnou verzi dat, což snižuje vliv jednotlivých outlierů. Náhodný výběr příznaků zase zajišťuje, že i když jsou dva příznaky silně korelované, model nebude záviset jen na jednom z nich; různé stromy budou nuceny použít oba, což vede k vyváženějšímu a robustnějšímu modelu. Random Forest tedy není jen "lepší rozhodovací strom", ale je to algoritmus specificky navržený tak, aby exceloval v reálných, nedokonalých podmínkách, které jsou v materiálové vědě na denním pořádku.

Kapitola 3: Týmová práce expertů – Boosting a Gradient Boosting

Druhá rodina ansámblových metod, boosting, je založena na zcela odlišné filozofii. Místo demokratického hlasování nezávislých modelů si představme tým expertů, kteří spolupracují a učí se jeden od druhého.

3.1 Princip Boostingu: Sekvenční vylepšování

Na rozdíl od paralelního a nezávislého tréninku v Baggingu, boosting staví modely **sekvenčně**. Každý nový model v řadě se explicitně snaží **opravit chyby**, které udělaly všechny modely před ním.

Základní mechanismus funguje následovně:

1. Natrénuje se první, velmi jednoduchý model (slabý žák) na původních datech.
2. Analyzují se jeho predikce. Těm datovým bodům (materiálům), které byly predikovány špatně, se přiřadí vyšší váha. Tím se model "zaměří" na příklady, které jsou pro něj obtížné.
3. Natrénuje se druhý model, který se snaží minimalizovat chybu, přičemž více zohledňuje vzorky s vyšší vahou.
4. Tento proces se opakuje. Každý další model se soustředí na chyby, které zbyly po předchozím ansámblu.
5. Finální predikce je pak váženým součtem predikcí všech modelů v řadě, kde modely, které si vedly lépe, mají obvykle větší váhu v konečném rozhodnutí.

Zatímco Bagging se primárně snaží snížit varianci, hlavním cílem boostingu je **snížení biasu**. Postupným a cíleným zaměřováním se na chyby model systematicky zpřesňuje své predikce a dokáže se naučit i velmi složité a jemné vzory v datech, které by jednotlivé modely přehlédly.

3.2 Gradient Boosting: Učení se z chyb (reziduí)

Gradient Boosting je elegantní a matematicky podložená formalizace myšlenky boostingu, která se stala jedním z nejvýkonnějších algoritmů pro tabulková data. Místo složitého převažování vzorků je jeho princip založen na jednoduché a intuitivní myšlence: **učit se přímo z chyb**.

Představme si regresní úlohu krok za krokem:

1. **Start:** Začneme s velmi naivním modelem. Například modelem, který pro všechny materiály predikuje jednoduše průměrnou hodnotu cílové vlastnosti z trénovací sady (např. průměrnou mez pevnosti).
2. **Výpočet chyb:** Spočítáme chyby tohoto prvního modelu. Těmto chybám se říká **rezidua** – pro každý materiál je to rozdíl mezi jeho skutečnou hodnotou a naší aktuální predikcí (reziduum = y_skutecna - y_predikovana).
3. **Trénink na chybách:** Nyní natrénujeme nový model (typicky mělký rozhodovací strom). Jeho úkolem ale není predikovat původní cílovou vlastnost (mez pevnosti), ale **predikovat rezidua z předchozího kroku**. Tento strom se tedy učí, jaké korekce musíme provést, abychom se přiblížili správné odpovědi.
4. **Aktualizace modelu:** Přidáme predikci tohoto nového "chybového" modelu k našemu původnímu modelu. Abychom se vyhnuli příliš velkým skokům a přeučení, tuto korekci vynásobíme malým číslem zvaným **learning rate** (např. 0.1). Naše nová, vylepšená predikce je tedy: predikce_nova = predikce_stara + learning rate · predikce_rezidua.
5. **Opakování:** Celý proces opakujeme mnohokrát. V každém kroku spočítáme nová, menší rezidua a natrénujeme další strom, který se je snaží opravit. Každý strom tak přidává malou, postupnou korekci, která zpřesňuje celkovou predikci.

Tento zdánlivě jednoduchý proces má hlubokou matematickou podstatu. Lze ukázat, že je ekvivalentní provádění **gradientního sestupu** v prostoru funkcí. Rezidua (pro případ střední kvadratické chyby) jsou totiž záporným gradientem chybové funkce. Každý nový strom, který se snaží rezidua modelovat, je tedy krokem ve směru nejstrmějšího poklesu celkové chyby modelu.

3.3 Příklad z materiálových věd: Návrh slitin a predikce výkonu

Modely založené na Gradient Boostingu, jako jsou populární knihovny **XGBoost**, **LightGBM** a **CatBoost**, často představují absolutní špičku ve výkonu pro prediktivní úlohy na strukturovaných, tabulkových datech. V materiálové vědě se proto nasazují na ty nejnáročnější problémy. Příkladem může být návrh nových vysokopevnostních slitin titanu s TRIP/TWIP efektem, kde model predikuje mechanické vlastnosti na základě složení a parametrů tepelného zpracování. Další významnou aplikací je screening a predikce adsorpčních vlastností metalo-organických koster (MOFs) pro účely separace plynů, což je klíčové pro technologie zachycování uhlíku.
Tyto modely jsou sice extrémně výkonné, ale jejich síla je vykoupena vyšší složitostí. Jsou citlivější na správné ladění hyperparametrů (jako je learning rate, hloubka stromů, počet stromů) a jsou náchylnější k přeučení, pokud nejsou použity správné regularizační techniky.

3.4 Srovnání: Demokracie vs. Týmová práce

Následující tabulka shrnuje klíčové rozdíly mezi těmito dvěma filozofiemi ansámblového učení.

Kritérium	Bagging (Random Forest)	Boosting (Gradient Boosting)
Princip tréninku	Paralelní, nezávislé modely ("demokracie")	Sekvenční, každý model opravuje chyby předchozího ("týmová práce")
Hlavní cíl	Snížení variance (redukce přeučení)	Snížení biasu (zvýšení přesnosti)
Vzorkování dat	Bootstrap (náhodný výběr s vracením)	Vážení vzorků nebo trénink na reziduích
Agregace predikcí	Průměrování / Hlasování	Vážený součet predikcí
Citlivost na šum	Robustní	Náchylnější k šumu a outlierům
Výpočetní náročnost	Snadno paralelizovatelné	Sekvenční, nelze snadno paralelizovat
Náchylnost k přeučení	Menší	Větší, vyžaduje pečlivou regularizaci a ladění

Volba mezi Random Forest a Gradient Boosting není jen otázkou výkonu, ale odráží strategii modelování. Na první pohled by se mohlo zdát, že bychom měli vždy volit model s nejvyšší přesností, což je v mnoha případech Gradient Boosting. Nicméně Random Forest je podstatně robustnější a méně citlivý na přesné nastavení hyperparametrů. Často poskytuje "dostatečně dobré" výsledky s minimálním úsilím a je vynikajícím výchozím modelem (baseline) pro jakýkoli problém. Gradient Boosting naopak vyžaduje pečlivější ladění a validaci. Jeho síla spočívá ve schopnosti "vytěžit" z dat maximum informace, ale to s sebou nese vyšší riziko přeučení, pokud data obsahují hodně šumu nebo outlierů. Strategická volba tedy zní: Pokud je potřeba rychle vytvořit robustní a spolehlivý model, je rozumné začít s Random Forest. Pokud je cílem dosáhnout absolutně nejvyšší možné prediktivní přesnosti a jsme ochotni investovat čas do pečlivého ladění, sáhnutí po Gradient Boostingu je správnou volbou. Není to souboj "lepší vs. horší", ale spíše "robustnost a jednoduchost vs. maximální výkon".

Kapitola 4: Dilema černé skříňky (The Black Box Dilemma)

4.1 Cena za výkon: Ztráta interpretovatelnosti

Zkombinováním stovek nebo tisíců jednoduchých rozhodovacích stromů jsme dosáhli obrovského nárůstu prediktivní síly a robustnosti. Zaplatili jsme za to ale vysokou cenu: ztratili jsme jednoduchou a přímou interpretovatelnost, kterou měl jeden jediný strom. Pokusit se pochopit, jak dospěl ke svému rozhodnutí ansámbl stovek modelů, je pro lidský mozek prakticky nemožné. Je to jako snažit se zpětně zrekonstruovat myšlenkové pochody tisíců hlasujících voličů nebo sledovat stovky postupných korekčních kroků v týmu expertů. Finální logika je

skrytá, neprůhledná. Tyto výkonné modely se pro nás stávají **černou skříňkou** (black box) – vidíme vstup (deskriptory materiálu), vidíme výstup (predikci), ale proces mezi nimi je nám utajen.

4.2 Proč je to problém ve vědě?

V některých komerčních aplikacích, kde záleží pouze na přesnosti predikce (například predikce ceny akcií nebo doporučování produktů), nemusí být černá skříňka zásadním problémem. Pokud model funguje, jeho vnitřní logika není prioritou.
V materiálové vědě je však situace diametrálně odlišná. Naším konečným cílem není jen predikovat vlastnosti, ale především **pochopit** fundamentální vztahy mezi složením, strukturou, zpracováním a výslednými vlastnostmi materiálu. Chceme odhalit kauzální mechanismy, formulovat nové fyzikální principy a budovat hlubší intuici. Černá skříňka nám sice může říct, že slitina X bude mít vysokou pevnost, ale neřekne nám **proč**. Brání nám v generování nových vědeckých hypotéz a v budování důvěry v model. Bez pochopení "proč" se vracíme zpět k sofistikované, digitální formě "pokus-omyl" alchymie, kde sice máme mocný nástroj, ale nerozumíme mu.
Tento problém je o to zákeřnější, že model může dosahovat vysoké přesnosti ze zcela nesprávných, nevědeckých důvodů. Tento jev se někdy označuje jako "Clever Hans effect". Model se může naučit například falešnou korelaci mezi přítomností určitého prvku a vysokou pevností, ačkoliv skutečným důvodem je parametr tepelného zpracování, který s přítomností tohoto prvku v trénovacích datech jen náhodně koreluje. Bez možnosti nahlédnout dovnitř modelu tuto chybnou logiku nikdy neodhalíme a můžeme být svedeni na scestí ve svém výzkumu.

Kapitola 5: Nahlédnutí do stroje – Globální vysvětlitelnost

Abychom překonali dilema černé skříňky, obracíme se k rychle se rozvíjející oblasti zvané **vysvětlitelná umělá inteligence (Explainable AI, XAI)**. XAI je soubor metod a procesů, které nám umožňují pochopit a důvěřovat výsledkům a výstupům vytvořeným algoritmy strojového učení. Cílem je transformovat černé skříňky na přinejmenším "šedé" nebo ideálně "bílé" skříňky. Metody XAI můžeme rozdělit do dvou hlavních kategorií: **globální vysvětlitelnost**, která se snaží popsat, jak model funguje jako celek, a **lokální vysvětlitelnost**, která vysvětluje, proč model udělal jedno konkrétní rozhodnutí pro jeden konkrétní vzorek. V této kapitole se zaměříme na globální pohled.

5.2 Důležitost příznaků (Feature Importance)

Nejzákladnější otázkou, kterou si můžeme položit, je: "Které deskriptory jsou pro predikce mého modelu celkově nejdůležitější?". Existuje několik způsobů, jak na to odpovědět.

Mean Decrease in Impurity (Gini Importance)

Tato metoda je specifická pro modely založené na stromech, jako je Random Forest, a je vypočítána přímo z jejich vnitřní struktury. Princip je následující: v každém uzlu každého stromu se při dělení dat měří, o kolik daný příznak snížil "nečistotu" dat (což je míra toho, jak moc jsou v dané skupině smíchané různé kategorie) - např. pomocí Giniho nečistoty pro klasifikaci nebo snížením variance pro regresi. Důležitost příznaku je pak definována jako průměrné snížení nečistoty, které tento příznak způsobil, zprůměrované přes všechny stromy v lese.

- **Výhody:** Je to extrémně rychlá metoda, protože všechny potřebné informace se sbírají již během tréninku modelu.
- **Nevýhody:** Tato metoda má známé nedostatky. Má tendenci systematicky nadhodnocovat důležitost numerických příznaků a kategorických příznaků s mnoha unikátními hodnotami (vysokou kardinalitou). Navíc, pokud jsou dva příznaky silně korelované, může model přiřadit veškerou důležitost jednomu z nich a druhý zcela ignorovat, což může vést k zavádějícím závěrům.

Permutation Importance

Permutační důležitost je mnohem robustnější a obecnější alternativa, která je navíc modelově agnostická – funguje pro jakýkoli natrénovaný model. Její princip je velmi intuitivní a je založen na jednoduchém experimentu:

1. Nejprve natrénujeme náš model (např. Random Forest) a změříme jeho výkon (např. R^2) na odložené testovací sadě. Tím získáme naši základní, referenční hodnotu výkonu.
2. Nyní vezmeme jeden sloupec (jeden příznak) v testovací sadě a náhodně zamícháme jeho hodnoty. Tím efektivně "rozbijeme" jakýkoli informační vztah mezi tímto příznakem a cílovou vlastností, zatímco všechny ostatní příznaky zůstanou nezměněny.
3. Na těchto datech s jedním zamíchaným sloupcem znovu provedeme predikce a změříme výkon modelu.
4. **Pokles výkonu** oproti referenční hodnotě je mírou důležitosti daného příznaku. Pokud se výkon dramaticky zhorší, znamená to, že se model na tento příznak silně spoléhal. Pokud se výkon téměř nezmění, znamená to, že příznak byl pro model nedůležitý.
5. Tento proces opakujeme pro každý příznak v datasetu.

- **Výhody:** Je to spolehlivá a teoreticky podložená metoda, která přímo měří vliv příznaku na skutečný prediktivní výkon modelu. Je modelově agnostická a netrpí předsudky Gini importance.
- **Nevýhody:** Je výpočetně náročnější, protože vyžaduje opakované vyhodnocování modelu na pozměněných datech.

Kapitola 6: Vysvětlení konkrétní predikce – Lokální vysvětlitelnost

Globální důležitost příznaků je užitečná, ale často nám nestačí. Potřebujeme odpovědět na konkrétnější otázky: "Proč byl zrovna tento materiál predikován jako vysoce stabilní?" nebo "Které vlastnosti způsobily, že tato slitina byla klasifikována jako křehká?". Zde nastupují metody lokální vysvětlitelnosti.

6.1 LIME (Local Interpretable Model-agnostic Explanations)

LIME je jednou z nejpopulárnějších technik pro lokální vysvětlení. Jeho základní myšlenka je geniálně jednoduchá: i když je globální chování složitého modelu (černé skříňky) vysoce nelineární a nepochopitelné, v těsném okolí jednoho konkrétního datového bodu se může chovat přibližně lineárně. LIME se tedy nesnaží vysvětlit celý model, ale pouze jeho chování v tomto malém, lokálním sousedství.

Mechanismus funguje následovně :

1. **Výběr instance:** Zvolíme si jeden konkrétní materiál z našich dat, jehož predikci chceme vysvětlit.
2. **Perturbace:** Vytvoříme novou, syntetickou sadu dat tím, že budeme mírně "pozměňovat" (perturbovat) hodnoty deskriptorů naší vybrané instance. Například mírně změníme hodnotu atomového poloměru, přidáme nebo ubereme valenční elektron atd. Tím vygenerujeme stovky nových, fiktivních materiálů, které jsou si s tím původním velmi podobné.
3. **Získání predikcí:** Pro každý z těchto nových, syntetických bodů získáme predikci od našeho původního, složitého modelu černé skříňky.
4. **Vážení:** Každému syntetickému bodu přiřadíme váhu podle toho, jak je blízko naší původní, vysvětlované instanci. Body, které jsou si podobnější, dostanou vyšší váhu.
5. **Trénink lokálního modelu:** Na této nově vytvořené, lokální a zvážené sadě dat natrénujeme jednoduchý, ze své podstaty interpretovatelný "náhradní" model (surrogate model), kterým je typicky lineární regrese nebo mělký rozhodovací strom.

Výsledkem jsou koeficienty tohoto jednoduchého lokálního modelu. Ty nám přesně řeknou, které příznaky v daném konkrétním případě nejvíce přispěly k finální predikci a zda byl jejich vliv pozitivní (zvyšoval predikovanou hodnotu) či negativní (snižoval ji). LIME je skvělý, protože je modelově agnostický a jeho výstupy jsou velmi intuitivní. Jeho slabinou však může být nestabilita – malé změny v procesu perturbace mohou někdy vést k odlišným vysvětlením.

6.2 SHAP (SHapley Additive exPlanations): Spravedlivé rozdělení zásluh

SHAP je další, teoreticky robustnější metoda pro lokální i globální vysvětlení. Je založena na pevných základech kooperativní teorie her, konkrétně na konceptu Shapleyho hodnot. Představme si predikci modelu jako "hru", kde "hráči" jsou jednotlivé příznaky (deskriptory) a

"výhra" je finální predikovaná hodnota. Shapleyho hodnoty poskytují matematicky podložený způsob, jak spravedlivě rozdělit celkovou "výhru" mezi jednotlivé hráče podle jejich příspěvku ke konečnému výsledku.
V kontextu strojového učení SHAP pro každý příznak a pro každou jednotlivou predikci vypočítá hodnotu (SHAP value), která představuje příspěvek tohoto příznaku k posunutí predikce od průměrné predikce celého datasetu (baseline) k finální hodnotě pro daný vzorek. Klíčovou a velmi žádoucí vlastností SHAP je aditivita: součet SHAP hodnot všech příznaků pro danou predikci se přesně rovná rozdílu mezi finální predikcí a průměrnou predikcí.

SHAP nabízí sadu velmi silných a informativních vizualizací:

- **Summary Plots (Beeswarm Plots):** Tyto grafy poskytují globální pohled. Ukazují nejen celkovou důležitost jednotlivých příznaků (seřazených od nejdůležitějšího), ale i distribuci SHAP hodnot pro každý příznak. Z barvy bodů navíc vidíme, zda vysoká hodnota příznaku typicky vede k vysoké nebo nízké predikci.
- **Force Plots / Waterfall Plots:** Tyto grafy vizualizují vysvětlení pro jednu jedinou predikci. Ukazují, jak hodnota každého příznaku "tlačí" predikci od základní průměrné hodnoty (baseline) směrem k finálnímu výsledku. Příznaky s pozitivní SHAP hodnotou (červené) predikci zvyšují, ty s negativní (modré) ji snižují.

6.3 Příklad z materiálových věd: Analýza stability perovskitů

Představme si, že jsme natrénovali XGBoost model, který s vysokou přesností predikuje formační entalpii (klíčový ukazatel termodynamické stability) pro perovskitové sloučeniny. Model nám pro novou, hypotetickou sloučeninu $ABCO_3$ predikuje velmi nízkou (tedy příznivou) formační entalpii, což naznačuje, že by mohla být syntetizovatelná a stabilní. Toto je skvělá zpráva, ale jako vědci chceme vědět, proč.

Použijeme SHAP k vysvětlení této konkrétní predikce. SHAP Waterfall plot nám může odhalit následující:

- Nízká hodnota deskriptoru "elektronegativita prvku na pozici A" měla silnou negativní SHAP hodnotu, což znamená, že silně **tlačila predikci směrem k nižší (stabilnější) entalpii**.
- Hodnota deskriptoru "Goldschmidtův toleranční faktor" blízká 1 měla také silný negativní příspěvek, což je v souladu s krystalochemickou teorií stability perovskitů.
- Naopak velká hodnota deskriptoru "iontový poloměr prvku na pozici B" měla mírně pozitivní SHAP hodnotu, což znamená, že působila mírně **destabilizačně**.

Tímto způsobem získáme hluboký, fyzikálně interpretovatelný vhled do rozhodovacího procesu modelu. Vidíme, že model se nenaučil jen náhodné korelace, ale jeho rozhodnutí je v souladu s našimi doménovými znalostmi, což dramaticky zvyšuje naši důvěru v jeho predikce a může nás navést na nové cesty v návrhu dalších stabilních materiálů.

6.4 Srovnání: LIME vs. SHAP

Obě metody jsou nesmírně užitečné, ale mají odlišné silné a slabé stránky, které shrnuje následující tabulka.

Aspekt	LIME	SHAP
Základní myšlenka	Lokální aproximace pomocí interpretovatelného modelu	Spravedlivé přiřazení příspěvku na základě teorie her
Typ vysvětlení	Pouze lokální	Lokální i globální (agregací lokálních)
Teoretické záruky	Heuristické, může být nestabilní	Silné teoretické základy (aditivita, konzistence)
Rychlost	Obecně rychlejší	Výpočetně náročnější (zejména modelově agnostické verze)
Konzistence	Může být citlivé na nastavení perturbace	Zaručuje konzistentní vysvětlení

Analýza pomocí SHAP může sloužit jako most mezi čistě prediktivním modelováním a skutečným vědeckým objevováním. Zatímco LIME je primárně diagnostický nástroj pro "debugování" jedné konkrétní predikce, SHAP, díky své teoretické robustnosti a schopnosti agregovat lokální vysvětlení do konzistentního globálního pohledu, je něčím víc. Analýzou SHAP hodnot napříč celým datasetem (např. pomocí summary plotů) můžeme odhalit systematické, nelineární vztahy a hlavně interakce mezi příznaky, které se model naučil. Můžeme například zjistit, že vysoká hodnota deskriptoru X má pozitivní vliv na cílovou vlastnost pouze tehdy, když je zároveň nízká hodnota deskriptoru Y. To je objev interakčního jevu, který by byl z jednoduché analýzy neviditelný. Tento objev, vygenerovaný z černé skříňky pomocí SHAP, se může stát základem pro novou, daty podloženou vědeckou hypotézu, kterou lze následně experimentálně ověřit. SHAP tak transformuje XAI z nástroje pro budování důvěry na nástroj pro generování nových znalostí.

Kapitola 7: Závěr a další kroky

7.1 Shrnutí klíčových poznatků

Dnes jsme společně urazili dlouhou a důležitou cestu. Začali jsme u problému přeučení jednotlivých rozhodovacích stromů a ukázali jsme si, jak princip "moudrosti davu" vede k robustním a vysoce výkonným ansámblovým metodám. Představili jsme si dva odlišné přístupy:

- **Random Forest**, demokratický přístup založený na paralelním tréninku nezávislých stromů, který je skvělý pro snížení variance a robustní modelování.
- **Gradient Boosting**, přístup založený na sekvenční týmové práci, kde se každý strom učí z chyb těch předchozích, což vede k extrémně přesným modelům schopným snížit bias.

Uvědomili jsme si, že s rostoucím výkonem těchto modelů roste i jejich neprůhlednost. Tento problém "černé skříňky" je v materiálové vědě, kde je pochopení mechanismů klíčové,

nepřijatelný. Proto jsme se vybavili sadou nástrojů z oblasti vysvětlitelné AI:

- **Feature Importance** (permutační i Gini) pro globální pochopení, které deskriptory jsou pro model nejdůležitější.
- **LIME** pro rychlé a intuitivní lokální vysvětlení jednotlivých predikcí.
- **SHAP** pro teoreticky podložené, konzistentní lokální i globální vysvětlení, které nám umožňuje nejen budovat důvěru, ale i objevovat nové vědecké poznatky.

7.2 Výhled na budoucnost: Od klasických modelů k hlubokému učení

Dnešní nástroje – Random Forest a Gradient Boosting – představují absolutní špičku v klasickém strojovém učení pro tabulková data, která jsou v našem oboru všudypřítomná. Existuje však celá třída problémů, kde tato reprezentace nestačí. Co když chceme pracovat přímo s krystalovou strukturou jako s grafem atomů, nebo s mikrostrukturou jako s obrázkem? V následujících přednáškách proto vstoupíme do světa **neuronových sítí a hlubokého učení**. Seznámíme se s architekturami, které dokáží zpracovávat složitější datové typy. U těchto ještě komplexnějších a výkonnějších modelů se problém černé skříňky stává ještě palčivějším. Principy XAI, které jsme si dnes představili, tak budou naprosto klíčové pro jejich smysluplné využití v našem oboru. Budeme se zabývat i specifickými technikami pro neuronové sítě, jako jsou například **attention mechanisms**, které nám umožňují zjistit, na které části struktury nebo obrazu se model při svém rozhodování nejvíce "dívá". Tím se naše schopnost nahlédnout do stroje posune na další úroveň.

Works cited

1. Ensemble Methods and Wisdom of the Crowd - GeeksforGeeks, https://www.geeksforgeeks.org/machine-learning/ensemble-methods-and-wisdom-of-the-crowd/ 2. Wisdom of the crowd - Wikipedia, https://en.wikipedia.org/wiki/Wisdom_of_the_crowd 3. What Is Bagging? | IBM, https://www.ibm.com/think/topics/bagging 4. Bagging (Bootstrap Aggregation) - Definition, How It Works - Corporate Finance Institute, https://corporatefinanceinstitute.com/resources/data-science/bagging-bootstrap-aggregation/ 5. Bootstrap aggregating - Wikipedia, https://en.wikipedia.org/wiki/Bootstrap_aggregating 6. Random Forest Classification with Scikit-Learn - DataCamp, https://www.datacamp.com/tutorial/random-forests-classifier-python 7. What Is Random Forest? | IBM, https://www.ibm.com/think/topics/random-forest 8. Random forest - Wikipedia, https://en.wikipedia.org/wiki/Random_forest 9. [2307.06879] Machine Learning Predictions of High-Curie-Temperature Materials - arXiv, https://arxiv.org/abs/2307.06879 10. [2506.01994] Re-experiment Smart: a Novel Method to Enhance Data-driven Prediction of Mechanical Properties of Epoxy Polymers - arXiv, https://arxiv.org/abs/2506.01994 11. [2406.15650] Machine Learning Materials Properties with Accurate Predictions, Uncertainty Estimates, Domain Guidance, and Persistent Online Accessibility - arXiv, https://arxiv.org/abs/2406.15650 12. What Is Boosting? | IBM, https://www.ibm.com/think/topics/boosting 13. Boosting (machine learning) - Wikipedia, https://en.wikipedia.org/wiki/Boosting_(machine_learning) 14. developers.google.com, https://developers.google.com/machine-learning/decision-forests/intro-to-gbdt#:~:text=Gradient%20boosting%20creates%20a%20strong,model%20to%20improve%20its%20accuracy. 15.

Gradient Boosted Decision Trees | Machine Learning - Google for Developers, https://developers.google.com/machine-learning/decision-forests/intro-to-gbdt 16. Gradient boosting - Wikipedia, https://en.wikipedia.org/wiki/Gradient_boosting 17. An intuitive explanation of gradient boosting, https://www.cse.chalmers.se/~richajo/dit866/files/gb_explainer.pdf 18. Comprehensive Guide to Understanding Gradient Boosting in Machine Learning - Medium, https://medium.com/@piyushkashyap045/comprehensive-guide-to-understanding-gradient-boosting-in-machine-learning-2cbbe048853c 19. Gradient boosting: frequently asked questions - explained.ai, https://explained.ai/gradient-boosting/faq.html 20. A machine learning method based on TPE-XGBoost model for TRIP/TWIP near-β titanium alloy design - ResearchGate, https://www.researchgate.net/publication/383762178_A_machine_learning_method_based_on_TPE-XGBoost_model_for_TRIPTWIP_near-b_titanium_alloy_design 21. XGBoost: An Optimal Machine Learning Model with Just Structural Features to Discover MOF Adsorbents of Xe/Kr, https://pmc.ncbi.nlm.nih.gov/articles/PMC8028164/ 22. XGBoost vs. LightGBM vs. CatBoost - ApX Machine Learning, https://apxml.com/posts/xgboost-vs-lightgbm-vs-catboost 23. (PDF) A Comparative Analysis of XGBoost - ResearchGate, https://www.researchgate.net/publication/337048557_A_Comparative_Analysis_of_XGBoost 24. Why AI is a "Black Box" – And Why It Doesn't Work Like a Human Brain - Reddit, https://www.reddit.com/r/ArtificialInteligence/comments/1kph5tc/why_ai_is_a_black_box_and_why_it_doesnt_work_like/ 25. Black box - Wikipedia, https://en.wikipedia.org/wiki/Black_box 26. What Is Black Box AI and How Does It Work? | IBM, https://www.ibm.com/think/topics/black-box-ai 27. www.qlik.com, https://www.qlik.com/us/augmented-analytics/explainable-ai#:~:text=Explainable%20AI%20(XAI)%20refers%20to,AI%20models'%20decisions%20and%20predictions. 28. What is Explainable AI (XAI)? | IBM, https://www.ibm.com/think/topics/explainable-ai 29. What is Explainable AI? Benefits & Best Practices - Qlik, https://www.qlik.com/us/augmented-analytics/explainable-ai 30. Random Forest Feature Importance Computed in 3 Ways with Python - MLJAR Studio, https://mljar.com/blog/feature-importance-in-random-forest/ 31. Using Random Forest For Feature Importance And Feature Selection | by Prasanna Ghattikar | Medium, https://medium.com/@prasannarghattikar/using-random-forest-for-feature-importance-118462c40189 32. 23 Permutation Feature Importance – Interpretable Machine Learning - Christoph Molnar, https://christophm.github.io/interpretable-ml-book/feature-importance.html 33. c3.ai, https://c3.ai/glossary/data-science/lime-local-interpretable-model-agnostic-explanations/#:~:text=What%20is%20Local%20Interpretable%20Model,to%20explain%20each%20individual%20prediction. 34. LIME: Local Interpretable Model-Agnostic Explanations - C3 AI, https://c3.ai/glossary/data-science/lime-local-interpretable-model-agnostic-explanations/ 35. Techniques for Explainable AI: LIME and SHAP - Unnat Bak (Founder @ Revscale, TABS Suite) Growth Hacking and Venture Advisory, https://www.unnatbak.com/blog/techniques-for-explainable-ai-lime-and-shap 36. 14 LIME – Interpretable Machine Learning, https://christophm.github.io/interpretable-ml-book/lime.html 37. How LIME works | Understanding in 5 steps - Openlayer, https://www.openlayer.com/blog/post/understanding-lime-in-5-steps 38. Local Interpretable Model-agnostic Explanations — InterpretML documentation, https://interpret.ml/docs/lime.html 39. An introduction to explainable artificial intelligence with LIME and SHAP, https://diposit.ub.edu/dspace/bitstream/2445/192075/1/tfg_nieto_juscafresa_aleix.pdf 40. What is SHAP (Shapley Additive Explanations)? - Milvus, https://milvus.io/ai-quick-reference/what-is-shap-shapley-additive-explanations 41. Welcome to the SHAP documentation — SHAP latest documentation, https://shap.readthedocs.io/ 42. An introduction to explainable AI with Shapley values — SHAP latest documentation,

https://shap.readthedocs.io/en/latest/example_notebooks/overviews/An%20introduction%20to%20explainable%20AI%20with%20Shapley%20values.html 43. Explainable AI for Material Science Interpretability, https://atomfair.com/semiconductor-material-primer/article.php?id=G106-2090 44. The emergent role of explainable artificial intelligence in the materials sciences | Request PDF - ResearchGate, https://www.researchgate.net/publication/374594346_The_emergent_role_of_explainable_artificial_intelligence_in_the_materials_sciences 45. Explainable AI for Material Property Prediction Based on Energy Cloud: A Shapley-Driven Approach - PubMed Central, https://pmc.ncbi.nlm.nih.gov/articles/PMC10706902/ 46. A Perspective on Explainable Artificial Intelligence Methods: SHAP and LIME - arXiv, https://arxiv.org/html/2305.02012v3