Přednáška 10: Grafové Neuronové Sítě (GNN) – Revoluce v Atomistických Simulacích

Kapitola 1: Most z přednášky 9 – Proč CNN selhává na atomech?

Vítám vás na desáté přednášce. Minulý týden, v **přednášce 9**, jsme detailně prozkoumali Konvoluční neuronové sítě (CNN). Pochopili jsme, že jejich genialita spočívá v zavedení tzv. „induktivních předsudků“ (inductive biases), které dokonale odrážejí povahu obrazových dat: princip **lokality** (zpracování okolí pomocí malých filtrů/kernelů) a **sdílení vah** (které vede k translační ekvivarianci).

Díky těmto vlastnostem jsou CNN absolutními mistry ve zpracování dat, která existují na **pravidelné euklidovské mřížce** – ať už jde o 2D pixely v obraze mikrostruktury nebo 3D voxely v tomografickém skenu.

Jak jsme si ale řekli v samém závěru minulé přednášky, tento fundamentální předpoklad pravidelné mřížky je zároveň největší slabinou CNN. Položili jsme si klíčovou otázku: „Co ale data, která nemají strukturu mřížky? Co data, která jsou definována vztahy mezi entitami?“.

Krystalová struktura není obraz

Krystalová struktura nebo molekula *není* pravidelná mřížka pixelů. Je to ze své podstaty **graf** – soubor entit (atomů) propojených komplexními vztahy (vazbami nebo prostorovými interakcemi). V terminologii datové vědy jsou atomy **uzly (nodes)** a jejich vzájemné vztahy jsou **hrany (edges)**.

Pokus aplikovat architekturu CNN přímo na taková data selhává ze dvou zásadních topologických a fyzikálních důvodů:

1. **Problém pevného filtru vs. proměnného koordinačního čísla:** Standardní 3x3x3 konvoluční filtr, jak jsme ho definovali v **přednášce 9**, předpokládá, že každý bod v mřížce má pevně daný, uniformní počet sousedů (např. 26 sousedů ve 3D mřížce). V reálné chemii je však počet sousedů atomu – jeho **koordinační číslo** – proměnný a definuje jeho vlastnosti. Uhlík v diamantu má 4 sousedy, v grafenu 3, v acetylenu 2. Nelze na ně aplikovat stejný pevný 3x3 filtr.

2. **Problém chybějící invariance:** CNN je *ekvivariantní vůči translaci* (posunu). Pokud se ale vstupní data **otočí (rotace)** nebo pokud atomy v seznamu pouze **přeznačíme (permutace)**, CNN bude tato data vnímat jako zcela nový, odlišný objekt. To je fundamentálně fyzikálně špatně. Energie systému se nesmí změnit, pokud jej otočíme v prostoru nebo pokud prohodíme indexy atomu #1 a atomu #2.

Potřebujeme tedy zcela jinou architekturu. Architekturu, která je pro grafy „nativní“. Architekturu, jejíž induktivní předsudky neodrážejí pravidla fotografie, ale **základní fyzikální zákony**.
Touto architekturou je **Grafová Neuronová Síť (Graph Neural Network, GNN)**.

Kapitola 2: Motivace – Revoluce v simulacích (MLIPs)

Než se ponoříme do architektury GNN, musíme pochopit, proč je jejich aplikace v materiálové vědě tak transformační. Klíčová aplikace, která mění pravidla hry, je tvorba **Strojově učených meziatomových potenciálů (MLIPs)**.

Dilema výpočetní vědy o materiálech

Naše pole je desítky let rozpolceno mezi dvěma extrémy, které definují kompromis mezi přesností a výpočetními náklady.

1. **Vysoká přesnost, extrémní cena: Kvantová mechanika (DFT)**
   - **Princip:** Metody jako Teorie funkcionálu hustoty (DFT) se snaží řešit (byť přibližně) Schrödingerovu rovnici. Poskytují „zlatý standard“ přesnosti a umožňují nám vypočítat energie, síly na atomy a elektronové vlastnosti materiálů *ab initio* (z prvních principů).
   - **Cena:** Výpočetní náročnost škáluje katastrofálně, typicky jako $O(N^3)$ nebo $O(N^4)$, kde N je počet atomů. DFT simulace jsou proto omezeny na stovky, maximálně tisíce atomů, a na časové škály pikosekund (10^{-12} s). To zdaleka nestačí k pozorování mnoha reálných jevů, jako je difúze, fázové transformace nebo růst zrn.

2. **Nízká přesnost, nízká cena: Klasické potenciály (Force Fields, FF)**
   - **Princip:** Jedná se o analytické, ručně odvozené rovnice (např. potenciál Lennarda-Jonese nebo EAM), které popisují interakce mezi atomy zjednodušenou formou.
   - **Cena:** Jsou extrémně rychlé, škálují lineárně O(N). Umožňují simulovat miliardy atomů po dobu mikrosekund (10^{-6} s).
   - **Problém:** Jsou nepřesné a hlavně **nepřenositelné**. Potenciál vyvinutý pro čistý křemík zcela selže, pokud do systému přidáte kyslík nebo pokud se křemík dostane do jiné fáze. Jejich vývoj je navíc náročný a vyžaduje hlubokou expertní intuici.

Řešení: MLIPs jako surrogátní modely

Tato situace vytváří jasnou potřebu: hledáme „svatý grál“ simulací. Chceme metodu, která má **přesnost DFT, ale běží rychlostí klasických potenciálů**.

Řešením je vytvořit **surrogátní model**. Místo abychom se snažili odvodit zjednodušenou *analytickou* rovnici (jako u FF), použijeme flexibilitu neuronových sítí k *naučení* komplexního vztahu mezi polohou atomů a jejich kvantově-mechanickou energií.

Tomuto modelu říkáme **Strojově Učený Meziatomový Potenciál (Machine Learning Interatomic Potential, MLIP)**.

Princip tréninku MLIP:

1. **Generování dat:** Provedeme tisíce malých, ale výpočetně drahých DFT výpočtů pro různé konfigurace atomů (např. mírně deformovaný krystal, povrch, molekula). Tím získáme trénovací databázi ve formátu: [Vstupy: seznam atomů a jejich pozic] -> [Výstupy: celková energie systému a síly na každý atom].
2. **Trénink:** Na této databázi natrénujeme model hlubokého učení (GNN), aby se naučil mapování Struktura -> (Energie, Síly).
3. **Nasazení:** Jakmile je model natrénován, samotná predikce (inference) je extrémně rychlá, často škáluje lineárně O(N). Tento natrénovaný model nyní můžeme použít v masivních simulacích molekulární dynamiky (MD) se statisíci či miliony atomů, přičemž každý krok simulace má *de facto* přesnost DFT.

Toto je revoluce v atomistickém modelování. Následující tabulka shrnuje tento zásadní kompromis.

Tabulka 10.1: Srovnání simulačních metod v materiálové vědě

Metoda	Hlavní princip	Přesnost	Výpočetní náročnost	Typické měřítko (Atomy / Čas)
Kvantová mechanika (DFT)	Řeší Schrödingerovu rovnici	Velmi vysoká	Extrémní ($O(N^3)$ - $O(N^4)$)	~10^2 atomů / ~ps
Klasické potenciály (FF)	Ručně odvozené rovnice	Nízká, nepřenositelné	Velmi nízká (O(N))	~10^9 atomů / ~μs
MLIPs (GNN)	Surrogátní model trénovaný na DFT	**Velmi vysoká (jako DFT)**	**Nízká (O(N))**	**~10^6 atomů / ~ns**

Kapitola 3: GNN jako motor pro MLIPs

Položili jsme si otázku, proč jsou GNN (a ne třeba základní MLP z **přednášky 8**) tím dokonalým motorem pro tvorbu MLIPs.

Odpověď je elegantní: GNN jsou úspěšné, protože jejich architektura má v sobě **zabudované fundamentální fyzikální zákony (symetrie)**. Model se tyto zákony nemusí pracně učit z dat (což by vyžadovalo enormní množství dat), on jim „rozumí“ ze své podstaty.
GNN pro MLIPs musí respektovat tři klíčové symetrie:

1. Permutační invariance

- **Fyzika:** Celková energie systému je vlastností *systému*, nikoli vlastností našeho seznamu atomů. Pokud máme krystal s 1000 atomy, jeho energie (např. -500 eV) musí být stejná bez ohledu na to, jestli atom v levém rohu označíme jako #1 a atom v pravém rohu jako #1000, nebo naopak. Na pořadí (permutaci) atomů v našem seznamu nesmí záležet.

- **Jak to GNN dělá:** Architektura GNN je navržena tak, že nejprve vypočítá lokální příspěvek k energii E_i pro každý atom *i* na základě jeho okolí. Celková energie systému E_{total} je pak definována jako prostá **agregace (součet)** všech těchto příspěvků. Protože operace sčítání je komutativní ($E_1 + E_2 = E_2 + E_1$), je výsledná energie automaticky a ze své definice **permutačně invariantní**.

2. Translační a Rotační invariance

- **Fyzika:** Vnitřní energie systému se nesmí změnit, pokud celý systém jako celek **posuneme** o 10 Å doprava (translace), nebo jej **otočíme** o 90 stupňů (rotace).

- **Jak to GNN dělá (Základní přístup):** Nejjednodušší způsob, jak toto zajistit, je nekrmit síť absolutními souřadnicemi (x, y, z), které se při rotaci mění. Místo toho síti poskytneme pouze **invariantní deskriptory**. Nejzákladnějším invariantním deskriptorem je **vzdálenost** mezi dvěma atomy r_{ij}. Vzdálenost je z definice invariantní vůči translaci i rotaci. Modely jako SchNet (viz Kapitola 4) jsou postaveny primárně na této myšlence.

- **Pokročilý přístup (Ekvivariance):** Použití *pouze* invariantních deskriptorů (jako jsou vzdálenosti) je sice funkční, ale zároveň plýtvá informacemi – zahazujeme veškerou 3D informaci o směrech a úhlech. Moderní, nejpřesnější GNN proto pracují na principu **E(3) ekvivariance**. To znamená, že interní reprezentace (vektory a tenzory) *uvnitř* sítě se **otáčejí společně se vstupem**. Model si je plně vědom 3D prostoru a orientace v každém kroku. Teprve na samém konci je tato ekvivariantní 3D reprezentace „zkolabována“ (zkontrahována) do jediného *invariantního* čísla (energie). Tyto modely jsou datově efektivnější, protože se „učí fyziku“ na hlubší úrovni.

3. Lokalita

- **Fyzika:** Většina chemických interakcí je lokální. Energie a síly působící na daný atom jsou téměř výhradně určeny jeho bezprostředním chemickým okolím (atomy do vzdálenosti několika Ångströmů).

- **Jak to GNN dělá:** Architektura GNN je ze své podstaty lokální. Operuje na principu sousedství – atom komunikuje (předává si zprávy) pouze se svými sousedy v definovaném „cutoff“ okruhu.

Princip (Jak?): "Message Passing" (Předávání zpráv)

Jak tedy GNN konkrétně buduje reprezentaci lokálního chemického prostředí? Používá intuitivní algoritmus nazvaný **"Message Passing" (Předávání zpráv)**.

Představme si centrální atom *i*, který chceme popsat:

- **Krok 0: Inicializace** Každý atom *i* v systému je inicializován jako vektor příznaků. Ten typicky kóduje pouze jeho chemickou identitu.
- **Krok 1: Tvorba zpráv (Message)** Atom *i* se „podívá“ na všechny své sousedy *j* (atomy uvnitř cutoff vzdálenosti). Pro každého souseda *j* vytvoří „zprávu“ m_ij. Tato zpráva je neuronovou sítí vypočítaná funkce, která kombinuje stav atomu *i*, stav souseda *j* a jejich vztah.
- **Krok 2: Agregace zpráv (Aggregate)** Atom *i* nyní „shromáždí“ všechny zprávy, které mu přišly od všech jeho sousedů (m_1i, m_2i, …), a sloučí je (agreguje) do jediného vektoru m_i. Tato agregace musí být permutačně invariantní (nezáleží na pořadí sousedů), takže se typicky používá **součet**.
- **Krok 3: Aktualizace stavu (Update)** Nakonec atom *i* vezme svůj starý stav a agregované zprávy m_i a pomocí další malé neuronové sítě je zkombinuje, aby vytvořil svůj nový, bohatší stav.

Tento tříkrokový cyklus (Message -> Aggregate -> Update) se opakuje L-krát (což odpovídá L vrstvám GNN).

S každou iterací se atom „dozví“ informace ze vzdálenějšího okolí.

- Po 1. kroku, vektor obsahuje informace o přímých sousedech atomu *i*.
- Po 2. kroku, atom *i* přijal zprávy od svých sousedů, kteří mu „řekli“ o *svých* sousedech. Vektor tedy obsahuje informace i o „sousedech sousedů“.

Toto je přímá analogie „receptivního pole“ (receptive field), které jsme viděli u CNN v **přednášce 9**. Po L krocích je finální vektor bohatým, naučeným deskriptorem, který kóduje celé lokální chemické prostředí atomu *i* až do L „skoků“ daleko.

Tento finální vektor je pak použit k predikci příspěvku atomu *i* k celkové energii E_i. A jak jsme již řekli, celková energie je jejich permutačně invariantní součet E_total.

Kapitola 4: Architektury a nástroje pro materiály

Zatímco princip "message passing" je obecný, existuje mnoho specifických architektur. Krátce zmíníme obecné „akademické“ modely, o kterých můžete slyšet:

- **GCN (Graph Convolutional Networks):** Základní model, který v kroku agregace jednoduše zprůměruje příznaky sousedů. Pro komplexní chemii a MLIPs je příliš jednoduchý.
- **GAT (Graph Attention Networks):** Vylepšení GCN, které používá mechanismus „pozornosti“ (attention) k tomu, aby se naučilo dávat různým sousedům různou váhu (důležitost).

V materiálové vědě se však zaměřujeme na modely navržené speciálně pro 3D atomární struktury a tvorbu MLIPs.

SchNet / SchNetPack

SchNet (a jeho implementace v balíčku SchNetPack) byl jedním z prvních a dodnes je velmi populárním GNN potenciálem.

- **Klíčová myšlenka:** Místo aby operoval na diskrétních hranách (vazbách), SchNet používá **spojité konvoluční filtry** založené na **vzdálenostech** atomů. To elegantně řeší problém, že atomy nemají pevné vazby, ale spíše spojité interakce.

- **Architektura:** Jak ukazuje výzkum, modely ve SchNetPack mají dvě hlavní komponenty:
    1. **Representation Block (Blok reprezentace):** Vezme vstupní atomové pozice a typy. Pomocí série interakčních bloků (které implementují "message passing" založený na vzdálenostech) postupně vylepšuje atomové reprezentace, dokud nedosáhne finálního stavu.
    2. **Prediction Block (Blok predikce):** Vezme tyto finální, bohaté reprezentace a pomocí agregace (součtu) a malé neuronové sítě predikuje celkovou energii systému.

M3GNet (Materials 3-body Graph Network)

M3GNet je moderní, vysoce výkonná architektura, která posouvá fyzikální přesnost GNN na další úroveň.

- **Klíčová inovace:** Většina starších modelů, včetně SchNet, primárně modeluje **2-částicové interakce** (informace založené na vzdálenostech r_ij). Pro chemii a materiály je ale zásadní informace o **úhlech mezi vazbami**, což je **3-částicová interakce** (závisí na třech atomech i, j, k).

- **Jak to dělá:** Jak název napovídá, M3GNet **explicitně a efektivně zahrnuje 3-částicové**

informace (úhly) přímo do procesu "message passing". Během aktualizace reprezentací model explicitně počítá interakce tří těles a integruje je do zpráv.

- **Výsledek:** Díky tomuto mnohem bohatšímu fyzikálnímu popisu lokálního prostředí dosahuje M3GNet špičkové přesnosti a je schopen fungovat jako robustní, „univerzální“ potenciál pro širokou škálu chemických systémů.

Kapitola 5: Závěr a výhled na příští týden

Dnes jsme společně udělali klíčový krok v našem porozumění AI architekturám.

1. **Shrnutí:** Zvládli jsme přechod od dat na pravidelné mřížce (která jsme řešili pomocí CNN v **přednášce 9**) k datům definovaným vztahy a konektivitou (která řešíme pomocí GNN).

2. **Aplikace:** Pochopili jsme, proč jsou GNN ideálním nástrojem pro řešení zásadního „dilematu“ v molekulárních simulacích. Tvorba MLIPs pomocí GNN nám umožňuje dosáhnout **přesnosti DFT rychlostí klasických potenciálů**.

3. **Princip:** Naučili jsme se, že GNN jsou tak úspěšné, protože jejich architektura (založená na "message passing" a agregaci) má v sobě od základu zabudované fundamentální fyzikální symetrie: **invarianci vůči permutaci, translaci a rotaci**.

Navázání na Přednášku 11: Chybějící dimenze dat

Dosud jsme pokryli dvě hlavní domény dat v materiálové vědě:
1. **Prostorová data** (Obrazy mikrostruktur) -> **CNN** (Přednáška 9)
2. **Relační data** (Atomární grafy) -> **GNN** (Přednáška 10)

Co ale data, jejichž význam není dán jen polohou v mřížce nebo konektivitou v grafu, ale především jejich **pořadím** a **kontextem v sekvenci**?

Příklady v našem oboru jsou všudypřítomné:
- **Spektra (XRD, Raman, EELS):** Spektrum je sekvence datových bodů. Význam (pík) není dán jedním bodem, ale jeho tvarem a kontextem okolních bodů v celé sekvenci.
- **Časové řady:** Vývoj energie, teploty nebo tlaku v průběhu MD simulace je sekvence hodnot v čase.
- **Vědecká literatura (NLP):** Nejbohatší, ale nejméně strukturovaný zdroj dat. Věta „Slitina Ti-6Al-4V vykazuje vysokou pevnost“ je sekvence slov (tokenů). Význam slova „pevnost“ je dán kontextem celé věty a celého článku.

Pro tento typ dat potřebujeme modely, které mají „paměť“ nebo chápou kontext celé sekvence. **Příští týden v přednášce 11** se proto podíváme na architektury navržené pro sekvenční data.

Začneme krátkým pohledem na historický přístup, **Rekurentní neuronové sítě (RNN)** a jejich vlivnou variantu LSTM. Okamžitě ale přejdeme k moderní a mnohem výkonnější architektuře, která dnes dominuje všemu, od zpracování jazyka po biologii: **Transformery**. Ukážeme si, jak modely jako BERT a jejich materiálově specifické varianty (např. MaterialBERT) dokáží „číst“ vědeckou literaturu a automaticky z ní extrahovat cenné znalosti.

Works cited

1. A Gentle Introduction to Graph Neural Networks - Distill.pub, https://distill.pub/2021/gnn-intro/ 2. Efficient Machine Learning Force Field for Large-Scale Molecular ..., https://www.chinesechemsoc.org/doi/10.31635/ccschem.024.202404785 3. A Benchmark for Quantum Chemistry Relaxations via Machine Learning Interatomic Potentials - arXiv, https://arxiv.org/html/2506.23008v2 4. Machine learning interatomic potential: Bridge the gap between small-scale models and realistic device-scale simulations - PMC, https://pmc.ncbi.nlm.nih.gov/articles/PMC11033164/ 5. Machine Learning Force Fields | Chemical Reviews, https://pubs.acs.org/doi/10.1021/acs.chemrev.0c01111 6. Equivariant Machine Learning Interatomic Potentials with Global Charge Redistribution, https://arxiv.org/html/2503.17949v1 7. Efficient moment tensor machine-learning interatomic potential for accurate description of defects in Ni-Al Alloys | Phys. Rev. Materials, https://link.aps.org/doi/10.1103/PhysRevMaterials.9.053805 8. Machine Learning of Force Fields for Molecular Dynamics Simulations of Proteins at DFT Accuracy | InstaDeep - Decision-Making AI For The Enterprise, https://instadeep.com/research/paper/machine-learning-of-force-fields-for-molecular-dynamics-simulations-of-proteins-at-dft-accuracy/ 9. Machine Learning Interatomic Potentials and Long-Range Physics - ACS Publications, https://pubs.acs.org/doi/10.1021/acs.jpca.2c06778 10. Spin-dependent graph neural network potential for magnetic materials | Phys. Rev. B, https://link.aps.org/doi/10.1103/PhysRevB.109.144426 11. Geometry-enhanced Pretraining on Interatomic Potentials, https://img.shlab.org.cn/pjlab/files/2024/04/638488787740580000.pdf 12. Fast and Fourier features for transfer learning of interatomic ..., https://pmc.ncbi.nlm.nih.gov/articles/PMC12463661/ 13. 8. Graph Neural Networks — deep learning for molecules & materials, https://dmol.pub/dl/gnn.html 14. Graph Neural Networks for Sustainable Energy: Predicting ... - MDPI, https://www.mdpi.com/2305-7084/9/4/85 15. Scaling Laws of Graph Neural Networks for Atomistic Materials Modeling∗ - arXiv, https://arxiv.org/html/2504.08112v1 16. Understanding the Capabilities of Molecular Graph Neural Networks in Materials Science Through Multimodal Learning and Physical Context Encoding - arXiv, https://arxiv.org/html/2505.12137v1 17. Data Generation for Machine Learning Interatomic Potentials and Beyond | Chemical Reviews - ACS Publications, https://pubs.acs.org/doi/10.1021/acs.chemrev.4c00572 18. SchNetPack: A Deep Learning Toolbox For Atomistic Systems ..., https://pubs.acs.org/doi/10.1021/acs.jctc.8b00908 19. The principles behind equivariant neural networks for physics and chemistry - PNAS, https://www.pnas.org/doi/10.1073/pnas.2415656122 20. Graph Neural Network for Unified Electronic and Interatomic Potentials: Strain-tunable Electronic Structures in 2D Materials - arXiv, https://arxiv.org/html/2510.16605v1 21. T036 · An introduction to E(3)-invariant graph neural networks - volkamerlab.github.io, https://projects.volkamerlab.org/teachopencadd/talktorials/T036_e3_equivariant_gnn.html 22. E(n) Equivariant Graph Neural Network for Learning Interactional Properties of Molecules | The

Journal of Physical Chemistry B - ACS Publications, https://pubs.acs.org/doi/10.1021/acs.jpcb.3c07304 23. Learning local equivariant representations for large-scale atomistic dynamics - PMC, https://pmc.ncbi.nlm.nih.gov/articles/PMC9898554/ 24. Optimal message passing for molecular prediction is simple, attentive and spatial - arXiv, https://arxiv.org/html/2509.10871v1/ 25. Flexible Dual-Branched Message-Passing Neural Network for a Molecular Property Prediction | ACS Omega - ACS Publications, https://pubs.acs.org/doi/10.1021/acsomega.1c05877 26. Towards Causal Classification: A Comprehensive Study on Graph Neural Networks - arXiv, https://arxiv.org/html/2401.15444v1 27. Materials fatigue prediction using graph neural networks on microstructure representations - PMC - PubMed Central, https://pmc.ncbi.nlm.nih.gov/articles/PMC10397301/ 28. Comprehensive Guide to GNN, GAT, and GCN: A Beginner's Introduction to Graph Neural Networks After Reading 11 GNN Papers | by Joyce Birkins | Medium, https://medium.com/@joycebirkins/comprehensive-guide-to-gnn-gat-and-gcn-a-beginners-introduction-to-graph-neural-networks-after-51d09ac043b5 29. Graph neural networks for materials science and chemistry - PubMed, https://pubmed.ncbi.nlm.nih.gov/36468086/ 30. Can anyone explain SchNetPack Model in Deep Learning ,Share your experience in using that Model,Its Algorithm ..Etc.? | ResearchGate, https://www.researchgate.net/post/Can_anyone_explain_SchNetPack_Model_in_Deep_Learning_Share_your_experience_in_using_that_Model_Its_Algorithm_Etc 31. M3GNet — m3gnet documentation, https://materialsvirtuallab.github.io/m3gnet/ 32. Data-Efficient Construction of High-Fidelity Graph Deep Learning Interatomic Potentials, https://arxiv.org/html/2409.00957v1 33. CCMS Summer Institute Lecture 2022 - Mathematical Graphs as a Representation for Materials - YouTube, https://www.youtube.com/watch?v=RiAKIaWY_iM 34. A universal graph deep learning interatomic potential for the periodic table - Materials Virtual Lab, https://materialsvirtuallab.org/pubs/10.1038_s43588-022-00349-3.pdf 35. Theoretical foundation of M3GNET — Zhengda Notes 0.1 ..., https://hezhengda.me/en/latest/ML_potential/MatGL/MatGL_theory.html 36. An Introduction To Deep Learning For Sequential Data - Towards Data Science, https://towardsdatascience.com/an-introduction-to-deep-learning-for-sequential-data-ac966b9b9b67/ 37. Delve into Sequences: Understanding the Power of Sequential Data in Machine Learning, https://medium.com/the-power-of-ai/delve-into-sequences-understanding-the-power-of-sequential-data-in-machine-learning-b1511cb669a8 38. Understanding the patterns that neural networks learn from chemical spectra - ChemRxiv, https://chemrxiv.org/engage/chemrxiv/article-details/640afb506642bf8c8f484b38 39. Automatic materials characterization from infrared spectra using convolutional neural networks - Chemical Science (RSC Publishing), https://pubs.rsc.org/en/content/articlelanding/2023/sc/d2sc05892h 40. Predicting optical spectra for optoelectronic polymers using coarse ..., https://www.pnas.org/doi/10.1073/pnas.1918696117 41. Sequential Machine Learning in Material Science - DiVA portal, http://www.diva-portal.org/smash/get/diva2:1800253/FULLTEXT01.pdf 42. Deep language models for interpretative and predictive materials science - AIP Publishing, https://pubs.aip.org/aip/aml/article/1/1/010901/2878738/Deep-language-models-for-interpretative-and 43. Full article: MaterialBERT for natural language processing of materials science texts, https://www.tandfonline.com/doi/full/10.1080/27660400.2022.2124831 44. Revolutionizing Materials Science with NLP: Introducing MatSci-NLP and HoneyBee | Mila, https://mila.quebec/en/article/revolutionizing-materials-science-with-nlp-introducing-matsci-nlp-a

nd-honeybee 45. AI system learns from many types of scientific information and runs experiments to discover new materials, https://dmse.mit.edu/news/ai-system-learns-from-many-types-of-scientific-information-and-runs-experiments-to-discover-new-materials/ 46. MaterialBERT for Natural Language Processing of Materials ..., https://jxiv.jst.go.jp/index.php/jxiv/preprint/download/119/677/509