Přednáška 12: Od černé skříňky k vědecké AI – Fyzikálně informované sítě a kvantifikace nejistoty

Kapitola 1: Most z přednášky 11 – Krize důvěry a dvě chybějící ingredience

Vážení studenti a kolegové,
vítám vás u dvanácté, předposlední lekce našeho cyklu "AI v materiálovém inženýrství".

Nacházíme se v bodě, který bychom mohli nazvat "údolím vystřízlivění". Minulý týden, v **přednášce 11**, jsme vystoupali na technologický vrchol. Zvládli jsme architektury, které dnes hýbou světem – Rekurentní neuronové sítě (RNN) a především Transformery. Viděli jsme, jak modely jako MatBERT dokáží s nadlidskou rychlostí "číst" statisíce vědeckých článků, extrahovat z nich vztahy mezi složením a vlastnostmi a jak díky strategii Transfer Learningu můžeme tuto "všeobecnou materiálovou inteligenci" přenést na naše specifické, často datově chudé problémy.

Máme tedy v rukou nástroje s ohromující prediktivní silou. Modely, které dokáží z rentgenového spektra určit krystalovou fázi lépe než zkušený krystalograf, nebo modely, které navrhnou složení slitiny s pevností, o jaké se nám před deseti lety nesnilo. Přesto, když s těmito modely přijdete za hlavním inženýrem v leteckém průmyslu nebo za vedoucím bezpečnosti v jaderné elektrárně, pravděpodobně vás s nimi vyhodí. Proč? Protože navzdory své "inteligenci" sdílejí všechny tyto architektury – od jednoduchých MLP, přes konvoluční sítě (CNN) pro analýzu mikrostruktur, až po grafové sítě (GNN) pro atomární simulace – dvě fundamentální, kritické slabiny. V očích konzervativní vědy jsou to stále jen nedůvěryhodné "černé skříňky".

Dnešní přednáška je věnována překonání této propasti. Je to moment, kdy se přestáváme ptát "jak dosáhnout nejvyšší přesnosti na trénovacích datech" a začínáme se ptát "jak vytvořit model, kterému můžeme svěřit životy a kritickou infrastrukturu". Budeme řešit dva existenční problémy moderní AI:

1. **Problém fyzikální konzistence (The Physics Consistency Problem):** Naše dosavadní modely jsou agnostické vůči realitě. Jsou řízené čistě daty (data-driven). Minimalizují statistickou chybu, ale nemají žádné vnitřní ponětí o zákonech zachování energie, hmoty, hybnosti nebo o termodynamických limitech. Model může klidně předpovědět negativní teplotu v Kelvinech nebo vznik hmoty z ničeho, pokud ho k tomu šum v datech svede. Jak můžeme neuronovou síť donutit, aby respektovala diferenciální rovnice, které vládnou našemu vesmíru, i v oblastech, kde nemáme data? Odpovědí, která mění paradigma vědeckých výpočtů, jsou **Fyzikálně Informované Neuronové Sítě (PINNs)**.

2. **Problém falešné jistoty (The False Confidence Problem):** Standardní hluboké sítě jsou z principu deterministické a často arogantní. Poskytují nám tzv. bodové odhady (point estimates). Model řekne: "Únavová životnost této součástky je 15 000 cyklů." Tečka. Ale v inženýrství je číslo bez kontextu bezcenné. Znamená to 15 000 ± 10 cyklů, nebo 15 000 ± 10 000 cyklů? Standardní sítě neumí říct "nevím". V oblastech extrapolace, daleko od trénovacích dat, často s bohorovným klidem predikují nesmysly. Jak naučíme síť kvantifikovat svou vlastní pochybnost? Odpovědí je **Bayesovské hluboké učení (BNN)** a praktické techniky jako **Monte Carlo Dropout**.

Tato přednáška představuje přechod od "čistého strojového učení" k "vědeckému strojovému učení" (Scientific Machine Learning - SciML). Je to disciplína, kde se datová věda nesnaží fyziku nahradit, ale kde se s ní snoubí v symbiotickém vztahu.

Kapitola 2: Řešení otázky #1 – Fyzikálně Informované Neuronové Sítě (PINNs)

2.1 Motivace: Konec diktatury velkých dat

V klasickém hlubokém učení platí mantra: "Data jsou nové ropné bohatství." Čím více dat máte, tím lepší model získáte. Pokud data nemáte, končíte. V materiálové vědě a inženýrství se však často nacházíme v situaci, která je pro klasické DL ("Deep Learning") smrtící. Naše data jsou "drahá, řídká a zašuměná" (expensive, sparse, noisy). Získání jednoho datového bodu může znamenat týdenní experiment na synchrotronu nebo měsíc výpočtů na superpočítači.

Nemůžeme si dovolit natrénovat model na milionech příkladů, jako to dělá Google s obrázky koček.

Máme však něco, co Google nemá. Máme staletími prověřené fyzikální teorie. Máme Navier-Stokesovy rovnice pro proudění tekutin, Schrödingerovu rovnici pro kvantové jevy, rovnice vedení tepla a difúze (Fickovy zákony). Tyto rovnice představují "apriorní znalost" s nekonečnou informační hodnotou. Tradiční numerické metody (jako FEM - Metoda konečných prvků) tyto rovnice řeší, ale neumí využít experimentální data. Tradiční neuronové sítě využívají data, ale ignorují rovnice.

Fyzikálně informované neuronové sítě (PINNs), popularizované prací Raissiho a kol., představují elegantní sjednocení těchto dvou světů. Nejde o novou architekturu ve smyslu uspořádání neuronů – PINN je často "obyčejný" plně propojený vícevrstvý perceptron (MLP), který jsme poznali v přednášce 8. Revoluce spočívá v **trénovacím procesu a konstrukci ztrátové funkce**. PINNs nám umožňují trénovat modely s minimem dat, nebo dokonce zcela bez dat, pouze na základě znalosti fyzikálních zákonů.

2.2 Mechanismus: Anatomie hybridní ztrátové funkce

Abychom pochopili, jak PINN funguje, musíme se vrátit k tomu, co vlastně neuronová síť dělá při tréninku. Jak víme z přednášky 8, síť se snaží minimalizovat chybovou funkci (Loss Function). U standardní sítě je tato chyba definována čistě jako nesoulad mezi predikcí sítě a "pravdou" (trénovacími daty).

U PINN je celková ztráta L_total kompozicí tří fundamentálně odlišných sil, které táhnou parametry sítě (váhy a biasy) různými směry, dokud nenajdou rovnováhu.

Pojďme si tyto členy rozebrat do hloubky, protože právě zde se odehrává ona magie:

1. Datová ztráta (L_data): "Ukotvení v realitě"

Toto je klasická ztráta, kterou známe (zpravidla MSE - Mean Squared Error). Měří chybu na omezeném počtu bodů, kde máme k dispozici "tvrdá data" z experimentu nebo vysoce přesné simulace. Tento člen nutí síť, aby "procházela" naměřenými body.

2. Fyzikální ztráta (L_physics): "Respektování zákonů"

Toto je klíčová inovace. Zde penalizujeme síť za to, že její výstup nesplňuje danou parciální diferenciální rovnici (PDE). Představme si, že modelujeme chladnutí kovového ingotu, což se řídí rovnicí vedení tepla.

Neuronová síť je diferencovatelná funkce. Můžeme tedy vzít její výstup u_NN a dosadit ho do této rovnice. Pokud síť reprezentuje fyzikálně správné řešení, výsledek by měl být nula. Pokud ne, vznikne **reziduum** f.

Ztráta L_physics je pak průměrná kvadratická chyba tohoto rezidua, počítaná na množině tzv. **kolokačních bodů**.

Co jsou kolokační body? To je zásadní koncept. Jsou to virtuální body v prostoru a čase, kde *nemáme žádná měření*. Můžeme jich vygenerovat tisíce nebo miliony, prakticky zadarmo. V každém tomto bodě říkáme síti: "Nevím, jaká je zde přesně teplota, ale vím, že ať je jakákoliv, musí splňovat rovnici vedení tepla." Tímto způsobem fyzika "vyplňuje mezery" mezi řídkými experimentálními daty a funguje jako extrémně silný regularizátor.

3. Okrajové a počáteční podmínky (L_BC/IC): "Definice problému"

Diferenciální rovnice má nekonečně mnoho řešení. Abychom získali to jediné správné pro náš konkrétní problém, musíme definovat okrajové podmínky (BC - Boundary Conditions, např. teplota na povrchu ingotu) a počáteční podmínky (IC - Initial Conditions, např. teplota ingotu v

čase t=0). Na rozdíl od klasických numerických metod (FEM), které tyto podmínky často splňují "konstrukcí" (hard constraints), PINNs je obvykle zahrnují do ztrátové funkce jako "měkké omezení" (soft constraints).

To znamená, že síť se musí *naučit* splňovat okrajové podmínky, což může být někdy zdrojem chyb, zejména u složitých geometrií.

2.3 Technologie v pozadí: Automatická diferenciace (AD)

Možná se ptáte: "Jak počítač spočítá ty parciální derivace, které potřebujeme pro fyzikální ztrátu?" Zde studenti často dělají chybu a domnívají se, že používáme numerickou aproximaci. To by však bylo nepřesné a výpočetně neefektivní pro vysokorozměrné problémy.

PINNs využívají technologii zvanou **Automatická diferenciace (AD)**, která je motorem všech moderních frameworků jako PyTorch, TensorFlow nebo JAX. AD není ani symbolická diferenciace (jako v Mathematice), ani numerická. Je to technika, která při průchodu dat sítí ("forward pass") buduje výpočetní graf a přesně aplikuje řetězové pravidlo pro výpočet derivací výstupu podle vstupu. Díky AD můžeme získat **přesné hodnoty derivací** (až na strojovou přesnost) v libovolném bodě domény, bez nutnosti generovat mřížku (mesh). To činí PINNs "mesh-free" metodou, což je obrovská výhoda oproti FEM, zejména v problémech s velkými deformacemi nebo ve vysokých dimenzích.

2.4 Výzvy při tréninku PINNs: Není to tak snadné

Ačkoliv teorie zní elegantně, praxe je složitější. Trénink PINN je náročnější optimalizační problém než trénink klasické sítě na klasifikaci obrázků. Důvodem je **konflikt mezi složkami ztrátové funkce**. Členy L_data, L_physics a L_BC mohou mít řádově odlišné velikosti a jejich gradienty mohou táhnout parametry sítě protichůdnými směry.

- **Gradient Pathology:** Často se stává, že gradienty od okrajových podmínek jsou velmi strmé, zatímco gradienty od fyziky uvnitř domény jsou ploché. Síť se pak rychle naučí splnit okrajové podmínky, ale uvnitř domény "halucinuje" nefyzikální řešení.

- **Spectral Bias:** Neuronové sítě mají tendenci učit se nejprve nízkofrekvenční funkce (hladké průběhy) a teprve později vysokofrekvenční detaily. Pokud řešení PDE obsahuje ostré změny (např. rázové vlny nebo fázová rozhraní), PINN může mít potíže je zachytit.

Pro řešení těchto problémů se používají pokročilé techniky, jako je **adaptivní váhování ztrát** (kde se váhy w_physics mění dynamicky během tréninku, aby vyrovnaly histogramy gradientů) nebo speciální aktivační funkce (např. sinusové funkce v metodě SIREN), které lépe zachycují vysoké frekvence.

2.5 Aplikace v materiálovém inženýrství: Od simulace k objevu

Nyní se podívejme, jak PINNs mění pravidla hry v našem oboru. Rozlišujeme dva hlavní typy úloh: dopředné (Forward) a inverzní (Inverse).

Dopředné problémy (Forward Problems): Rychlejší než FEM?

Zde známe rovnice, parametry i okrajové podmínky a hledáme řešení u(x,t). V této oblasti PINNs soutěží s klasickými solvery (FEM, CFD).

- **Výhoda PINN:** Jsou "mesh-free". Nemusíte generovat složitou síť pro komplikovanou geometrii (např. porézní médium). Řešení je spojitá, diferencovatelná funkce, kterou můžete vyhodnotit kdekoli.
- **Nevýhoda:** Pro jednoduché problémy jsou často pomalejší a méně přesné než vyladěné FEM kódy. Jejich síla se ukazuje až u multifyzikálních, vysokodimenzionálních problémů.

Inverzní problémy (Inverse Problems): "Killer App" pro materiály

Zde PINNs naprosto dominují. Představte si, že máte experimentální data (např. z měření koncentrace látek v čase), ale neznáte materiálové parametry (např. difuzní koeficient D) v rovnici difúze.

- **Klasický přístup:** Iterativní "trial-and-error". Odhadnete D, spustíte simulaci, porovnáte s daty, opravíte D, opakujete. To je výpočetně drahé.
- **PINN přístup:** Neznámý parametr D učiníte **trénovatelnou proměnnou** sítě (stejně jako váhy). Síť během tréninku minimalizuje datovou ztrátu (aby seděla na experiment) A SOUČASNĚ fyzikální ztrátu (aby splňovala Fickův zákon).
- **Výsledek:** Na konci tréninku získáte nejen rekonstrukci koncentračního pole v celém prostoru a čase (i tam, kde jste neměřili), ale jako vedlejší produkt vám "vypadne" přesná hodnota difuzního koeficientu D.

Konkrétní příklady z výzkumu:

1. **Fickova difúze:** Identifikace difuzních koeficientů závislých na koncentraci z experimentálních profilů. PINN dokáže určit funkční závislost D(c) nebo D(x), což je klasickými metodami obtížné.
2. **Mechanika pevných látek:** Identifikace elastických modulů nebo parametrů poškození z měření posunutí (např. pomocí DIC - Digital Image Correlation) na vzorku s trhlinou. PINN řeší rovnice lineární elasticity a inverzně určuje materiálové vlastnosti v místě koncentrace napětí.
3. **Optické metamateriály:** Rekonstrukce permitivity a permeability nanostrukturovaných materiálů z měření rozptylu světla (řešení inverzních Maxwellových rovnic).

PINNs tak fungují jako **mikroskop do fyziky**: umožňují nám "vidět" parametry, které nelze přímo měřit, tím, že je "vydedukují" z pozorovaných dat skrze prizma fyzikálních zákonů.

Kapitola 3: Řešení otázky #2 – Kvantifikace Nejistoty v DL

3.1 Motivace: Nebezpečí bodového odhadu

Vraťme se k našemu druhému problému. Představte si, že používáte neuronovou síť k predikci životnosti lopatky turbíny. Model vám řekne: "Zbývající životnost je 500 hodin." Znamená to, že máte 500 hodin do havárie? Nebo to znamená, že model "viděl" podobná data a průměrná životnost byla 500, ale rozptyl byl od 10 do 1000 hodin? Nebo to znamená, že model *nikdy* neviděl tento typ zatížení a prostě si číslo vymyslel (halucinoval)?

Rozlišení mezi těmito situacemi je otázkou života a smrti. V inženýrství potřebujeme predikce s "error barem". Musíme rozlišovat dva typy nejistoty:

1. **Aleatorická nejistota (Data Uncertainty):** Je inherentní vlastností dat. Vzniká ze šumu v měření (chyba senzoru) nebo z přirozené variability materiálu (mikrostrukturální heterogenita). Tuto nejistotu nelze snížit přidáním více dat – je to vlastnost systému. Může být *homoscedastická* (konstantní šum) nebo *heteroscedastická* (šum závisí na vstupu).

2. **Epistemická nejistota (Model Uncertainty):** Je to nejistota "z nevědomosti". Znamená to, že model nemá dostatek informací (trénovacích dat) v dané oblasti vstupního prostoru. Tuto nejistotu **lze** snížit přidáním nových dat.

Naším cílem je model, který pro každý vstup x vrátí nejen predikci y, ale i distribuci pravděpodobnosti p(y|x).

3.2 Přístup 1: Bayesovské Hluboké Učení (BNN)

Klasické neuronové sítě hledají jednu optimální sadu vah W. Bayesovské neuronové sítě (BNN) přistupují k problému jinak. Předpokládají, že každá váha v síti není číslo, ale náhodná veličina s rozdělením pravděpodobnosti (normální rozdělení se střední hodnotou a rozptylem).

Princip: Trénink BNN neznamená hledání "nejlepších" vah, ale hledání tzv. **posteriorní distribuce** vah P(W|Data) pomocí Bayesova teorému. To nám říká: "Jaké jsou pravděpodobné hodnoty vah vzhledem k datům, která jsme viděli?" Při predikci pak neprovádíme jeden průchod sítí. Místo toho provádíme tzv. **Bayesovské průměrování**: vzorkujeme různé sady vah z jejich distribucí a pro každou sadu uděláme predikci. Výsledkem je soubor (distribuce) predikcí.

Průměr této distribuce je náš odhad, rozptyl je naše nejistota.

Nevýhoda: Exaktní výpočet posteriorní distribuce je u moderních sítí s miliony parametrů matematicky nemožný (intraktabilní). Musíme používat aproximace, jako je **Variační Inference (Variational Inference - VI)**. Variační inference se snaží nahradit složitou skutečnou distribuci

jednodušší (např. Gaussovskou) distribucí a minimalizovat rozdíl mezi nimi (pomocí KL-divergence v rámci tzv. ELBO funkce). I přes tyto triky je trénink BNN výpočetně náročný, nestabilní a obtížně škálovatelný na velké sítě.

3.3 Přístup 2: Monte Carlo Dropout – "Bayes for Cheap"

Zde přichází na scénu metoda, která způsobila revoluci v praktickém nasazení UQ (Uncertainty Quantification). V roce 2016 Yarin Gal a Zoubin Ghahramani ukázali, že trénování sítě s technikou **Dropout** je matematicky ekvivalentní aproximaci Bayesovské inference.

Trik MC Dropout: Techniku Dropout jsme poznali již v přednášce 8 jako regularizační techniku: během tréninku náhodně "vypínáme" neurony, abychom zabránili přeučení. Při testování se Dropout standardně vypíná. Trik **Monte Carlo (MC) Dropout** spočívá v tom, že **Dropout necháme zapnutý i při predikci (inferenci)**.

Postup (Algoritmus pro materiálového vědce): Chcete predikovat pevnost nové slitiny X_new.

1. Vezměte svou natrénovanou síť.
2. Zapněte Dropout (např. s pravděpodobností vypnutí 10 %).
3. Pošlete X_new skrz síť T-krát (např. T=100 průchodů).
4. Protože v každém průchodu náhodně vypadnou jiné neurony, získáte 100 mírně odlišných predikcí: y_1, y_2, … , y_100.

Tento soubor predikcí reprezentuje vzorky z prediktivní distribuce.

- **Finální predikce:** Průměr těchto hodnot.
- **Epistemická nejistota:** Rozptyl (variance) těchto hodnot.

Interpretace: Pokud je síť v dané oblasti "sebejistá", vypnutí několika neuronů nezmění výsledek zásadně – rozptyl bude malý. Pokud je síť v oblasti, kterou nezná (extrapolace), je její vnitřní reprezentace křehká. Vypnutí neuronů povede k drasticky odlišným výsledkům – rozptyl bude velký.

Výhody a limity: Obrovskou výhodou MC Dropout je, že nevyžaduje žádnou změnu architektury ani trénovacího procesu. Můžete ho aplikovat na již natrénované modely (pokud měly Dropout vrstvy). Je to "Bayesovství zadarmo".

- Na druhou stranu, kritici (a některé snippety) upozorňují, že nejistota získaná z MC Dropout nemusí být vždy přesně kalibrovaná (může být podhodnocená) a závisí na volbě parametru dropout rate.

- Pro přesnější odhady se někdy používají **Deep Ensembles** (natrénování 5-10 různých sítí od začátku), což dává kvalitnější nejistotu, ale za cenu 5-10x vyšších nákladů na trénink.

- Ještě pokročilejší metodou je **Concrete Dropout**, kde se samotná pravděpodobnost dropoutu učí jako parametr sítě, čímž se odstraňuje nutnost manuálního ladění.

- Další moderní alternativou, zmiňovanou v literatuře, je **Conformal Prediction** (např. MC-CP), která poskytuje statisticky garantované intervaly spolehlivosti a v kombinaci s MC Dropoutem může nabídnout to nejlepší z obou světů – pokrytí skutečných hodnot i v oblastech mimo distribuci.

Aplikace v materiálech: MC Dropout byl úspěšně nasazen například pro:

- **Predikci meze kluzu:** Model nejen odhadne pevnost, ale varuje inženýra, pokud je vstupní složení slitiny příliš exotické (vysoká nejistota).

- **Segmentaci mikrostruktur:** U-Net s MC Dropoutem vygeneruje "mapu nejistoty" (uncertainty map), která ukazuje pixely, kde si síť není jistá (např. nejasné hranice zrn). To umožňuje expertovi zkontrolovat jen problematické oblasti.

- **Active Learning:** V kombinaci s DFT výpočty. Algoritmus prozkoumává chemický prostor a vybírá k drahému DFT výpočtu jen ty materiály, kde má model nejvyšší nejistotu (pomocí akvizičních funkcí), čímž dramaticky zefektivňuje hledání nových materiálů.

Kapitola 4: Závěr a výhled na příští týden

Shrnutí: Kompletní arzenál

Dnes jsme udělali kritický krok od "akademických hraček" k robustním inženýrským nástrojům.

1. **PINNs** nám umožňují překlenout propast mezi daty a fyzikou. Umožňují nám modelovat systémy, kde data chybí, ale známe rovnice, a co je důležitější, umožňují nám řešit inverzní problémy – objevovat materiálové vlastnosti přímo z pozorování.

2. **Kvantifikace nejistoty (BNN/MC Dropout)** nám dává do ruky záchrannou brzdu. Umožňuje modelům přiznat "nevím", což je nezbytná podmínka pro nasazení AI v bezpečnostně kritických aplikacích a pro efektivní řízení experimentů (Active Learning).

Navázání na P13: Od analýzy k tvorbě

Doteď jsme se v celém kurzu věnovali téměř výhradně **predikci** (dopředný směr: Vstup -> Vlastnost). Ptali jsme se: "Jaké vlastnosti má tento materiál?" Existuje však "Svatý grál" materiálové informatiky, který se ptá opačně: **Inverzní návrh** (Opačný směr: Vlastnost -> Vstup).

"Jak můžeme použít AI ne k analýze existujících materiálů, ale k tvorbě a generování nových, dosud neviděných struktur s vlastnostmi, které si přejeme?"

Chceme, aby nám AI "vymyslela" novou krystalovou strukturu supravodiče nebo novou molekulu léku. K tomu budeme potřebovat zcela novou třídu algoritmů, které se učí tvořit. V naší finální, třinácté přednášce, vstoupíme do fascinujícího světa **Generativních modelů**. Budeme mluvit o Variačních autoenkodérech (VAE), které se učí "mapu" chemického prostoru. Budeme mluvit o Generativních adversariálních sítích (GANs), které se učí tvořit realistické mikrostruktury. A budeme mluvit o **Difúzních modelech** – technologii, která pohání DALL-E a Midjourney a která dnes způsobuje revoluci v "de novo" designu proteinů a krystalů.

Připravte se, příští týden budeme tvořit hmotu.

Works cited

1. Fick's laws of diffusion - Wikipedia, https://en.wikipedia.org/wiki/Fick%27s_laws_of_diffusion 2. Fick's law of diffusion (video) - Khan Academy, https://www.khanacademy.org/science/health-and-medicine/respiratory-system/gas-exchange-jv/v/fick-s-law-of-diffusion 3. Causality-Aware Training of Physics-Informed Neural Networks for Solving Inverse Problems - MDPI, https://www.mdpi.com/2227-7390/13/7/1057 4. Revolutionary Physics Informed Neural Networks (PINNs) Guide - CAE Assistant, https://caeassistant.com/blog/physics-informed-neural-networks-pinns/ 5. What Are Physics-Informed Neural Networks (PINNs)? - MATLAB & Simulink - MathWorks, https://www.mathworks.com/discovery/physics-informed-neural-networks.html 6. Understanding Physics-Informed Neural Networks (PINNs) — Part 1, https://thegrigorian.medium.com/understanding-physics-informed-neural-networks-pinns-part-1-8d872f555016 7. Physics-Informed Neural Networks (PINNs) and Residual Minimization, https://www.ml4science.com/static_files/lectures/07/pinns-intro 8. Physics-informed neural network for the heat equation under imperfect contact conditions and its error analysis - AIMS Press, https://www.aimspress.com/article/doi/10.3934/math.2025364 9. Review of Physics-Informed Neural Networks: Challenges in Loss Function Design and Geometric Integration - MDPI, https://www.mdpi.com/2227-7390/13/20/3289 10. Embedding Physics into Deep Learning: A Structured Review of Physics-Informed Neural Networks | Sciety, https://sciety.org/articles/activity/10.20944/preprints202504.2577.v1 11. From PINNs to PIKANs: Recent Advances in Physics-Informed Machine Learning - arXiv, https://arxiv.org/html/2410.13228v1 12. PINN Inverse Examples, https://pinnx.readthedocs.io/inverse_examples.html 13. (PDF) PINN Model of Diffusion Coefficient Identification Problem in Fick's Laws, https://www.researchgate.net/publication/377194152_PINN_Model_of_Diffusion_Coefficient_Identification_Problem_in_Fick's_Laws 14. PINN Model of Diffusion Coefficient Identification Problem in Fick's Laws | ACS Omega, https://pubs.acs.org/doi/10.1021/acsomega.3c07924 15. Modeling a Typical Non-Uniform Deformation of Materials Using Physics-Informed Deep Learning: Applications to Forward and Inverse Problems - MDPI, https://www.mdpi.com/2076-3417/13/7/4539 16. Physics-informed neural networks for inverse problems in nano-optics and metamaterials, https://opg.optica.org/oe/abstract.cfm?uri=oe-28-8-11618 17. An Introduction to Bayesian

Neural Network and Uncertainty Quantification in Deep Learning-Jacopo Talpini.pdf - CERN Indico, https://indico.cern.ch/event/1208723/contributions/5230073/attachments/2600859/4521507/An%20Introduction%20to%20Bayesian%20Neural%20Network%20and%20Uncertainty%20Quantification%20in%20Deep%20Learning-Jacopo%20Talpini.pdf 18. Monte Carlo Dropout: a practical guide | by Ciaran Bench - Medium, https://medium.com/@ciaranbench/monte-carlo-dropout-a-practical-guide-4b4dc18014b5 19. Scalable Bayesian Uncertainty Quantification for Neural Network Potentials: Promise and Pitfalls | Journal of Chemical Theory and Computation - ACS Publications, https://pubs.acs.org/doi/abs/10.1021/acs.jctc.2c01267 20. Bayesian neural networks for uncertainty quantification in data-driven materials modeling | Request PDF - ResearchGate, https://www.researchgate.net/publication/353995341_Bayesian_neural_networks_for_uncertainty_quantification_in_data-driven_materials_modeling 21. Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning, http://proceedings.mlr.press/v48/gal16.pdf 22. Monte Carlo dropout - AWS Prescriptive Guidance, https://docs.aws.amazon.com/prescriptive-guidance/latest/ml-quantifying-uncertainty/mc-dropout.html 23. [D] MC Dropout is not Bayesian, so why are so many papers still using it for that? - Reddit, https://www.reddit.com/r/MachineLearning/comments/ry61q5/d_mc_dropout_is_not_bayesian_so_why_are_so_many/ 24. When Is Bayesian Machine Learning Actually Useful? - Towards Data Science, https://towardsdatascience.com/when-is-bayesian-machine-learning-actually-useful-1fd8af456e4c/ 25. What is Monte Carlo (MC) dropout? - GeeksforGeeks, https://www.geeksforgeeks.org/deep-learning/what-is-monte-carlo-mc-dropout/ 26. aurelio-amerio/ConcreteDropout: Concrete Dropout implementation for Tensorflow 2.0 and PyTorch - GitHub, https://github.com/aurelio-amerio/ConcreteDropout 27. [P] Concrete dropout implementation for tensorflow 2.0 : r/MachineLearning - Reddit, https://www.reddit.com/r/MachineLearning/comments/vrxpk8/p_concrete_dropout_implementation_for_tensorflow/ 28. Using Monte Carlo conformal prediction to evaluate the uncertainty of deep-learning soil spectral models, https://soil.copernicus.org/articles/11/553/2025/ 29. Uncertainty Estimation for Image Segmentation using Monte Carlo Dropout | PyTorch Tutorial - YouTube, https://www.youtube.com/watch?v=SCFQMbKfdLI 30. Uncertainty Quantification for Material Science and Engineering, https://www.imsi.institute/activities/uncertainty-quantification-and-ai-for-complex-systems/uncertainty-quantification-for-material-science-and-engineering/ 31. Tutorial 2: Comparison to other methods of uncertainty quantification, https://uvadlc-notebooks.readthedocs.io/en/latest/tutorial_notebooks/DL2/Bayesian_Neural_Networks/dl2_bnn_tut2_student_with_answers.html