Přednáška 13: Inverzní návrh a Generativní AI – Svatý grál materiálové vědy

Kapitola 1: Most z přednášky 12 – Překročení hranice od analýzy k tvorbě

Vítejte u třináctého, závěrečného a v mnoha ohledech nejdůležitějšího zastavení našeho semestrálního cyklu „AI v materiálovém inženýrství“. Stojíme na prahu nové éry, kterou můžeme bez nadsázky nazvat érou *Digitální alchymie*.

V minulé, dvanácté přednášce, jsme se společně postavili čelem k existenciální krizi důvěry v umělou inteligenci. Ukázali jsme si, že v inženýrské praxi, kde selhání materiálu může znamenat pád letadla nebo zhroucení mostu, nestačí pouhá statistická korelace. Nestačí, aby model měl vysokou přesnost na trénovacích datech, pokud nerozumí fyzikální realitě nebo pokud je arogantně falešně sebejistý.

Naučili jsme se, jak pomocí Fyzikálně informovaných neuronových sítí (PINNs) vnutit modelům respekt k diferenciálním rovnicím, které vládnou našemu vesmíru. Viděli jsme, jak do ztrátové funkce integrovat rezidua parciálních diferenciálních rovnic (PDEs), a tím donutit síť, aby její predikce byly termodynamicky konzistentní.

Dále jsme se naučili pracovat s nejistotou. Pochopili jsme rozdíl mezi aleatorickou nejistotou (šum v datech) a epistemickou nejistotou (neznalost modelu) a ukázali si, jak pomocí Bayesovského učení a technik jako Monte Carlo Dropout donutit neuronové sítě přiznat „nevím“.

Tím jsme vybudovali robustní základ pro *Vědeckou AI* – umělou inteligenci, která není jen černou skříňkou, ale důvěryhodným partnerem vědce.

Dnes však tento solidní základ použijeme jako odrazový můstek k něčemu, co bylo ještě před dekádou považováno za doménu science fiction. Celý dosavadní kurz, od první jednoduché lineární regrese v Přednášce 4 až po komplexní grafové sítě pro simulaci atomů v Přednášce 10, se pohyboval v jednom směru: **dopředném směru (Forward Direction)**.

1.1 Fundamentální asymetrie: Predikce vs. Návrh

Abychom pochopili revoluční povahu dnešního tématu, musíme si rigorózně definovat rozdíl

mezi tím, co jsme dělali doteď, a tím, co nás čeká. Dopředný problém, kterým jsme se zabývali celých dvanáct týdnů, lze matematicky zapsat jako hledání funkce f, která mapuje vstup X na výstup Y:

Kde:

- **Vstup X** představuje kompletní popis materiálu. Jak jsme viděli v přednášce 2, může to být chemické složení (vektor prvků), krystalová struktura (CIF soubor), mikrostruktura (snímek z SEM) nebo procesní parametry (teplota, tlak, čas).
- **Výstup Y** představuje vlastnost nebo chování materiálu. Může to být skalární hodnota (mez pevnosti, zakázaný pás), kategorická proměnná (typ fáze) nebo celá sekvence hodnot (spektrum, časová řada).
- **Funkce f** je to, co se snažíme aproximovat pomocí AI. Ať už jsme použili Random Forest, CNN nebo GNN, vždy jsme se snažili najít model f, který pro dané X co nejpřesněji predikuje Y.

Ptali jsme se: *„Jakou pevnost bude mít tato ocel, když ji zakalím?“* nebo *„Je tento konkrétní krystal perovskitu stabilní?“*. Ačkoliv je tento úkol výpočetně náročný (často vyžaduje DFT simulace), je matematicky „dobře definovaný“ (well-posed). Pro jednu konkrétní, plně definovanou strukturu existuje (zpravidla) jedna definovaná sada fyzikálních vlastností, daná přírodními zákony. Kauzalita teče od struktury k vlastnosti.

Dnes se však vydáváme proti proudu řeky. Vstupujeme do domény **Inverzního návrhu (Inverse Design)**. Naše otázka se radikálně mění a stává se inženýrskou v pravém slova smyslu: *„Chci materiál s modulem pružnosti přesně 200 GPa, tepelnou vodivostí nad 150 W/mK, odolností proti korozi v mořské vodě a cenou pod 500 Kč/kg. Jaká je jeho struktura X? Jaké má být jeho chemické složení? Jak ho mám vyrobit?“*

Formálně hledáme inverzní funkci.

1.2 Prokletí nejednoznačnosti a historický kontext

Proč je tento úkol označován za „Svatý grál“ a proč je tak obtížný, že jsme si ho nechali až na úplný závěr? Problém spočívá v tom, že inverzní zobrazení f^-1 je matematicky tzv. **ill-posed problem** (špatně podmíněná úloha).

Hlavním důvodem je nejednoznačnost, neboli zobrazení „jeden ku mnoha“ (one-to-many mapping).

- Existuje nekonečně mnoho různých mikrostruktur, které mohou vykazovat stejnou průměrnou tvrdost.
- Existuje tisíce různých organických molekul, které mohou mít stejnou rozpustnost ve vodě nebo stejný excitační potenciál.
- Existuje mnoho kombinací legujících prvků, které mohou vést ke stejné mezi kluzu oceli.

Když zadáme požadovanou vlastnost Y, neexistuje jediné správné řešení X. Existuje celá varieta řešení, z nichž některá jsou fyzikálně realizovatelná, jiná jsou nestabilní a další jsou

ekonomicky nesmyslná.

Tradiční přístup k tomuto problému byl po staletí „Edisonský“ – metoda pokus-omyl, vedená intuicí experta. V posledních dekádách jsme tento proces urychlili pomocí **Vysokokapacitního experimentování (HTE)**, o kterém jsme mluvili v přednášce 2. V tomto přístupu generujeme tisíce kandidátních materiálů (kombinatorické knihovny), změříme jejich vlastnosti a doufáme, že se trefíme do cíle. I když jsme tento proces vylepšili pomocí **Aktivního učení** (viz přednáška 5 a 12), kde model vybírá další experiment na základě nejistoty, stále se v podstatě jedná o prohledávání (screening). Stále jsme omezeni tím, co nás napadne otestovat.

Cílem dnešní přednášky je představit vám **Generativní modely** – zcela novou třídu algoritmů, které mění pravidla hry. Tyto stroje se nesnaží vlastnosti predikovat. Ony se učí samotnou podstatu a distribuci hmoty. Učí se „gramatiku“ chemie a „syntaxi“ krystalografie. Díky tomu nám umožňují „vzorkovat“ nové materiály přímo z požadované oblasti vlastností, čímž efektivně invertují proces objevování. Přecházíme od pasivní analýzy existujícího k aktivní tvorbě nového.

Kapitola 2: Generativní modely – Stroje, které tvoří

Abychom pochopili hloubku revoluce, kterou generativní AI přináší do materiálové vědy, musíme nejprve definovat rozdíl mezi tím, co jsme dělali doteď (diskriminativní modelování), a tím, co budeme dělat dnes.

- **Diskriminativní modely** jsou ty, které jsme probírali v přednáškách 4 až 12. Ať už šlo o klasifikaci ocelí pomocí SVM v přednášce 5, analýzu obrazu pomocí CNN v přednášce 9 nebo predikci energie pomocí GNN v přednášce 10, vždy jsme modelovali **podmíněnou pravděpodobnost P(Y|X)**. Ptali jsme se: jaká je pravděpodobnost vlastnosti Y (např. "je to martenzit"), pokud vidím data X (obrázek)? Tyto modely se učí kreslit hranice v datech. Rozlišují mezi „feritem“ a „martenzitem“, mezi „stabilním“ a „nestabilním“. Jsou to analytici.

- **Generativní modely** mají ambicióznější cíl. Učí se **sdruženou pravděpodobnost P(X, Y)** nebo samotnou distribuci dat P(X). Nesnaží se data roztřídit, snaží se pochopit, jak data vznikají. Snaží se modelovat samotnou distribuci hmoty v přírodě. Místo aby klasifikovaly obrázek mikrostruktury, učí se, jak takový obrázek namalovat pixel po pixelu tak, aby byl statisticky a fyzikálně nerozeznatelný od reality. Jsou to tvůrci.

V následujících sekcích si představíme tři klíčové architektury, které byly avizovány v závěru přednášky 12 a které dnes tvoří páteř generativního designu materiálů.

2.1 Variační autoenkodéry (VAE): Mapování chemického vesmíru

Variační autoenkodér (Variational Autoencoder, VAE) je jednou z nejzákladnějších a nejužitečnějších generativních architektur v materiálové vědě. Jeho síla spočívá v schopnosti

transformovat diskrétní, nespojitý svět chemie (kde mezi molekulou metanu a etanu není "nic") na **spojitou, diferencovatelnou mapu**.

Princip: Komprese do pravděpodobnostního prostoru

VAE se skládá ze dvou neuronových sítí spojených do tvaru přesýpacích hodin, což je koncept, který jsme v jiné formě (U-Net) viděli v přednášce 9:

1. **Encoder (Kompresor):** Tato síť vezme vstupní materiál X (např. krystalovou strukturu reprezentovanou grafem nebo voxelovou mřížkou) a „zmáčkne“ ho do nízko-dimenzionálního vektoru z. Tento vektor leží v takzvaném **latentním prostoru** (latent space).

2. **Decoder (Generátor):** Tato síť vezme latentní kód z a snaží se z něj co nejpřesněji zrekonstruovat původní materiál X (výstup X').

Kde je ten trik? Vzpomeňme si na přednášku 3, kde jsme používali PCA (Analýzu hlavních komponent) pro redukci dimenze. PCA je lineární a deterministická. VAE je nelineární a **pravděpodobnostní**. Klíčová inovace VAE spočívá v tom, že Encoder nemapuje materiál na jeden pevný bod v latentním prostoru, ale na **Gaussovu distribuci** (obláček pravděpodobnosti), definovanou střední hodnotou μ a rozptylem σ. Během tréninku se síť snaží minimalizovat rekonstrukční chybu (aby výstup vypadal jako vstup) a zároveň se snaží udržet latentní distribuci blízkou standardnímu normálnímu rozdělení (pomocí tzv. KL-divergence). Tento mechanismus nutí síť, aby latentní prostor organizovala efektivně, hladce a spojitě. Podobné materiály jsou mapovány blízko sebe.

Aplikace: Navigace a optimalizace

Proč je to pro materiálového vědce užitečné? Protože latentní prostor se stává mapou chemického vesmíru, po které můžeme chodit.

- Představte si, že v latentním prostoru máme bod A (známý polymer s vysokou pevností) a bod B (známý polymer s vysokou flexibilitou).

- V reálném světě nemůžeme chemicky "zprůměrovat" dvě molekuly. Ale v latentním prostoru VAE můžeme vést přímku mezi body A a B a vybrat bod přesně uprostřed.

- Když tento středový bod pošleme do Decoderu, síť nám vygeneruje **zcela nový, dosud neexistující polymer**, který bude mít strukturální rysy obou rodičů a pravděpodobně i interpolované vlastnosti.

Tímto způsobem můžeme provádět **gradientní optimalizaci**. Můžeme v latentním prostoru natrénovat jednoduchý regresní model (např. Gaussovský proces z přednášky 5), který mapuje latentní souřadnice na vlastnosti. Poté můžeme v tomto hladkém prostoru hledat směr

(gradient), ve kterém roste požadovaná vlastnost (např. vodivost), posunout se v tomto směru do neprobádané oblasti a nechat Decoder vygenerovat nový kandidátní materiál. VAE nám tak dává kompas k navigaci v dříve chaotickém chemickém prostoru.

2.2 Generativní adversariální sítě (GANs): Souboj padělatele a policisty

Zatímco VAE vynikají v generování diskrétních struktur (molekul, grafů), Generativní adversariální sítě (Generative Adversarial Networks, GANs) jsou absolutními králi v generování realistických spojitých dat, jako jsou **snímky mikrostruktur**.

Princip: Hra s nulovým součtem

GANs jsou založeny na teorii her. Skládají se ze dvou hlubokých neuronových sítí (často konvolučních, viz přednáška 9), které hrají proti sobě v "minimax" hře:

1. **Generátor (Padělatel):** Jeho úkolem je vzít náhodný šum (z latentního prostoru) a vytvořit z něj umělý obrázek mikrostruktury (syntetická data), který je k nerozeznání od skutečného.

2. **Diskriminátor (Policista):** Jeho úkolem je dostat na vstup obrázek a rozhodnout (binární klasifikace), zda je to skutečný snímek z elektronového mikroskopu (z trénovací sady), nebo zda je to padělek vytvořený Generátorem.

Během tréninku se oba zlepšují v evolučním závodě ve zbrojení. Diskriminátor se učí lépe odhalovat drobné chyby (např. nefyzikální zakřivení hranic zrn, špatnou texturu fází), což zpětnou vazbou (přes gradienty) nutí Generátora vytvářet stále dokonalejší a fyzičtější textury. V ideálním bodě rovnováhy (Nash equilibrium) Generátor produkuje mikrostruktury, které jsou statisticky a vizuálně nerozeznatelné od experimentu, a Diskriminátor si musí "házet mincí", protože už nepozná rozdíl.

Aplikace: Řešení problému malých dat a inverzní metalurgie

V přednášce 9 jsme detailně diskutovali o kritickém problému nedostatku anotovaných dat pro trénink segmentačních sítí (jako U-Net) a o nutnosti datové augmentace. GANs zde nabízejí řešení, které daleko přesahuje prosté otáčení obrázků. Můžeme natrénovat GAN na existujících snímcích a poté nechat Generátor vyrobit miliony *nových*, unikátních snímků mikrostruktur. Co je důležité, můžeme generovat i vzácné anomálie (např. specifické defekty), které se v reálných datech vyskytují zřídka, a tím vytrénovat robustnější detekční modely.

Ještě více fascinující je použití tzv. **Conditional GANs (cGANs)** pro studium vztahů „Process-Structure-Property“. Můžeme podmínit Generátor procesními parametry (např. vložím do něj vektor). Pak se můžeme sítě zeptat: *„Vygeneruj mi, jak bude vypadat mikrostruktura této oceli, když ji budu žíhat při 900 °C po dobu 2 hodin.“* Model vygeneruje realistický obrázek, který nahrazuje drahý a časově náročný experiment. Tímto způsobem můžeme virtuálně prozkoumávat prostor zpracování a hledat optimální procesní podmínky pro dosažení požadované morfologie.

2.3 Difúzní modely: Termodynamika tvorby

Nejnovějším a v současnosti nejvýkonnějším hráčem v generativní AI jsou Difúzní modely (Diffusion Models). Je to technologie, která stojí za slavnými systémy jako DALL-E 3 nebo Midjourney, ale v materiálové vědě způsobují tichou revoluci v *de novo* návrhu krystalů a proteinů.

Princip: Odšumování jako inverze entropie

Difúzní modely jsou, na rozdíl od GANs, inspirovány nerovnovážnou termodynamikou. Proces generování je modelován jako fyzikální proces difúze. Má dvě fáze:

1. **Dopředný proces (Forward Diffusion):** Vezmeme reálnou strukturu materiálu (pozice atomů x_0) a v postupných časových krocích t k ní přidáváme malá množství Gaussovského šumu. S rostoucím t se struktura postupně rozpadá, atomy se náhodně posouvají, až v čase T zbyde jen čistý, náhodný šum (stav maximální entropie). Tento proces je deterministický a snadno popsatelný.

2. **Zpětný proces (Reverse Diffusion):** Zde nastupuje AI. Naučíme neuronovou síť (často založenou na U-Netu nebo GNN s mechanismem pozornosti) tento proces obrátit. Síť se učí predikovat šum, který byl přidán v každém kroku, a odečíst ho. Učí se, jak z náhodného chaosu krok za krokem „odšumět“ data tak, aby vznikla smysluplná, uspořádaná struktura.

Je to jako kdybychom se dívali na film, kde se krystalová mřížka rozpouští v tepelném šumu, a pak se učili tento film přehrávat pozpátku, abychom viděli, jak krystalizace probíhá (ačkoliv matematicky jde o denoising score matching).

Aplikace: Krystalový design (CDVAE, M3GNet)

Difúzní modely řeší problém, se kterým VAE a GANs často bojují: generování přesných 3D souřadnic atomů v periodické mřížce bez porušení fyzikálních vazeb. Modely jako **CDVAE** (Crystal Diffusion VAE) nebo generativní verze modelů typu **M3GNet** (které jsme jako potenciály

viděli v přednášce 10) dokáží generovat krystalové mřížky, které jsou termodynamicky stabilní (leží v lokálních minimech DFT energie). Můžeme tak difúznímu modelu zadat inverzní úlohu: *„Vygeneruj stabilní krystalovou strukturu se složením Li_x M_y O_z, která má velký prostor pro difúzi lithia (vhodné pro baterie).“* Model začne z náhodného šumu a postupně „zkondenzuje“ atomy do mřížky, která respektuje kvantově-mechanická pravidla a symetrie (díky GNN architektuře), aniž by kdy viděl přesně tuto sloučeninu v trénovacích datech.

Kapitola 3: Pokročilé strategie pro reálná data

Nyní máme k dispozici generativní modely i prediktivní modely. Přesto v praxi stále narážíme na dva fundamentální limity, které se jako červená nit táhly celým naším kurzem: nedostatek vysoce kvalitních anotovaných dat přednáška 2 a 5) a propastný rozdíl mezi ideální simulací a špinavou realitou (přednáška 10). Abychom mohli AI nasadit v reálném výzkumu, musíme nasadit dvě pokročilé strategie učení.

3.1 Self-supervised learning (SSL): Využití temných dat

V přednášce 5 jsme zavedli dělení na učení s učitelem (Supervised, kde známe Y) a bez učitele (Unsupervised, kde hledáme shluky). **Self-supervised learning (SSL)** je chytrá cesta mezi tím, která nám umožňuje odemknout potenciál obrovského množství dat, která leží ladem.

V materiálové vědě trpíme nedostatkem „štítků“ (labels Y), ale topíme se v datech X.

- Máme miliony snímků z elektronových mikroskopů v archivech univerzit, ale nikdo k nim nenapsal „toto je bainitická ocel s 0.5% C“.
- Máme databáze jako Materials Project s miliony struktur, ale jen u zlomku z nich byla změřena například tepelná vodivost.
- Máme miliony vědeckých abstraktů, které nikdo neanotoval.

SSL nám umožňuje tato data využít k předtrénování silných modelů. **Princip:** Vytvoříme si „pomocnou“ (pretext) úlohu, pro kterou nepotřebujeme lidskou anotaci, protože „pravdu“ si můžeme vygenerovat sami z dat.

- **Masked Modeling (Maskování):** Jak jsme viděli u modelu MatBERT v přednášce 11 , skryjeme část vstupu (např. vymažeme náhodné atomy z krystalové struktury nebo vyčerníme čtverce v obrázku mikrostruktury) a nutíme model, aby chybějící části zrekonstruoval na základě kontextu zbytku. Aby to model dokázal, musí pochopit chemii nebo morfologii. Nemůže jen hádat.

- **Kontrastivní učení:** Vezmeme obrázek mikrostruktury a vytvoříme jeho dvě verze (např. jednu otočíme a druhou ořízneme - viz augmentace v přednášce 9). Nutíme model, aby poznal, že tyto dva různé obrazy reprezentují „stejný“ materiál, a zároveň aby je odlišil od obrázku jiného materiálu. Tím se model učí robustní reprezentaci, která je invariantní vůči

detailům snímání.

Tímto způsobem se model naučí bohatou reprezentaci materiálu (featurizaci) sám od sebe na milionech neanotovaných vzorků. Tuto „předtrénovanou“ síť pak můžeme vzít a s minimem drahých anotovaných dat ji „doladit“ (fine-tuning) na konkrétní predikci vlastnosti. SSL je klíčem k využití „temných dat“ v materiálové vědě a řešením problému malých dat.

3.2 Adaptace na doménu (Domain Adaptation) – Problém "Sim2Real"

V přednášce 10 jsme se učili o MLIPs trénovaných na datech z DFT. DFT je úžasné, ale je to idealizovaná simulace při 0 K v dokonalém vakuu, s periodickými okrajovými podmínkami a bez defektů. Realita v laboratoři je nedokonalá, probíhá při 300 K (nebo 1000 K), vzorky jsou konečné, obsahují nečistoty a měření je zatíženo šumem (aleatorická nejistota).

Tento statistický rozdíl v distribuci dat mezi **zdrojovou doménou** (simulace) a **cílovou doménou** (experiment) se nazývá **Domain Shift**. Pokud vezmeme model natrénovaný čistě na datech z Materials Project a použijeme ho k predikci vlastností reálného vzorku z laboratoře, často selže, protože vidí data, která jsou „mimo distribuci“ (out-of-distribution).

Řešení: Adaptace na doménu (Domain Adaptation). Cílem je vytvořit model, který se naučí extrahovat takové rysy (features), které jsou společné pro obě domény (invariantní vůči doméně) – tedy skutečnou fyzikální podstatu.

- Jednou z technik je využití **adversariálního učení** (podobně jako u GANs). K našemu prediktivnímu modelu (např. GNN) přidáme další síť – „doménový diskriminátor“.
- Tento diskriminátor se snaží poznat, zda latentní reprezentace materiálu pochází ze simulace nebo z experimentu.
- Náš hlavní model (feature extractor) se pak snaží tuto síť oklamat – snaží se naučit takové deskriptory, podle kterých nelze poznat původ dat. Tím se efektivně odstraní specifický „otisk“ simulace nebo šum experimentu a zůstane čistá materiálová informace.

Toto je naprosto nezbytné pro budoucí nasazení AI v **autonomních laboratořích** (zmíněných v přednášce 2), kde robot musí rozhodovat na základě modelů trénovaných na simulacích, ale operuje v reálném světě.

Kapitola 4: Závěrečné shrnutí – Cesta od dat k objevům

Tímto se uzavírá náš kurz. Dovolte mi v krátkosti, ale komplexně shrnout tu neuvěřitelnou intelektuální cestu, kterou jsme za posledních 13 týdnů urazili. Není to jen seznam metod; je to příběh o tom, jak jsme se naučili digitalizovat hmotu a jak jsme postupně předávali žezlo objevování algoritmům.

Fáze 1: Základy a klasické ML – Budování základů (Přednáška 1 až 7)
Naše cesta začala pokorou před daty. V přednáškách 2 a 3 jsme pochopili starou pravdu „Garbage in, Garbage out“. Naučili jsme se, že AI není magie, ale statistika na steroidech. Zjistili jsme, že model neumí „vidět“ atomy, pokud mu je nepřevedeme na vektory pomocí featurizace (Pymatgen, Matminer). Naučili jsme se bojovat s „prokletím dimenzionality“ pomocí PCA a čistit data od chybějících hodnot. V přednáškách 4 až 6 jsme si osvojili řemeslo validace. Pochopili jsme, proč je křížová validace (Cross-validation) svatým zákonem proti přeučení. Seznámili jsme se s „dříči“ klasického ML – Random Forestem a Gradient Boostingem, které dodnes excelují na tabulkových datech díky své schopnosti agregovat moudrost davu rozhodovacích stromů.

Fáze 2: Revoluce hlubokého učení – Od manuálu k automatizaci (Přednáška 8)
V Přednášce 8 přišel zlom. Odhodili jsme manuální featurizaci, která nás limitovala naší vlastní intuicí. Vstoupili jsme do světa neuronových sítí – vícevrstvých perceptronů (MLP). Pochopili jsme sílu nelinearity (aktivační funkce ReLU) a mechanismu učení pomocí zpětné propagace chyby (Backpropagation) a gradientního sestupu. Zjistili jsme, že sítě se mohou učit reprezentace automaticky, přímo z hrubých dat.

Fáze 3: Specializované architektury – Naslouchání struktuře dat (Přednáška 9 až 11)
Pak jsme začali být chytřejší v tom, jakou architekturu volíme. Přestali jsme používat univerzální kladivo (MLP) na všechno a začali jsme naslouchat symetrii dat.

- Pro **mřížky a obrazy** (mikrostruktury) jsme v přednášce 9 nasadili Konvoluční sítě (**CNN**). Využili jsme jejich translační invarianci a lokální filtry k segmentaci hranic zrn (U-Net) a klasifikaci fází.
- Pro **atomy a vazby** (krystaly, molekuly) jsme v přednášce 10 nasadili Grafové sítě (**GNN**). Respektovali jsme grafovou povahu hmoty a permutační invarianci. Tím jsme odemkli možnost vytvářet ML potenciály (MLIPs), které simulují chemii s přesností DFT, ale milionkrát rychleji.
- Pro **sekvence a text** (spektra, literatura) jsme v přednášce 11 nasadili **Transformery**. Pochopili jsme sílu mechanismu pozornosti (Self-Attention), který vyřešil limity RNN. Viděli jsme, jak modely jako MatBERT dokáží přečíst miliony článků a extrahovat z nich znalosti pomocí Transfer Learningu.

Fáze 4: Vědecká AI – Návrat k fyzice a pokoře (Přednáška 12)
V minulé lekci jsme dospěli. Přestali jsme si hrát na černou skříňku. Uvědomili jsme si, že data nestačí. Ukotvili jsme naše modely ve fyzikální realitě pomocí **PINNs**, které přímo řeší diferenciální rovnice. Naučili jsme naše modely pokoře pomocí kvantifikace nejistoty (**BNN**, MC Dropout), což je nezbytné pro bezpečné inženýrství a efektivní experimentování.

Fáze 5: Tvůrčí AI – Uzavření kruhu (Přednáška 13) A dnes jsme kruh uzavřeli. S nástroji jako **VAE, GANs a Difúzní modely** jsme přešli od pozorovatele k tvůrci. Už se neptáme jen „co to je“, ale říkáme „vytvoř to“.

Nyní stojíte na prahu nové éry materiálového inženýrství. Máte k dispozici kompletní ekosystém nástrojů, který vám umožňuje zrychlit cyklus objevování materiálů z dekád na měsíce. Už nejste jen materiáloví inženýři, jste materiáloví informatici. Budoucnost patří těm, kteří dokáží spojit hlubokou fyzikální intuici chemika s hrubou výpočetní silou a elegancí algoritmů, které jsme zde společně studovali.

Děkuji vám za pozornost, trpělivost a zvídavost v celém tomto kurzu. Nyní je řada na vás – vezměte tyto nástroje, jděte do laboratoří (virtuálních i skutečných) a navrhněte materiály budoucnosti, které změní svět.